

硕士学位论文

中南大学研究生学位论文 LaTeX 模板

LaTeX Template of Postgraduate Thesis of

Central South University

专业学位类别

电子信息

专 业 领 域

电子信息

作 者 姓 名

韦康琦

指 导 教 师

张德宇

2026 年 4 月

中图分类号 TP391

学校代码 10533

UDC 004.9

学位类别 专业学位

硕士学位论文

中南大学研究生学位论文 LaTeX 模板

LaTeX Template of Postgraduate Thesis of Central South University

作 者 姓 名	韦康琦
专业学位类别	电子信息
专 业 领 域	电子信息
研 究 方 向	人工智能
二级培养单位	计算机学院
指 导 教 师	张德宇
副 指 导 教 师	

论文答辩日期

答辩委员会主席

中 南 大 学

2026 年 4 月

学位论文原创性声明

本人郑重声明，所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了论文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中南大学或其他教育机构的学位或证书而使用过的材料。与我共同工作的同志对本研究所作的贡献均已在论文中作了明确的说明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

学位论文作者签名：_____ 日期：_____ 年 ____ 月 ____ 日

学位论文版权使用授权书

本学位论文作者和指导教师完全了解中南大学有关保留、使用学位论文的规定：即学校有权保留并向国家有关部门或机构送交学位论文的复印件和电子版，允许本学位论文被查阅和借阅。本人授权中南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索和公开传播，可以采用复印、缩印或其它手段保存和汇编学位论文。本人同意按《中国优秀博硕士学位论文全文数据库出版章程》规定享受相关权益。本人保证：毕业后以学位论文内容发表的论文作者单位注明中南大学；学位论文电子文档的内容和纸质学位论文的内容相一致。

延缓公开论文延缓到期后适用本授权书，涉密论文在解密后适用本授权书。

本学位论文属于：（请在以下相应方框内打“√”）

☐ 公开

☐ 延缓公开，延缓期限（____ 年 ____ 月 ____ 日至 ____ 年 ____ 月 ____ 日）

学位论文作者签名：_____ 指导教师签名：_____

日期：_____ 年 ____ 月 ____ 日 日期：_____ 年 ____ 月 ____ 日

（填写阿拉伯数字）

中南大学研究生学位论文 LaTeX 模板

摘要： 随着人工智能与计算机视觉技术的飞速发展，人体姿态估计（Human Pose Estimation, HPE）作为连接数字世界与物理世界的关键纽带，已在众多领域展现出巨大的应用价值。该技术旨在从图像或视频中定位人体关键点（如肩、肘、腕、膝等）并构建骨架结构，广泛应用于人机交互、虚拟现实/增强现实（VR/AR）、智慧医疗康复、体育动作分析以及智能安防监控等场景。特别是在医疗康复领域，通过精确捕捉患者的运动轨迹，系统能够量化评估肢体功能，辅助医生制定个性化的治疗方案。

尽管基于深度学习的二维（2D）人体姿态估计技术已趋于成熟，但其仅能提供平面位置信息，缺乏深度维度，难以全面反映人体在三维空间中的真实姿态与运动细节，限制了其在复杂交互场景下的应用潜力。相比之下，三维（3D）人体姿态估计能够恢复人体关节的空间坐标，提供更丰富的运动学信息。然而，直接从单目图像恢复 3D 姿态本质上是一个不适定问题（Ill-posed Problem），面临着严重的深度歧义性，即多种三维姿态可能投影为相同的二维图像，导致在遮挡或复杂背景下估计精度大幅下降。为了解决这一难题，双目立体视觉（Binocular Stereo Vision）技术通过模拟人类双眼感知机制，利用左右视图的视差原理和三角测量几何约束，能够提供明确的深度线索，从而有效消除深度模糊，显著提升三维重建的精度与鲁棒性。

然而，随着物联网（IoT）与边缘计算的兴起，将高精度的 3D 姿态估计模型部署至移动端或嵌入式设备（如智能手机、无人机、XR 眼镜）已成为行业迫切需求。现有的高性能 3D 姿态估计模型（如基于 Transformer 或复杂 3D 卷积的网络）通常伴随着巨大的参数量和计算开销（FLOPs），对设备的算力、存储空间和功耗（SWaP）提出了极高要求。传统的双目立体匹配算法往往需要构建高维代价体（Cost Volume），消耗大量显存与带宽，导致在资源受限的边缘设备上难以满足实时性要求，甚至无法运行。此外，移动端硬件（如 NPU/DSP）通常对特定算子支持有限，直接部署复杂大模型面临着推理延迟高、能效比低等严峻挑战。

因此，如何在保证双目 3D 姿态估计精度的前提下，设计轻量化、高效率的网络架构，并结合模型压缩技术实现边缘端的高效部署，是

当前学术界与工业界亟待解决的关键问题。一方面，研究者开始探索通过改进网络结构（如引入深度可分离卷积、轻量化注意力机制）来降低计算冗余；另一方面，知识蒸馏（Knowledge Distillation）和模型量化（Quantization）等技术被广泛证明是在不显著牺牲精度的前提下压缩模型体积、加速推理的有效手段。开展面向资源受限设备的轻量化双目 3D 人体姿态估计研究，不仅具有重要的学术理论意义，更能推动智能感知技术在移动终端的广泛落地与普惠应用。

图 14 幅，表 7 个，参考文献 10 篇

关键词：中南大学；学位论文；LaTeX 模板

分类号：TP391

LaTeX Template of Postgraduate Thesis of Central South University

Abstract: LaTeX can be compiled into a pdf of uniform format using the set template. At present, most domestic publishers and universities still use word. Because of its powerful function and flexibility, when faced with fixed-form papers by novices, simple matters such as typesetting, numbering, and reference documents will bring many difficulties and troubles. For some problems that need to be modified throughout, to achieve the efficiency of LaTeX, it requires a high level of skill for word users.

In order to focus on the writing of papers, many international journals and universities support the writing and submission of LaTeX. Novices don't need to care about formatting issues. They only need to use a few symbolic labels step by step to get the documents that meet the requirements. And when you need to modify the entire format, you can directly recompile the template file by replacing or modifying the template file. This is incredible for the word novice to use the word.

The purpose of this project is to create a TeX template that meets the specifications of the graduate degree thesis (PhD) of Central South University, and to address the pain points of format adjustment during the dissertation writing.

Keywords: CSU; LaTeX; Template

Classification: TP391

目 录

摘要	I
ABSTRACT	III
目录	IV
插图索引	VII
表格索引	VIII
符号说明	IX
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 双目 3D 人体数据集	2
1.2.2 3D 多人人体姿态估计	3
1.2.3 双目深度估计研究现状	5
1.2.4 模型轻量化与压缩研究现状	6
1.3 研究内容	6
1.4 论文组织结构	7
第 2 章 相关技术与理论介绍	8
2.1 深度学习基础	8
2.1.1 卷积神经网络	8
2.1.2 Transformer 架构	9
2.2 人体姿态估计相关理论	11
2.2.1 人体姿态估计概述 (Overview)	11
2.2.2 关键点表示方法 (Keypoint Representations)	11
2.2.3 二维人体姿态估计范式 (2D HPE Paradigms)	12
2.2.4 三维人体姿态估计方法 (3D HPE Methods)	12
2.2.5 常用网络骨干与机制 (Backbones & Mechanisms)	12
2.2.6 数据集与评价指标 (Datasets & Metrics)	13

2.3	双目立体视觉原理	16
2.3.1	双目立体视觉成像模型	16
2.3.2	极线几何与立体校正	16
2.3.3	视差与深度恢复（三角测量）	17
2.3.4	误差来源与工程要点	17
2.4	轻量化网络设计	17
2.4.1	问题定义与设计原则	18
2.4.2	结构轻量化设计	18
2.4.3	模型压缩与端侧部署优化	19
第 3 章	基于双目相机的轻量化 3D 人体姿态检测网络设计	21
3.1	研究背景	21
3.2	问题分析	22
3.2.1	单目人体姿态估计的尺度模糊问题	22
3.2.2	多目人体姿态估计的问题	23
3.2.3	现有基于双目人体姿态估计的问题	24
3.3	轻量化非对称双目学习框架与网络结构设计	27
3.3.1	整体框架与端到端流程	27
3.3.2	非对称双目 Backbone 设计	27
3.3.3	极线特征增强模块（EFEM）	28
3.3.4	可微加权三角化姿态求解器	30
3.3.5	跨分支表征一致性约束与损失函数	35
3.4	实验评估	36
3.4.1	实验设置	36
3.4.2	实验结果	37
3.4.3	消融实验	39
3.5	本章小结	41
第 4 章	硬件感知部署与量化压缩	41
4.1	研究背景	41
第 5 章	总结与展望	42
5.1	总结	42
5.2	展望	42

第 6 章 图像布局	42
6.1 单图布局	42
6.2 横排布局	42
6.3 竖排布局	42
6.3.1 竖排多图横排布局	43
6.3.2 横排多图竖排布局	43
6.4 本章小结	43
第 7 章 表格插入示例	45
第 8 章 算法示例	46
第 9 章 公式、定理、证明插入示例	47
第 10 章 参考文献插入示例	49
第 11 章 总结与展望	50
11.1 工作展望	50
参考文献	51
附录 A (附录名称) (三号黑体, 加粗) (必要时)	52
攻读学位期间主要的研究成果	53
致 谢	54

插图索引

图 1-1 RT-Pose 数据集样例帧	2
图 1-2 双目激光雷达收集数据的设备示例	3
图 2-1 典型的人体关节点骨架示意图	14
图 3-1 单目三维人体姿态估计的尺度模糊示意图	23
图 3-2 基于稠密深度先验的双目两阶段三维人体姿态估计流程示意图	25
图 3-3 左右视图热力图对比：响应分布高度重叠，提示双全量骨干的计算 冗余	26
图 3-4 极线交叉注意力计算示意图：右视图特征作为 Query，左视图特征 作为 Key/Value，沿水平极线在视差窗口内计算权重并对 Value 加权聚 合。	28
图 3-5 极线注意力与加权聚合过程示意图	29
图 3-6 端侧推理时延随人数变化的对比（数据来自 StereoMulti3DPose 的 Xiaomi 14/MNN/FP16/4-thread 测量）。	39
图 6-1 单图布局示例	42
图 6-2 横排布局示例	43
图 6-3 竖排布局示例	43
图 6-4 竖排多图横排布局	43
图 6-5 横排多图竖排布局，斜体 <i>emph A</i> ， <i>A</i> ，斜体 <i>text A</i>	44

表格索引

表 2-1	COCO, MPII 与 Human3.6M (常用 17 点) 关节索引对照表	15
表 3-1	RT-Pose 数据集上的实验对比结果 (数据来自 StereoMulti3DPose 的公开 benchmark)。单目方法仅使用左视图 I_l ；两阶段双目方法遵循基于稠密深度先验的级联范式 (先估计稠密深度/视差, 再结合二维关键点回代/融合得到三维姿态)；本文方法在双目输入下端到端预测三维关节。所有 MPJPE 为左相机坐标系下的绝对 MPJPE (mm)。	38
表 3-2	不同人数下的端到端推理时延对比 (ms)。	39
表 3-3	不同跨视图特征交互方式的对比 (消融数值复用 StereoMulti3DPose 的公开消融设置)。	40
表 3-4	不同三维恢复策略对比 (双目, 消融数值复用 StereoMulti3DPose 的公开消融设置)。	40
表 3-5	跨分支一致性约束形式对比 (消融数值复用 StereoMulti3DPose 的公开消融设置)。	41
表 7-1	表格为三线表斜体 <i>emph A</i> , <i>A</i> , 斜体 <i>text A</i>	45

符号说明

符号	意义	单位（量纲）
频率	赫 [兹]	Hz

第 1 章 绪论

1.1 研究背景与意义

随着人工智能与计算机视觉技术的飞速发展，人体姿态估计（Human Pose Estimation, HPE）作为连接数字世界与物理世界的关键纽带，已在众多领域展现出巨大的应用价值。该技术旨在从图像或视频中定位人体关键点（如肩、肘、腕、膝等）并构建骨架结构，广泛应用于人机交互、虚拟现实/增强现实（VR/AR）、智慧医疗康复、体育动作分析以及智能安防监控等场景。特别是在医疗康复领域，通过精确捕捉患者的运动轨迹，系统能够量化评估肢体功能，辅助医生制定个性化的治疗方案。

尽管基于深度学习的二维（2D）人体姿态估计技术已趋于成熟，但其仅提供平面位置信息，缺乏深度维度，难以全面反映人体在三维空间中的真实姿态与运动细节，限制了其在复杂交互场景下的应用潜力。相比之下，三维（3D）人体姿态估计能够恢复人体关节的空间坐标，提供更丰富的运动学信息。然而，直接从单目图像恢复 3D 姿态本质上是一个不适定问题（Ill-posed Problem），面临着严重的深度歧义性，即多种三维姿态可能投影为相同的二维图像，导致在遮挡或复杂背景下估计精度大幅下降。为了解决这一难题，双目立体视觉（Binocular Stereo Vision）技术通过模拟人类双眼感知机制，利用左右视图的视差原理和三角测量几何约束，能够提供明确的深度线索，从而有效消除深度模糊，显著提升三维重建的精度与鲁棒性。

然而，随着物联网（IoT）与边缘计算的兴起，将高精度的 3D 姿态估计模型部署至移动端或嵌入式设备（如智能手机、无人机、XR 眼镜）已成为行业迫切需求。现有的高性能 3D 姿态估计模型（如基于 Transformer 或复杂 3D 卷积的网络）通常伴随着巨大的参数量和计算开销（FLOPs），对设备的算力、存储空间和功耗（SWaP）提出了极高要求。传统的双目立体匹配算法往往需要构建高维代价体（Cost Volume），消耗大量显存与带宽，导致在资源受限的边缘设备上难以满足实时性要求，甚至无法运行。此外，移动端硬件（如 NPU/DSP）通常对特定算子支持有限，直接部署复杂大模型面临着推理延迟高、能效比低等严峻挑战。

因此，如何在保证双目 3D 姿态估计精度的前提下，设计轻量化、高效率的网络架构，并结合模型压缩技术实现边缘端的高效部署，是当前学术界与工业界亟待解决的关键问题。一方面，研究者开始探索通过改进网络结构（如引入深度可分离卷积、轻量化注意力机制）来降低计算冗余；另一方面，知识蒸馏（Knowledge Distillation）和模型量化（Quantization）等技术被广泛证明是在不显

著牺牲精度的前提下压缩模型体积、加速推理的有效手段。开展面向资源受限设备的轻量化双目 3D 人体姿态估计研究，不仅具有重要的学术理论意义，更能推动智能感知技术在移动终端的广泛落地与普惠应用。

1.2 国内外研究现状

本章节将综述双目 3D 人体姿态估计领域的国内外研究现状，重点分析现有方法的技术路线、优势与不足，并探讨模型轻量化与压缩技术在该领域的应用进展。

1.2.1 双目 3D 人体数据集

RT-Pose^[1] (Radar Tensor-based 3D Human Pose Estimation Benchmark) 是由 Ho 等人在 ECCV 2024 上发布的一个新兴多模态 3D 人体姿态估计与定位基准数据集。与传统仅依赖视觉图像的数据集不同，RT-Pose 旨在解决隐私保护和遮挡场景（如穿墙识别）下的姿态估计难题，因此引入了毫米波雷达作为核心模态。



图 1-1 RT-Pose 数据集样例帧

该数据集具有以下显著特征：

1. 多模态数据同步：RT-Pose 包含同步采集的 4D 雷达张量 (Radar Tensors)、激光雷达点云 (LiDAR Point Clouds) 以及 RGB 图像。其中，4D 雷达张量提供原始的时空信息，高精度 3D 骨架标签则通过联合标定 RGB 图像与 LiDAR 点云生成，确保标注准确性。

2. 数据规模与多样性：数据集共包含 7.2 万帧数据，跨越 240 个序列，涵盖 6 种不同复杂度的动作类型。相比实验室环境下的数据集（如 Human3.6M），RT-Pose 采集于更复杂的现实世界场景，包含光照变化与背景干扰。
3. 基线算法：该工作同时提出 HRRadarPose 算法，这是首个在 3D 空间中提取 4D 雷达张量高分辨率表示的单阶段架构，在基准测试中取得了 9.91 cm（约 99.1 mm）的 MPJPE。

1.2.1.1 在本研究中的应用

尽管 RT-Pose 的初衷是推动雷达辅助的姿态估计，但本研究主要关注资源受限边缘设备上的纯视觉解决方案。考虑到移动端与物联网设备通常不具备昂贵的 LiDAR 或高带宽雷达传感器，而双目摄像头较为普及，本文将 RT-Pose 作为一个高难度真实场景测试基准。具体而言，本文仅使用 RT-Pose 中的双目 RGB 图像作为输入进行训练与评估。由于该数据集的场景复杂度远高于传统室内数据集，且包含大量非受控环境下的动作，利用其进行测试能够有效验证本文提出的 StereoMulti3DPose 框架在去除雷达辅助情况下，仅凭轻量化双目视觉算法在复杂现实场景（in-the-wild）中的鲁棒性与泛化能力。




图 1-2 双目激光雷达收集数据的设备示例

1.2.2 3D 多人人体姿态估计

1.2.2.1 单目 3D 人体姿态估计

近年来，单目 3D 人体姿态估计领域取得了显著进展，从估计深度方向可以分为直接回归法和 2D 提升法。从估计关键点角度来看，又可以分为自顶向下（Top-Down）和自底向上（Bottom-Up）两大类方法。

(1) 基于自顶向下的直接回归方法

最早，Kanazawa 等人提出了开创性的 HMR (CVPR 2018)，主张利用对抗训练（GAN）将图像特征直接映射为 SMPL 参数，确立了“检测-裁剪-回归”的经

典范式；随后，Kolotouros 等人在 SPIN (ICCV 2019) 中提出了将迭代优化算法嵌入神经网络训练循环的思想，利用 2D 关键点的几何约束大幅提升了模型贴合度。然而，针对上述方法中“裁剪操作导致透视丢失”的固有缺陷，Li 等人提出了 CLIFF (ECCV 2022)，主张将检测框的全局位置信息重新注入网络以感知相机视锥。到了 2025 年，Jin 等人进一步提出了 PersPose (ICCV 2025)，通过构建显式的透视编码 (Perspective Encoding) 和旋转变换矩阵，强制网络模拟相机内参对人体形态的影响，从而在不依赖相机参数真值的情况下，彻底解决了广角镜头边缘的人体畸变问题。

(2) 基于自顶向下的 2D 提升方法

在利用 2D 关键点恢复 3D 的路径上，Pavlo 等人首先提出了 VideoPose3D (CVPR 2019)，证明了利用时序卷积网络 (TCN) 聚合视频前后帧信息，足以解决单帧预测的深度歧义与抖动；紧接着，Zheng 等人提出了 PoseFormer (ICCV 2021)，将 Transformer 的注意力机制引入该领域，极大地增强了模型对长序列动作的捕捉能力。为了解决 Transformer 计算复杂度过高的问题，Zhu 等人在 PoseMamba (ArXiv 2024 / CVPR 2025 pending) 中提出了利用状态空间模型 (SSM) 替代注意力机制，通过 Mamba 架构特有的线性复杂度特性，实现了在极低显存占用下对数千帧超长序列的实时推理，成为当前长序列建模的新基准。

(3) 基于自底向上的直接回归方法

为了解决多人拥挤场景下的检测难题，Sun 等人提出了 ROMP (ICCV 2021)，主张抛弃检测框，利用像素级的中心热力图 (Center Map) 直接回归多人的 Mesh 参数，实现了推理速度与人数无关的特性。针对拥挤人群中特征混淆的顽疾，Li 等人在 NIKI (CVPR 2024) 中提出了基于可逆神经网络 (Invertible Neural Networks) 的生成式框架，他们认为传统的回归方法只能输出单一均值，无法处理严重遮挡下的多模态解，因此通过双射变换将图像特征映射到潜在分布，成功实现了在极度拥挤场景下对交织肢体的精准解耦与重建。

(4) 基于自底向上的 2D 提升方法

早期，Bertoni 等人提出了 MonoLoco (ICCV 2019)，利用 2D 关键点的高度与肩宽比率来推算 3D 绝对距离，主要服务于自动驾驶中的行人定位。近年来，为了应对多视角监控中数据不同步和噪声大的挑战，研究团队提出了 SyncDiffPose (AAAI 2025)，通过引入扩散模型 (Diffusion Model) 的去噪机制，将时间未对齐导致的 2D 误差视为噪声，利用扩散逆过程从嘈杂的观测中“生成”出符合物理规律的同步 3D 姿态序列，为低成本监控环境下的高精度捕捉提供了全新的解决

方案。

1.2.3 双目深度估计研究现状

1.2.3.1 基于手工特征的方法

传统双目立体匹配算法通常基于多视图几何原理，依赖人工设计的特征描述符与代价函数来计算视差，主要分为局部匹配（Local Methods）、全局匹配（Global Methods）以及半全局匹配（Semi-Global Matching, SGM）三大类。局部方法如块匹配算法（Block Matching, BM），通过在左右视图的局部窗口内计算灰度差绝对值和（SAD）或归一化互相关（NCC）来寻找对应点，其计算效率高但难以处理弱纹理、重复纹理及深度不连续区域，匹配精度有限。全局方法如图割（Graph Cuts）和置信度传播（Belief Propagation），通过构建包含数据项和平滑项的全局能量函数并进行最小化求解，虽然精度较高，但计算复杂度巨大，难以满足实时性需求。作为两者的折中方案，由 Hirschmüller 提出的 SGM 算法是该领域的里程碑，它通过沿多个方向（通常为 8 或 16 个方向）进行一维路径代价聚合来近似二维全局能量最小化，在保证效率的同时显著提升了对遮挡和物体边缘的处理能力，被广泛应用于工业界。此外，针对前向平行窗口假设的局限性，PatchMatch Stereo 算法引入了倾斜支持窗口（Slanted Support Windows）和随机搜索策略，有效提升了倾斜表面的重建精度

1.2.3.2 基于深度学习的方法

随着卷积神经网络（CNN）的兴起，双目深度估计进入了端到端学习时代，主要经历了从基于匹配代价计算的 CNN 到基于 3D 卷积的代价体回归，再到基于迭代优化和 Transformer 架构的演进。早期的 MC-CNN 利用 CNN 替代手工特征计算匹配代价，显著提升了相似度度量的准确性。随后，GC-Net 和 PSMNet 开创了使用 4D 代价体配合 3D 卷积神经网络进行正则化的范式，其中 PSMNet 引入的空间金字塔池化（SPP）和堆叠沙漏结构能有效捕获全局上下文信息，成为该领域的重要基准，但其高昂的显存和计算开销限制了在边缘设备的部署。为了降低计算成本，GwcNet 提出了分组相关（Group-wise Correlation）策略来构建高效的代价体。近年来，受到光流算法 RAFT 的启发，RAFT-Stereo 和 IGEV-Stereo 等方法采用了基于 GRU 的迭代优化策略，通过循环神经网络逐步细化视差场，展现了优异的跨域泛化能力。此外，Transformer 架构也被引入该领域（如 STTR），利用自注意力机制处理长距离依赖和遮挡问题，将立体匹配建模为序列到序列的对应任务。针对移动端应用，MobileStereoNet、CoEx 和 LightStereo 等轻量化网络则通过使用 2D 卷积替代 3D 卷积或设计高效的代价聚合模块，在保持精度的

同时实现了实时推理。

1.2.4 模型轻量化与压缩研究现状

1.2.4.1 轻量化结构设计

面向端侧部署的轻量化研究通常首先从网络结构入手,通过减少冗余计算与降低高维特征张量的规模来获得更低的时延与更小的内存占用。典型做法包括使用深度可分离卷积、倒残差与线性瓶颈等高效模块替代标准卷积;在多尺度特征融合中控制高分辨率分支的通道宽度与融合路径数量;在注意力与 Transformer 结构中采用局部窗口、分层结构或低秩/稀疏近似来降低全局自注意力的二次复杂度。对于双目任务而言,结构轻量化的关键还在于避免构建高分辨率、全视差范围的代价体,并通过相关/分组相关与迭代细化等方式将跨视图匹配计算转化为更紧凑、更算子友好的形式。

1.2.4.2 模型压缩与加速

除结构设计外,模型压缩技术为端侧落地提供了另一条重要路径。剪枝通过移除冗余通道、卷积核或注意力头来降低计算量,其中结构化剪枝更有利于获得真实加速;量化将权重与激活映射到低比特表示(如 INT8),可显著降低内存带宽需求并提升硬件利用率;知识蒸馏通过引入教师网络的软标签或中间特征约束,在不显著增加推理开销的前提下提升轻量模型精度。实际部署中,这些方法常与硬件友好算子选择、算子融合与编译优化联合使用,以获得更稳定的端侧加速收益。

1.3 研究内容

围绕资源受限设备上的双目 3D 人体姿态估计问题,本文主要研究内容包括:

- 构建轻量化双目 3D 人体姿态估计框架 StereoMulti3DPose,研究左右视图特征提取、跨视图信息交互与三维关节点回归的整体流程。
- 设计面向端侧部署的高效网络结构,在保证姿态估计精度的前提下,降低参数量、计算量与峰值内存占用,提高实时性与能效比。
- 探索知识蒸馏、量化等模型压缩策略及其与网络结构轻量化的协同方式,分析不同压缩方案对精度与效率的影响。
- 基于复杂真实场景数据集(如 RT-Pose)开展实验评估,验证所提方法在弱纹理与光照变化等条件下的鲁棒性与泛化能力。

1.4 论文组织结构

全文结构安排如下：第一章介绍研究背景与意义，综述国内外研究现状，并给出本文研究内容与整体思路；第二章介绍与本文相关的理论基础与关键技术，包括深度学习基础、人体姿态估计、双目立体视觉以及轻量化网络设计等。其余章节将进一步给出本文方法的整体框架与关键模块实现，展示实验设置与结果分析，并在最后对全文工作进行总结与展望。

第2章 相关技术与理论介绍

2.1 深度学习基础

2.1.1 卷积神经网络

卷积神经网络 (Convolutional Neural Network, CNN) 是一类特殊设计的深度学习模型, 它在计算机视觉领域取得了革命性的成功, 尤其擅长处理具有网格状拓扑结构的数据, 如图像 (2D 网格) 和视频 (3D 网格)。CNN 的核心思想在于通过模仿生物视觉系统的机制, 有效利用图像的空间局部相关性, 并通过一系列专门的层级结构来学习和提取从低级到高级的层次化特征。

典型的 CNN 架构主要由以下几种关键层堆叠而成:

2.1.1.1 卷积层 (Convolutional Layer)

卷积层是 CNN 的核心。它使用一组可学习的滤波器 (或称为卷积核, Kernel) 在输入数据 (如图像) 上进行滑动窗口式的卷积操作。每个卷积核负责检测一种特定的局部特征, 例如边缘、角点、纹理或颜色块。通过卷积操作, 可以生成一个二维的特征图 (Feature Map), 图中的每个像素代表了其在原始图像对应感受野 (Receptive Field) 上对该特定特征的响应强度。卷积层有两个非常重要的特性:

- **局部连接 (Local Connectivity):** 每个神经元只与输入数据的一个局部区域相连, 这大大减少了模型的参数数量, 并使网络能专注于学习局部信息。
- **权值共享 (Weight Sharing):** 单个卷积核 (滤波器) 在整个输入图像上共享同一组权重参数。这意味着, 网络在图像的一个区域学习到的特征 (例如, 一个垂直边缘), 可以同样被用来检测图像其他区域的相同特征。这赋予了模型平移不变性 (Translation Invariance), 进一步降低了模型复杂度。

2.1.1.2 激活函数 (Activation Function)

在卷积操作之后, 通常会应用一个非线性激活函数, 如 ReLU (Rectified Linear Unit, $f(x) = \max(0, x)$)。激活函数的引入打破了模型的线性, 使得网络能够学习和表示更加复杂的非线性关系, 这是深度学习模型强大表达能力的关键。

2.1.1.3 池化层 (Pooling Layer)

池化层 (也称下采样层) 通常紧跟在卷积层之后, 其主要作用是对特征图进行降维, 以减少计算量、降低过拟合风险, 并增强模型的泛化能力。最常见的池化操作是最大池化 (Max Pooling), 它将特征图划分为若干个不重叠的矩形区域,

并从每个区域中输出最大值。池化操作在保留最显著特征的同时，也为模型带来了一定程度的旋转和尺度不变性。

2.1.1.4 全连接层 (Fully Connected Layer)

在经过多层卷积和池化的堆叠，提取出丰富的层次化特征之后，这些特征图通常会被展平 (Flatten) 成一个一维向量，并输入到一个或多个全连接层中。全连接层的每个神经元都与前一层的所有神经元相连，其作用类似于传统的多层感知机，负责将学习到的分布式特征表示进行整合，并最终映射到任务的输出空间，例如，在分类任务中输出每个类别的概率，或在回归任务（如人体姿态估计）中输出关节点的坐标。

通过这种“卷积-激活-池化”模块的堆叠，CNN 能够自动地、层次化地从原始像素中学习从简单到复杂的视觉模式，使其在图像分类、目标检测、语义分割以及本文所关注的人体姿态估计等任务中表现出色。

2.1.2 Transformer 架构

Transformer 架构最初由 Vaswani 等人在其著名的论文“Attention Is All You Need” [2] 中提出，旨在解决自然语言处理 (NLP) 中的序列到序列 (Seq2Seq) 任务。它摒弃了传统的循环神经网络 (RNN) 和卷积神经网络 (CNN) 的序列处理方式，完全依赖于注意力机制来捕捉输入和输出序列之间的全局依赖关系。由于其强大的长距离依赖建模能力和并行计算潜力，Transformer 及其变体（如 Vision Transformer, ViT[3]）已被成功应用于计算机视觉领域，并在包括人体姿态估计在内的多项任务中取得了 SOTA (State-of-the-art) 性能。

Transformer 的核心是注意力机制，特别是缩放点积注意力 (Scaled Dot-Product Attention)，其计算可概括为以下公式：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中， Q (Query)、 K (Key) 和 V (Value) 是由输入序列经过线性变换得到的三个向量。注意力机制通过计算 Query 和所有 Key 的相似度（点积），并对结果进行缩放和 softmax 归一化，得到一组权重系数。这些权重随后被用于对 Value 向量进行加权求和，从而得到最终的输出。这个过程可以直观地理解为：根据“查询”向量 Q ，从一系列“键-值”对 ($K - V$) 中检索信息。

2.1.2.1 自注意力 (Self-Attention)

自注意力是 Transformer 中的一个关键特例，其中 Q, K, V 均来自同一个输入序列。这意味着序列中的每个元素都会计算与序列中所有其他元素（包括自

身)的注意力权重,从而能够动态地、内容感知地捕捉序列内部的依赖关系,无论它们相隔多远。这与CNN的局部感受野形成了鲜明对比。

2.1.2.2 多头注意力 (Multi-Head Attention)

为了让模型能够共同关注来自不同表示子空间的信息,Transformer引入了多头注意力机制。它将原始的 Q, K, V 向量在特征维度上线性投影并划分为多个“头”(heads),对每个头分别执行缩放点积注意力操作,然后将所有头的输出拼接并再次进行线性变换。这种方式允许多个注意力模块并行地捕捉不同方面的依赖关系,极大地增强了模型的表达能力。

2.1.2.3 交叉注意力 (Cross-Attention)

交叉注意力是连接编码器(Encoder)和解码器(Decoder)的关键桥梁,在标准的Transformer架构中至关重要。与自注意力不同,交叉注意力的 Q 向量来自解码器(Decoder)的输出,而 K 和 V 向量则来自编码器(Encoder)的最终输出。具体来说,在解码器的每个步骤中,交叉注意力模块允许解码器“关注”输入序列(即编码器的输出)中与当前生成任务最相关的部分。例如,在机器翻译中,当解码器要生成下一个目标词时,交叉注意力会帮助它定位到源句子中最相关的几个词。在多模态任务(如图像描述生成)或本文涉及的双目视觉任务中,交叉注意力机制同样强大。它可以让一个模态的特征(例如,左视图的特征作为Query)去查询和融合另一个模态的特征(例如,右视图的特征作为Key和Value),从而实现跨模态、跨视图的信息对齐与有效融合。

2.1.2.4 位置编码 (Positional Encoding)

由于注意力机制本身不包含序列中元素的位置信息,为了让模型能够利用序列的顺序,Transformer在输入嵌入中加入了位置编码。这些编码是预先定义或可学习的向量,它们为每个位置提供了唯一的标识,使得模型能够区分序列中不同位置的元素。

一个完整的Transformer层通常由一个多头注意力模块和一个前馈神经网络(Feed-Forward Network)组成,每个模块之后都跟随着残差连接(Residual Connection)和层归一化(Layer Normalization)。通过堆叠多个这样的层,Transformer能够构建起强大的深度模型。

2.2 人体姿态估计相关理论

2.2.1 人体姿态估计概述 (Overview)

人体姿态估计 (Human Pose Estimation, HPE) 旨在从图像或视频中定位人体关键点 (如肩、肘、腕、髋、膝等), 并根据预定义的拓扑连接关系构建人体骨架 (Pose Skeleton), 从而为动作理解、人机交互、康复评估等下游任务提供结构化的运动学表示。

从任务设定上, HPE 通常可从以下两个维度进行划分:

- **按输出维度:** 分为 **2D 姿态估计** (预测关键点平面坐标 (x, y)) 与 **3D 姿态估计** (预测空间坐标 (x, y, z) 或根相对坐标)。
- **按目标数量:** 分为 **单人姿态估计** (Single-person) 与 **多人姿态估计** (Multi-person)。

实际应用中, 遮挡、光照变化、视角差异以及复杂背景都会显著影响关键点定位的鲁棒性; 而在 3D 姿态估计中, 还存在典型的**深度歧义性 (Depth Ambiguity)** 问题, 即不同的三维姿态可能投影为相似的二维观测, 使得仅凭单目图像恢复绝对深度具有不稳定性。

2.2.2 关键点表示方法 (Keypoint Representations)

关键点的输出表征直接影响网络结构设计、训练目标与推理开销, 常见形式包括:

- **基于坐标回归 (Regression-based):** 直接从图像特征回归关键点坐标 (或其偏移量)。该方法计算简单、推理速度快、后处理开销小, 适合端侧部署; 但由于需要从高维特征到精确坐标的强非线性映射, 通常对训练策略与特征表达要求更高, 定位精度在复杂场景下可能受限。
- **基于热图 (Heatmap-based):** 为每个关键点预测一个二维概率热图 (通常为高斯分布), 通过峰值位置获得坐标。该方法保留了空间结构信息, 定位精度较高, 是 2D 姿态估计的主流范式; 但为获得高精度通常需要较高分辨率的特征图与上采样模块, 计算与内存开销较大, 同时存在由下采样引入的量化误差。
- **坐标分类 (如 SimDR):** 将关键点的 x 与 y 坐标分别建模为一维分类 (或离散分布回归) 问题, 在一定程度上兼顾热图法的精度与回归法的效率, 近年来在轻量化场景中受到关注。

2.2.3 二维人体姿态估计范式 (2D HPE Paradigms)

二维多人姿态估计主要分为自顶向下 (Top-Down) 与自底向上 (Bottom-Up) 两类路线:

- **自顶向下 (Top-Down):** 先使用目标检测器 (如 YOLO 系列) 检测出每个人体边界框, 再对每个框内执行单人关键点检测 (如 AlphaPose、CPN、HRNet 等)。该范式通常精度较高、对尺度变化更鲁棒, 但整体计算量随图像中人数近似线性增长, 且性能受检测器误差传递影响。
- **自底向上 (Bottom-Up):** 先在整幅图像上检测所有关键点, 再通过关联与分组策略 (如 PAF) 将关键点组装成不同的人体实例 (如 OpenPose、HigherHRNet 等)。该范式推理开销相对稳定, 不随人数显著增长; 但在严重遮挡、多人拥挤及尺度差异较大时, 关键点分组更容易出现歧义。

2.2.4 三维人体姿态估计方法 (3D HPE Methods)

三维人体姿态估计常见方法可归纳为:

- **端到端直接估计 (Direct Estimation):** 直接从图像特征回归 3D 关节点坐标, 或进一步回归人体参数化模型 (如 SMPL) 以获得网格与姿态参数。该类方法流程简洁, 但往往依赖大量 3D 标注数据, 跨场景泛化能力易受限制。
- **两阶段法 / 2D 到 3D 提升 (2D-to-3D Lifting):** 第一阶段利用成熟的 2D 检测器获取 2D 关键点, 第二阶段通过提升网络将 2D 坐标映射到 3D 空间 (可结合时序信息以抑制抖动)。该路线充分利用海量 2D 数据, 且第二阶段输入维度低、计算效率高, 因此在轻量化与实时应用中非常常见。
- **多目/双目视觉辅助 (Stereo/Multi-view):** 引入多视角几何约束 (如极线约束与三角测量), 可显著缓解单目深度歧义, 提高 3D 重建精度与鲁棒性; 但对相机标定与同步提出更高要求。

2.2.5 常用网络骨干与机制 (Backbones & Mechanisms)

在姿态估计任务中, 骨干网络通常承担特征提取与多尺度信息融合的职责, 常见结构包括:

- **ResNet:** 通过残差连接缓解深层网络训练困难, 常作为通用特征提取骨干。
- **Hourglass:** 采用对称的下采样-上采样结构进行多尺度融合, 适合关键点热图回归。
- **HRNet:** 在整个网络中保持高分辨率分支并进行跨尺度信息交换, 能更好保留细粒度空间信息, 常用于高精度 2D 姿态估计。

此外，Transformer 通过自注意力机制建模全局依赖，可显式刻画关节间的长距离关系；通道注意力与空间注意力机制则可在复杂背景中抑制噪声、聚焦人体区域。在双目任务中，跨视图注意力（Cross-Attention）还可用于左右视图特征对齐与融合，为后续 3D 回归提供更一致的表征。

2.2.6 数据集与评价指标 (Datasets & Metrics)

2.2.6.1 常用数据集

2D 姿态估计领域常用的公开数据集包括 COCO（17 个关键点）与 MPII（16 个关键点）等；3D 姿态估计领域经典数据集包括 Human3.6M（室内动作捕捉标注）与 MPI-INF-3DHP 等。针对复杂真实场景，近年来也出现了包含更丰富环境变化的基准数据集，用于检验模型的跨域泛化能力。

2.2.6.2 人体关节点定义与标准

人体姿态估计的核心任务是定位一系列预先定义的人体关节点 (Human Keypoints)，这些关节点是人体骨骼上的特定解剖学标志点，如头、颈、肩、肘、腕、髋、膝、踝等。通过连接这些关节点，可以构建出能够描述人体姿态和动作的骨架结构 (Pose Skeleton)。因此，一套清晰、一致的关节点定义是进行模型训练、性能评估与跨数据集比较的基础，对于人体姿态估计任务至关重要。

然而，在学术界和工业界并未形成完全统一的关节点标注标准。不同的研究任务和应用场景催生了多样的关节点定义方案，它们在关节点的数量、具体位置和拓扑连接上存在差异。例如，常用于 2D 姿态估计的 COCO (Common Objects in Context) 数据集定义了 17 个关节点，侧重于日常场景中可见的主要身体部位；而 MPII Human Pose 数据集则标注了 16 个关节点，并为每个关节点提供了更丰富的属性信息。在 3D 姿态估计领域，源自实验室动作捕捉的 Human3.6M 数据集虽然原始定义多达 32 个点，但在实际研究中，研究者们约定俗成地使用其中 17 个核心关节点进行算法评估。

此外，在 3D 姿态表示中，通常会指定一个根节点 (Root Joint)，如将骨盆 (Pelvis) 作为坐标系原点。所有其他关节点的位置都以相对于该根节点的坐标进行表示，这种根相对 (root-relative) 的表示法可以有效消除人体全局位置变化带来的影响，使模型能更专注于学习人体的姿态本身。图 2-1 直观地展示了典型的人体骨架关节点布局。

为了更清晰地展示不同标准间的差异，表 2-1 对比了 COCO 与 MPII 这两个经典数据集中人体关节点的定义。




图 2-1 典型的人体关节骨架示意图

2.2.6.3 评价指标

人体姿态估计任务通常通过一系列量化指标进行评估。对于 2D 姿态估计，常用指标包括：

- **PCK (Percentage of Correct Keypoints)**: 统计预测关键点落在阈值范围内的比例，阈值通常根据人体尺度（如头部尺寸或躯干长度）进行归一化。
- **OKS (Object Keypoint Similarity)**: 综合考虑关键点的像素误差、关键点可见性以及不同关键点的标注不确定性，用于更细致地衡量关键点相似度。
- **mAP**: 基于 OKS 阈值统计平均精度，是 COCO 评测中最常用的 2D 姿态指标。

对于 3D 人体姿态估计，最核心和最广泛使用的指标之一是平均每关节位置误差 (**Mean Per Joint Position Error, MPJPE**)。

(1) MPJPE (Mean Per Joint Position Error)

MPJPE，有时也称为重构误差 (**Reconstruction Error**)，是衡量 3D 人体姿态估计精度的金标准。它计算的是模型预测的 3D 关节点坐标与真实 3D 关节点坐标 (**Ground Truth**) 之间的平均欧氏距离 (**Euclidean Distance**)。如公式 2-2 所示，对于一个包含 N 个关节点的姿态，其 MPJPE 的计算方式如下：

$$\text{MPJPE} = \frac{1}{N} \sum_{i=1}^N \|J_{\text{pred},i} - J_{\text{gt},i}\|_2 \quad (2-2)$$

表 2-1 COCO, MPII 与 Human3.6M (常用 17 点) 关节索引对照表

Idx	COCO (17)	Idx	MPII (16)	Idx	Human3.6M (17)
0	Nose (鼻子)	0	R-Ankle (右踝)	0	Pelvis (骨盆/中心)
1	L-Eye (左眼)	1	R-Knee (右膝)	1	R-Hip (右臀)
2	R-Eye (右眼)	2	R-Hip (右臀)	2	R-Knee (右膝)
3	L-Ear (左耳)	3	L-Hip (左臀)	3	R-Ankle (右踝)
4	R-Ear (右耳)	4	L-Knee (左膝)	4	L-Hip (左臀)
5	L-Shoulder (左肩)	5	L-Ankle (左踝)	5	L-Knee (左膝)
6	R-Shoulder (右肩)	6	Pelvis (骨盆)	6	L-Ankle (左踝)
7	L-Elbow (左肘)	7	Thorax (胸部)	7	Torso (躯干)
8	R-Elbow (右肘)	8	Upper Neck (颈)	8	Neck (颈部)
9	L-Wrist (左腕)	9	Head Top (头顶)	9	Nose (鼻子/头)
10	R-Wrist (右腕)	10	L-Wrist (左腕)	10	Head (头顶)
11	L-Hip (左臀)	11	L-Elbow (左肘)	11	L-Shoulder (左肩)
12	R-Hip (右臀)	12	L-Shoulder (左肩)	12	L-Elbow (左肘)
13	L-Knee (左膝)	13	R-Shoulder (右肩)	13	L-Wrist (左腕)
14	R-Knee (右膝)	14	R-Elbow (右肘)	14	R-Shoulder (右肩)
15	L-Ankle (左踝)	15	R-Wrist (右腕)	15	R-Elbow (右肘)
16	R-Ankle (右踝)	—	—	16	R-Wrist (右腕)

其中, $J_{pred,i}$ 和 $J_{gt,i}$ 分别代表第 i 个预测关节点和真实关节点的 3D 坐标。这个值通常以毫米 (mm) 为单位, 其值越低, 代表模型的预测精度越高。本文实验默认报告**绝对 MPJPE**: 在左相机坐标系下直接计算预测三维关节与真值三维关节的欧氏距离 (mm); 根**相对 MPJPE** 可作为可选补充指标。

(2) PA-MPJPE (Procrustes Aligned MPJPE)

然而, 在某些场景下, 我们更关心模型预测的姿态形状 (Shape) 的准确性, 而非其在空间中的全局位置、旋转和缩放。例如, 一个预测的姿态可能在形状上与真实姿态完全一致, 但由于整体平移或旋转, 其 MPJPE 值仍然会很高。为了消除这种全局变换带来的影响, 研究者们提出了 **Procrustes** 对齐后的 **MPJPE** (**PA-MPJPE**), 也称形状误差 (Shape Error)。

在计算 PA-MPJPE 之前, 需要通过刚性变换 (旋转、平移和缩放), 即 Procrustes 分析, 将预测的 3D 姿态与真实 3D 姿态进行对齐。PA-MPJPE 计算的是在最佳对齐之后, 预测关节点与真实关节点之间的平均欧氏距离。其计算公式如下:

$$\text{PA-MPJPE} = \min_{R,t,s} \frac{1}{N} \sum_{i=1}^N \| (sR \cdot J_{pred,i} + t) - J_{gt,i} \|_2 \quad (2-3)$$

其中，优化过程寻找一个最佳的旋转矩阵 R 、平移向量 t 和缩放因子 s ，以最小化对齐后的平均误差。PA-MPJPE 能够更纯粹地评估模型对人体结构和比例的学习能力，是衡量姿态“形状”准确性的关键指标。

除了上述两个核心指标，根据任务的特定需求，有时还会使用其他评价指标，例如：

- **根相对 MPJPE (Root-Relative MPJPE)**: 在计算 MPJPE 之前，先将预测姿态和真实姿态的根关节点（如骨盆）平移到坐标原点。这可以消除全局平移的影响，但保留了旋转和缩放的差异。
- **加速度误差 (Acceleration Error)**: 在视频序列的姿态估计中，该指标用于衡量预测姿态在时间上的平滑度和物理真实性，通过计算关节点加速度的误差来评估抖动情况。

2.3 双目立体视觉原理

2.3.1 双目立体视觉成像模型

双目立体视觉通过两台相机从不同视角同时观测同一场景，利用左右视图之间的几何约束恢复场景的深度信息。设空间点在世界坐标系中的齐次坐标为 $\mathbf{X} = [X, Y, Z, 1]^T$ ，其在左/右相机成像平面上的齐次像素坐标分别为 $\mathbf{x}_l = [u_l, v_l, 1]^T$ 与 $\mathbf{x}_r = [u_r, v_r, 1]^T$ ，则在针孔相机模型下有：

$$s_l \mathbf{x}_l = \mathbf{K}_l [\mathbf{R}_l \mathbf{t}_l] \mathbf{X}, \quad s_r \mathbf{x}_r = \mathbf{K}_r [\mathbf{R}_r \mathbf{t}_r] \mathbf{X} \quad (2-4)$$

其中， $\mathbf{K}$ 为相机内参矩阵（包含焦距与主点）， $[\mathbf{R} \mathbf{t}]$ 为外参（描述相机坐标系相对世界坐标系的旋转和平移）， s 为尺度因子。双目系统通常通过标定获得两台相机的内参及它们之间的相对位姿，其中两相机光心之间的距离称为基线（Baseline） B 。

2.3.2 极线几何与立体校正

对于同一空间点 $\mathbf{X}$ 在左右视图中的像素对应 $\mathbf{x}_l$ 与 $\mathbf{x}_r$ ，其匹配关系满足极线约束：

$$\mathbf{x}_r^T \mathbf{F} \mathbf{x}_l = 0 \quad (2-5)$$

其中 $\mathbf{F}$ 为基础矩阵（Fundamental Matrix），由双目系统的相对位姿与内参共同决定。工程实现中通常对左右图像进行立体校正（Stereo Rectification），将极线变换为水平扫描线，使得对应点搜索从二维空间降为一维：对应点近似位于同一行，即 $v_l \approx v_r$ 。此时，匹配的核心任务可转化为沿水平方向估计视差（Disparity）。

2.3.3 视差与深度恢复（三角测量）

在完成立体校正且双目相机近似共面、光轴平行的情况下，视差定义为左右像素横坐标之差：

$$d = u_l - u_r \quad (2-6)$$

由相似三角形关系可得空间点的深度（以左相机坐标系为例）：

$$Z = \frac{fB}{d} \quad (2-7)$$

其中 f 为等效焦距（通常使用 f_x ）， B 为基线长度。由式2-7可知：深度与视差成反比，近处物体具有更大的视差、更易估计；远处物体视差很小，对匹配误差更敏感。进一步地，若视差估计存在标准差 σ_d ，深度误差可近似写为：

$$\sigma_Z \approx \left| \frac{\partial Z}{\partial d} \right| \sigma_d = \frac{fB}{d^2} \sigma_d \quad (2-8)$$

该关系揭示了双目系统在远距离场景下深度不确定性快速增长的原因。

2.3.4 误差来源与工程要点

双目深度恢复的精度不仅取决于匹配算法本身，还受到多种因素影响：

- **标定与同步误差**：内外参不准确、镜头畸变未充分校正或左右相机不同步，会破坏极线约束并引入系统性偏差。
- **遮挡与弱纹理**：遮挡区域在另一视图中不存在真实对应点；弱纹理或重复纹理会导致匹配代价不可靠，从而产生错误视差。
- **基线与焦距选择**：增大 B 或 f 可提升远距离深度分辨率，但会增加系统体积、降低近距离可视重叠并加剧遮挡。
- **亚像素视差估计**：通过代价曲线拟合或网络回归获得亚像素视差，可显著降低 σ_d ，进而改善深度精度。

在本文的双目 3D 人体姿态估计任务中，上述几何关系为模型从左右视图中提取跨视图一致的深度线索提供了理论基础：一方面可通过学习式立体匹配得到稠密深度/视差作为额外输入，另一方面也可在特征层面利用极线一致性与对应关系约束，提高三维关节点回归的稳定性与泛化能力。

2.4 轻量化网络设计

面向移动端或嵌入式设备的视觉算法通常受到算力、内存带宽与功耗的严格约束。对于双目 3D 人体姿态估计而言，网络既要从双视图中提取足够判别性的特征以恢复深度线索，又要尽量避免传统立体匹配中高维代价体（Cost Volume）

带来的显存与计算开销。因此，本小节从通用的轻量化网络设计角度，总结在边缘端实现高效推理时常用的结构设计与工程策略。

2.4.1 问题定义与设计原则

轻量化并不等同于单纯减少参数量，而是一个多目标权衡问题。实际部署中常用的评价维度包括：

- **参数量与模型大小**：影响存储占用与加载时间，亦与过拟合风险相关。
- **计算量（FLOPs/MACs）与时延**：FLOPs 反映理论复杂度，但端侧时延更依赖算子实现、并行度与访存模式。
- **峰值显存/内存占用**：双目任务容易在特征拼接、代价体构建和多尺度融合处出现峰值内存。
- **精度-效率折中**：在人体姿态估计中表现为 MPJPE/PA-MPJPE 等指标与端侧实时性之间的取舍。

需要强调的是，端侧推理的瓶颈往往不仅来自算术计算，还来自内存带宽与访存模式；例如，频繁的特征拼接与大体积张量读写会显著抬高时延与能耗。针对双目任务中代价体易导致内存峰值过高的问题，轻量化网络设计通常遵循“减少高维张量、优先 2D 算子、控制通道数与分辨率、以迭代细化替代一次性重计算”的总体原则。

2.4.2 结构轻量化设计

从结构层面来看，面向端侧部署的轻量化通常需要在骨干特征提取、跨尺度与跨视图融合以及预测头设计三个方面协同优化。

首先，在骨干特征提取方面，深度可分离卷积（Depthwise Separable Convolution）是降低计算量的典型手段。对于输入特征尺寸为 $H \times W$ 、通道数为 C_{in} ，输出通道数为 C_{out} 、卷积核大小为 $k \times k$ 的标准卷积，其计算复杂度近似为：

$$\text{Cost}_{\text{conv}} \propto HW \cdot C_{in} C_{out} \cdot k^2 \quad (2-9)$$

深度可分离卷积将其分解为逐通道卷积（Depthwise）与 1×1 点卷积（Pointwise），复杂度近似为：

$$\text{Cost}_{\text{dw}} \propto HW \cdot C_{in} \cdot k^2, \quad \text{Cost}_{\text{pw}} \propto HW \cdot C_{in} C_{out} \quad (2-10)$$

当 $k > 1$ 且 C_{out} 较大时，式2-10相较式2-9可显著降低计算量。进一步地，倒残差结构（Inverted Residual）与线性瓶颈（Linear Bottleneck）通过“先扩展后压缩”的通道设计，在保证表达能力的同时减少高成本卷积层的使用；组卷积（Group

Convolution) 与通道洗牌 (Channel Shuffle) 则在降低计算量的同时增强通道间信息交互。这些模块为在端侧构建高效特征提取器提供了基础。

其次, 在跨尺度与跨视图融合方面, 人体姿态估计与双目匹配均依赖多尺度信息与跨视图一致性。轻量化设计中应重点控制**通道宽度与融合路径数量**, 避免引入过多上/下采样分支与冗余卷积; 同时, 双目结构天然存在“左右分支”带来的参数与算力倍增风险, 实践中常采用左右视图**共享骨干参数 (Siamese Backbone)**以降低参数量并增强特征一致性。

在跨视图信息融合方面, 端侧系统通常难以承受高分辨率、全视差范围的代价体构建与 3D 卷积正则化。更可行的思路是在较低分辨率特征上建立粗对应关系, 并通过逐级细化或迭代更新恢复细节; 在匹配表征上, 采用相关 (Correlation) 或分组相关 (Group-wise Correlation) 构建更紧凑的跨视图交互特征, 以降低通道维度与访存压力。结合立体校正先验时, 可将信息聚合限制在极线方向, 从而在保证有效搜索范围的同时控制计算开销, 并对遮挡与误匹配提供更稳定的约束。

最后, 在姿态估计头与输出表征方面, 端侧场景中预测头的设计会直接影响整体效率与后处理复杂度。基于热力图的方法通常定位精度较高, 但为获得精细定位往往需要上采样与峰值解析; 直接坐标回归计算图更简洁, 但对特征表达与训练稳定性要求更高; 根相对 3D 表示则可减弱全局平移变化带来的干扰, 更利于跨场景泛化。在轻量化框架中通常优先选择算子友好、计算路径短的输出形式, 并通过共享特征、减少分支与控制输出分辨率来进一步降低时延与内存占用。

2.4.3 模型压缩与端侧部署优化

除结构轻量化外, 模型压缩与部署优化同样关键。常用压缩手段包括剪枝、知识蒸馏与量化, 其中量化在端侧场景中尤为重要: 其不仅降低存储与带宽开销, 还能显著提升 NPU/DSP 等硬件的算子吞吐。

量化方面, 以 b 比特整数量化为例, 常用的仿射量化可写为:

$$q = \text{clip} \left(\left\lfloor \frac{x}{s} \right\rfloor + z, q_{\min}, q_{\max} \right), \quad \hat{x} = s(q - z) \quad (2-11)$$

其中, x 为浮点值, q 为量化后的整数, $\hat{x}$ 为反量化后的近似值; $s > 0$ 为缩放因子, z 为零点 (zero-point), $\lfloor \cdot \rfloor$ 表示四舍五入; $q_{\min}, q_{\max}$ 由位宽确定 (如 INT8 时通常为 $[-128, 127]$ 或 $[0, 255]$)。对于给定动态范围 $[x_{\min}, x_{\max}]$, 一种常见的参数选取方式为:

$$s = \frac{x_{\max} - x_{\min}}{q_{\max} - q_{\min}}, \quad z = \left\lfloor q_{\min} - \frac{x_{\min}}{s} \right\rfloor \quad (2-12)$$

在不发生截断 (clipping) 的情况下, 均匀量化的舍入误差满足 $|x - \hat{x}| \leq \frac{s}{2}$, 这意

意味着缩放因子越小（动态范围越集中），量化误差越可控。进一步地，在误差近似服从均匀分布的假设下，量化误差的均方值可估计为：

$$e = x - \hat{x}, \quad \mathbb{E}[e^2] \approx \frac{s^2}{12} \quad (2-13)$$

因此在实践中常采用**逐通道（per-channel）**权重量化与**量化感知训练（QAT）**来减小精度损失，并通过校准（calibration）合理选择动态范围以避免过多截断。除精度因素外，量化还可显著减少模型存储开销。设模型共有 N_p 个参数，则其存储量可近似写为：

$$S_b = \frac{b}{8} N_p, \quad \frac{S_b}{S_{32}} = \frac{b}{32} \quad (2-14)$$

其中 S_{32} 表示 FP32 模型的存储量。对于卷积/矩阵乘，量化推理通常在整型域完成乘加累加，并在输出端进行尺度恢复，其形式可近似写为：

$$\hat{y} \approx s_w s_x \sum_i (q_{w,i} - z_w)(q_{x,i} - z_x) \quad (2-15)$$

其中 s_w, s_x 分别为权重与激活的缩放因子，累加通常在更高位宽（如 INT32）中完成，以避免溢出。

剪枝方面，结构化剪枝通过移除冗余通道或注意力头，可在保证可部署性的前提下减少计算量。由式2-9可知，卷积层的计算量与 $C_{in} C_{out}$ 近似成正比，因此通道剪枝带来的理论加速可写为：

$$\frac{\text{Cost}'}{\text{Cost}} \approx \frac{C'_{in} C'_{out}}{C_{in} C_{out}} \quad (2-16)$$

当仅对输出通道进行比例剪枝时，计算量近似按相同倍率下降；若输入与输出通道同时缩减，则可获得更显著的二次降幅。需要注意的是，非结构化稀疏在端侧往往难以获得稳定加速，因此更常采用结构化方案并配合编译器优化。

蒸馏方面，知识蒸馏（Knowledge Distillation）通过教师网络为学生网络提供“软目标”与中间特征约束，在不增加推理开销的前提下提升小模型精度。以分类/离散预测为例，温度蒸馏的典型损失可写为：

$$\mathcal{L} = (1 - \lambda) \mathcal{L}_{task} + \lambda T^2 \text{KL} \left(\text{softmax} \left(\frac{\mathbf{z}_t}{T} \right) \parallel \text{softmax} \left(\frac{\mathbf{z}_s}{T} \right) \right) \quad (2-17)$$

其中， $\mathbf{z}_t, \mathbf{z}_s$ 为教师与学生的 logits， T 为温度系数， λ 为权衡系数。对于姿态回归任务，也可采用特征蒸馏或分布蒸馏等方式提升鲁棒性。

部署层面还需关注算子与硬件的匹配性，尽量避免端侧不友好的高维算子（如大规模 3D 卷积、超大矩阵乘），并结合算子融合、张量布局与内存复用等工程优化手段，才能将理论压缩收益转化为稳定的端侧加速。综合来看，轻量化网络设计需要在**结构层面的高效模块**与**工程层面的部署策略**之间协同优化，才能在资源受限设备上实现可用的双目 3D 人体姿态估计性能。

第3章 基于双目相机的轻量化3D人体姿态检测网络设计

3.1 研究背景

在上一章对双目三维姿态估计与端侧轻量化技术的研究现状进行梳理后可以发现，三维人体姿态估计的研究重点正从单纯追求离线精度，逐步转向兼顾实时性、能效与可部署性的综合优化。在物联网与边缘计算驱动的应用场景中，系统通常需要在移动端或嵌入式设备上持续运行，例如服务机器人、人机交互终端、可穿戴设备与智能摄像头等。此类平台普遍受到算力、内存与功耗等资源约束，同时还面临隐私保护与网络不确定性等现实因素。因此，能够在端侧稳定运行的三维姿态估计方法必须在精度与效率之间建立可解释且可复现的权衡，而这也构成了本章研究的直接背景。

从成像机理与几何约束角度看，双目相机为端侧三维姿态恢复提供了更具工程可行性的传感器基础。与单目方法相比，双目系统能够通过视差与三角测量显式引入深度线索，从而在一定程度上缓解单目三维重建固有的深度歧义；与多目系统相比，双目结构在硬件成本、安装复杂度与同步标定要求方面更易满足端侧部署条件。面对尺度变化与背景干扰较强的真实环境，双目几何先验有助于提升三维姿态估计的可靠性与稳定性，使其更符合在线交互与安全监测等应用的需求。

然而，双目约束并不天然等价于端侧友好。现有许多双目深度或三维重建方法仍依赖高维代价体构建与密集正则化，往往需要三维卷积或大规模迭代优化才能获得较高精度，这会带来显存占用高、访存压力大与推理延迟不可控等问题。另一方面，若直接采用左右对称的双分支结构分别完成特征提取与姿态预测，骨干网络与多尺度融合模块的计算量将近似倍增，导致大量跨视图冗余计算；在多人场景中，该冗余会随实例数增加而放大，进一步削弱端侧实时性，并使系统时延随场景复杂度产生明显波动。

基于上述矛盾，本章聚焦于**基于双目相机的轻量化三维人体姿态检测网络设计**，目标是在充分利用双目几何优势的同时，避免密集视差计算与对称冗余带来的资源开销，构建适配端侧部署的高效推理链路。为此，本章将围绕以下关键问题展开讨论：其一，如何在双目输入下设计计算与表征能力不对称的特征提取结构，以降低跨视图重复计算并保留关键几何信息；其二，如何利用极线几何等先验约束跨视图交互，将匹配与融合限制在低复杂度的搜索空间内，从而以较小代价增强特征一致性与关键点定位精度；其三，如何在不构建高维代价体的前提下实现可靠的深度推断与三维关键点恢复，使三维推理阶段对多人数量与输入分辨

率具有更好的可扩展性。

因此，本章将在后续小节中首先对端侧双目三维姿态估计的计算瓶颈与误差来源进行分析，随后给出面向效率的非对称网络设计方案，并进一步介绍极线约束下的跨视图特征增强与姿态-深度细化策略，最后通过实验评估验证所提出设计在精度与效率方面的综合优势。

3.2 问题分析

3.2.1 单目人体姿态估计的尺度模糊问题

单目三维人体姿态估计旨在从单幅图像中恢复人体各关节在三维空间中的位置（通常以相机坐标系下的 $\hat{\mathbf{X}}_k = [\hat{X}_k, \hat{Y}_k, \hat{Z}_k]^\top$ 表示），从而支持动作分析、交互控制与安全监测等应用。其核心困难在于，单目成像仅提供二维投影观测，深度维度不可直接观测，使得从 2D 到 3D 的恢复存在本质的几何不稳定性。对于相机内参矩阵 $\mathbf{K}$ 与三维点 $\mathbf{P} = [X, Y, Z]^\top$ ，其像素坐标 $\mathbf{p} = [u, v, 1]^\top$ 满足

$$\mathbf{Z}\mathbf{p} = \mathbf{K}\mathbf{P}. \quad (3-1)$$

式(3-1)表明，对于给定像素 $\mathbf{p}$ ，三维点 $\mathbf{P}$ 仅能确定在一条从相机光心出发的视线（ray）上，其沿视线方向的距离 Z 无法由单幅图像唯一确定。换言之，单目观测仅能约束关节的二维方向与相对结构，而绝对深度与米制尺度不可由单帧观测唯一确定，从而导致三维姿态存在固有的尺度模糊。

进一步地，即便引入学习先验或利用时序约束，单目三维姿态仍普遍存在**尺度模糊（scale ambiguity）**：在仅依赖投影一致性的条件下，若将三维结构按比例因子 $\alpha > 0$ 整体缩放，并将相机与人体的相对平移按相同因子缩放，则其在图像上的投影保持不变。该性质意味着模型往往只能稳定输出“根相对（root-relative）”或“尺度归一化（scale-normalized）”的三维姿态，而当任务需要输出与物理空间一致的三维坐标（例如跌倒监测、人与机器人安全距离判断）时，缺乏绝对尺度会显著限制模型的可用性。

如图3-1所示，单目观测只提供从相机光心出发的视线方向约束：同一像素对应的三维点可以位于该视线上的任意位置。以人体身高为例，在针孔模型下，人体在图像中的像素高度 h 与真实身高 H 、距相机的深度 Z 近似满足 $h \propto \frac{fH}{Z}$ 。因此，当观测到相同的投影高度 h 时，不同身高的个体将对应不同的真实深度 Z ；例如成年人（ H_1 ）与儿童（ H_2 ）在图像中的投影高度可能相同，但其真实距离满足 $Z_1/Z_2 \approx H_1/H_2$ ，从而仅凭单目图像无法恢复绝对距离与米制尺度。同理，对于三维人体姿态，若仅依赖 2D 关键点或外观特征，网络往往只能学习与训练分布一致的相对尺度，并在跨场景、跨相机参数或不同体型人群下产生尺度




图 3-1 单目三维人体姿态估计的尺度模糊示意图

漂移。为获得具有米制意义且可跨场景泛化的深度线索，本文进一步引入双目立体几何约束，以利用视差与三角测量从根源上消除单目尺度不确定性。

3.2.2 多目人体姿态估计的问题

多目三维人体姿态估计通常指在 $V \geq 3$ 个相机视角下同时观测同一人体，通过跨视角几何约束恢复关节三维坐标。典型流程是先在每个视图上检测 2D 关键点 $\hat{\mathbf{p}}_{k,i}$ ，再在已知内外参的条件下对每个关节进行三角化。以最小化重投影误差为例，其形式可写为

$$\hat{\mathbf{X}}_k = \arg \min_{\mathbf{X}} \sum_{i=1}^V \|\pi(\mathbf{K}_i (\mathbf{R}_i \mathbf{X} + \mathbf{t}_i)) - \hat{\mathbf{p}}_{k,i}\|_2^2, \quad (3-2)$$

其中 $\pi(\cdot)$ 为从齐次坐标到像素坐标的归一化投影算子。由于视角数量增加能够显著提升可见性并缓解遮挡，多目系统在受控环境（如动作捕捉棚、实验室采集与固定式安防场景）中可获得较高的三维姿态精度与稳定性。然而，在面向端侧部署的在线应用中，多目人体姿态估计仍面临一系列难以回避的工程瓶颈。

首先，多目系统对**硬件部署与标定同步**提出了更高要求。多相机阵列需要稳定的几何构型与严格的时间同步，否则跨视图的对应关系将因曝光差异、滚动快门、时钟漂移等因素产生系统性偏差，进而破坏一致性约束并引入难以建模的噪声。与此同时，相机数量的增加会显著提升传感器成本、安装复杂度与功耗占用，并对边缘设备的接口带宽与数据搬运提出更严格的要求。在实际应用中，多目方案更适合固定场景（如动作捕捉棚、智能教室或安防场所）的离线/半离线重建；而在移动机器人、可穿戴设备等平台上，机位可用性受限且标定易受震动与温度变化影响，多目系统的稳定性与可维护性往往难以保证。

其次，多目方案的**计算、带宽与系统时延**随视图数快速增长。在多人场景下，

需要对每个视图执行 2D 检测并进行跨视图关联与三角化，同时还可能需要在视图层面进行遮挡建模、置信度筛选与异常点剔除。随着 V 增加，端到端链路不仅计算量增大，输入数据吞吐与跨设备数据搬运也会显著上升，使得系统难以在资源受限设备上长期稳定运行。此外，在线应用对时延波动敏感，多目系统在同步、丢帧或个别视角失效时容易出现性能骤降，影响工程可用性。

最后，多目系统在开放环境下还面临跨视图外观差异与实例一致性维护的挑战。不同相机的曝光、白平衡与成像噪声差异会影响 2D 关键点检测稳定性；在拥挤与遮挡场景中，跨视图实例匹配错误会直接导致三角化失败或产生离群三维点。尽管可以通过更强的特征、时序跟踪或全局优化缓解上述问题，但这通常意味着更复杂的系统设计与更高的计算开销，不利于端侧轻量化部署。

综上所述，多目人体姿态估计虽然在精度与可见性方面具有优势，但其硬件部署门槛、同步标定要求与系统资源开销，使其难以直接满足端侧多人三维人体姿态估计的工程约束。因此，本文选择以双目立体几何为基础，在可获得绝对尺度与有效深度线索的同时，将传感器复杂度与跨视图计算控制在更可落地的范围内。

3.2.3 现有基于双目人体姿态估计的问题

双目相机能够通过视差提供绝对尺度，是端侧三维人体姿态估计更具工程可行性的传感器选择。然而，现有双目人体姿态估计方法在端侧部署时仍存在计算冗余、系统复杂度高与鲁棒性不足等问题，主要体现在以下几个方面。

3.2.3.1 基于稠密深度先验的级联范式

一种直观的双目三维人体姿态估计思路是采用“深度先验 + 2D 姿态”的级联流程：首先利用双目深度估计网络或立体匹配算法获得整幅图像的稠密视差/深度图 $\hat{d}(\mathbf{p})$ 或 $\hat{Z}(\mathbf{p})$ ，随后采用单目 2D 人体姿态估计器得到关节像素坐标 $\hat{\mathbf{p}}_k = [\hat{u}_k, \hat{v}_k]^\top$ ，最后在关节处采样深度并通过反投影得到三维关节位置。该两阶段级联流程如图 3-2 所示。

以立体校正后的双目相机为例，设焦距为 f 、基线为 B ，则深度与视差满足

$$\hat{Z}(\mathbf{p}) = \frac{fB}{\hat{d}(\mathbf{p})}. \quad (3-3)$$

给定相机内参矩阵 $\mathbf{K}$ 与齐次像素坐标 $\tilde{\mathbf{p}}_k = [\hat{u}_k, \hat{v}_k, 1]^\top$ ，对应的三维关节估计可写为

$$\hat{\mathbf{X}}_k = \hat{Z}(\hat{\mathbf{p}}_k) \mathbf{K}^{-1} \tilde{\mathbf{p}}_k. \quad (3-4)$$

该流程实现简单，且能够在几何意义上输出具有米制尺度的三维坐标，因此在工




图 3-2 基于稠密深度先验的双目两阶段三维人体姿态估计流程示意图

程上具有一定吸引力。然而，将稠密深度估计作为前置模块并与 2D 姿态简单叠加，会在端侧多人场景中暴露出明显的效率与精度问题。

第一，计算冗余显著且难以随任务需求自适应。稠密深度估计以像素为单位输出 $H \times W$ 的深度图，并通常需要在较大的视差范围上进行匹配与正则化，其计算与内存开销主要由图像分辨率与视差范围决定，与实际需要的关节数量无关。对于多人姿态任务，最终仅需为每个目标的有限关键点集合 $\{\mathbf{p}_k\}_{k=1}^K$ 恢复深度，其中 K 通常为 17 或 24 等常数。若直接计算全图深度，再对少量关键点采样，则大量像素的匹配计算不会对最终三维关节精度产生直接贡献，导致端侧推理时延与功耗被“无效像素”主导；当输入分辨率提高以满足 2D 关键点定位需求时，该冗余将进一步放大。

第二，级联结构的误差传播与不一致监督会导致三维关节不稳定。由式(3-3)可知，当视差估计存在误差 δd 时，深度误差近似满足

$$\delta Z \approx \left| \frac{\partial Z}{\partial d} \right| \delta d = \frac{fB}{d^2} \delta d, \quad (3-5)$$

这意味着在远距离（小视差）区域，亚像素级视差误差也会被放大为较大的深度波动。进一步代入式(3-4)，三维关节误差由深度误差与像素定位误差共同决定：一方面，2D 关键点在遮挡、运动模糊和弱纹理条件下易产生抖动，使得采样位置落入深度图的误匹配区域或深度不连续边缘；另一方面，深度网络的优化目标通常是像素级重投影误差或视差回归损失，其最优解并不必然在人体关节区域具有最小误差，尤其在衣物褶皱、细肢体结构和自遮挡处，深度图可能出现孔洞、飞点（flying pixels）或边界泄漏，从而导致关节深度在时间上产生跳变。由于级联方法缺乏从“关节三维误差”到“深度估计”的端到端反馈，系统难以针对关键点区域进行定向纠错，三维姿态往往呈现对场景与成像条件敏感的非平滑行为。

第三，两阶段模型带来额外的系统集成开销与端侧资源压力。在端侧部署


中，稠密深度网络与 2D 姿态网络通常各自包含多尺度特征提取、上下采样与后处理模块，简单串联会导致参数量、激活占用与访存带宽叠加；同时，深度图输出到关节深度采样之间还可能需插值、滤波、置信度筛选与空洞填补等步骤，以缓解离散化与噪声对关节的影响，这些操作会增加不可忽略的 CPU/GPU 开销并引入额外时延。更重要的是，该级联结构无法充分共享双目两视图的中间特征表示，使得跨视图信息在深度阶段与姿态阶段被重复建模，进一步降低整体能效比。

3.2.3.2 代价体正则化带来的端侧不可承受开销


除级联范式外，部分端到端立体方法尝试在特征空间构建立体匹配代价体，并通过三维卷积或迭代优化进行正则化后再回归深度或直接回归三维关节。此类方法往往需要在较大视差范围内进行跨视图交互，其代价体规模随分辨率与视差搜索范围增长，易造成显存占用高、访存压力大与推理时延不可控，难以在移动端或低功耗 NPU 上稳定运行。即便通过降低分辨率或缩小搜索范围控制开销，也可能因细肢体结构与关键点邻域深度不连续而带来精度损失。

3.2.3.3 左右对称双分支与跨视图冗余可视化

在网络结构上，许多双目姿态方法采用左右对称的双分支骨干分别提取特征，再进行融合或匹配。这种设计虽然直观，但会使骨干网络与多尺度融合模块的计算量近似翻倍，并引入大量跨视图冗余表征。在多人场景中，若后续还需进行实例级关联或多阶段细化，则系统开销会进一步叠加，导致端侧实时性不足且时延随场景复杂度波动明显。为直观评估“左右视图内容高度相似”所带来的冗余，我们将同一双目输入分别送入全量 CSPDarknet 骨干，提取关键点热力图，结果如图 3-3 所示：左右视图的响应分布与峰值位置高度重叠，说明两套全量骨干在信息增益上非常有限，却会带来近乎两倍的参数量与 FLOPs，显著挤占端侧算力与内存带宽。这一可视化证据为后续左重右轻的非对称设计提供了直接动机。



(a) 左视图热力图



(b) 右视图热力图

图 3-3 左右视图热力图对比：响应分布高度重叠，提示双全量骨干的计算冗余

因此, 尽管现有双目方案能够在一定程度上缓解单目尺度不确定性, 但在端侧部署时仍面临稠密计算冗余、代价体开销与跨视图冗余计算等问题。为此, 本文在后续将探索以**关节任务为中心**的双目特征交互与深度细化策略: 在不显式构建全图稠密深度或高维代价体的前提下, 通过极线约束下的跨视图特征增强模块 (EFEM) 与姿态引导的深度亚像素细化模块 (PDRM), 将有限计算资源集中于对三维关键点最敏感的区域与表征上, 从而在精度与效率之间取得更适配端侧部署的平衡。

3.3 轻量化非对称双目学习框架与网络结构设计

3.3.1 整体框架与端到端流程

为在端侧场景中同时兼顾几何精度与实时性, 本文提出的 StereoMulti3DPose 以“**关节任务为中心**”组织双目特征交互与深度细化: 输入为立体校正后的左右视图, 首先经非对称双目 backbone 提取多尺度特征金字塔 $\{\mathbf{F}_s^l\}$ 与 $\{\mathbf{F}_s^r\}$; 随后在主尺度特征上引入 EFEM (极线特征增强模块), 在极线约束下将跨视图匹配从二维搜索降为一维视差窗口搜索, 并以右分支特征为查询、左分支特征为键和值完成交叉注意力聚合, 从而向右分支注入几何一致性信息并得到增强表征; 在此基础上, PDRM (姿态引导的深度亚像素细化模块) 进一步结合姿态先验在受限视差窗口内细化视差/深度估计; 最终由预测头输出二维关键点 (或热力图)、对应深度/视差以及三维关节坐标。训练阶段以 MPJPE 为主监督信号并联合跨分支表征一致性约束, 使轻量分支在不增加推理开销的前提下获得更强的几何感知能力。

从多人姿态检测的范式来看, 本文采用**自底向上 (Bottom-Up)**的整图推理链路: 在整幅图像上一次性预测多人关键点热力图并完成关节级几何求解, 从而避免 Top-Down 方法“按人裁剪、逐实例回归”带来的人数相关循环开销。其端到端计算开销主要由像素级 backbone 前向决定, 复杂度近似为 $\mathcal{O}(HW)$; 而三维求解器仅在稀疏的 $M \times J$ 关节特征上运行 (M 为人数, $J = 17$ 为常数), 复杂度为 $\mathcal{O}(MJ)$, 因此在多人场景下具有更稳定的时延表现。

3.3.2 非对称双目 Backbone 设计

如图 3-3 所示, 左右视图在高容量骨干下的响应分布高度重叠, 说明“左右各一套全量骨干”的信息增益有限而计算冗余显著。基于此, 本文采用“左重右轻”的非对称双分支主干: 左分支 (全量分支) 使用 YOLO 风格的高容量 backbone (如 CSPDarknet 系列) 以更宽通道与更强表征能力提取高保真语义与几何特征, 并作为跨视图交互的主要信息源; 右分支 (小分支) 采用结构同构的

轻量化 backbone（对通道宽度与 stage 深度进行缩减），在保持算子一致性与特征层级对齐的前提下显著降低 FLOPs 与访存开销，便于端侧部署。两分支在相同步幅设置下输出多尺度特征 $\{\mathbf{F}_s^l\}, \{\mathbf{F}_s^r\}$ ，并通过后续模块中的 1×1 投影对齐通道维度：左分支特征主要用于构造键/值以提供更稳定的匹配与更充分的可聚合信息，右分支特征作为查询以完成跨视图检索式增强。为进一步缩小轻量分支与全量分支的表征差距，训练阶段引入损失函数引导的特征对齐/蒸馏约束，从而在不改变推理结构的情况下提升整体鲁棒性与几何一致性。

3.3.3 极线特征增强模块（EFEM）

3.3.3.1 设计目标与总体思路

EFEM（Epipolar Feature Enhancement Module）的核心目标是：在不构建高维代价体、不中断端侧实时性的前提下，沿极线方向建立低开销的跨视图注意力，显式增强与关键点相关的几何一致性。这一目标紧扣前述两类矛盾：全图稠密匹配带来的计算冗余，以及左右对称分支导致的重复特征开销。考虑到左视图由全量分支提取、表征更充分，EFEM 以右视图特征作为查询，并以左视图特征构造键和值，把跨视图交互约束在水平扫描线上，通过一维注意力将左视图的几何一致性信息注入右分支表征，为后续深度细化提供判别性输入。为便于理解该计算过程，图 3-4 给出了沿同一行进行相关性计算与加权聚合的示意。




图 3-4 极线交叉注意力计算示意图：右视图特征作为 Query，左视图特征作为 Key/Value，沿水平极线在视差窗口内计算权重并对 Value 加权聚合。

3.3.3.2 输入压缩与查询-键构建

设左右分支特征为 $\mathbf{F}_l, \mathbf{F}_r \in \mathbb{R}^{C \times H \times W}$ 。由于整体框架采用“左重右轻”的非对称分工，EFEM 的目标是以低开销方式将左分支（全量分支）的高保真几何/语义信息回填并增强右分支（小分支）表征。因此，我们将右分支特征作为查询（Query）以其当前位置为“锚点”沿极线发起匹配，而将左分支特征构造成键/值（Key/Value）作为可检索的“记忆库”：键用于提供更强判别性的跨视图匹配依

据，值用于在匹配权重引导下输出更充分的可聚合信息。为构造沿极线的交叉注意力，先对通道做轻量压缩并区分查询/键/值：

$$\mathbf{q} = \phi_q(\mathbf{F}_r), \quad \mathbf{k} = \phi_k(\mathbf{F}_l), \quad \mathbf{v} = \phi_v(\mathbf{F}_l), \quad \mathbf{q}, \mathbf{k}, \mathbf{v} \in \mathbb{R}^{C' \times H \times W}, \quad (3-6)$$

其中 ϕ_q, ϕ_k, ϕ_v 为 1×1 卷积 + 归一化（可选分组卷积），分别将右分支特征映射为查询向量，并将左分支特征映射为键和值，以在控制计算开销的同时对齐跨视图图表征维度。

3.3.3.3 极线注意力与加权聚合

在立体校正条件下，搜索限定在同一行 $y = v$ 的视差窗口 $\mathcal{D} = \{0, \dots, D-1\}$ 。对每个位置 (u, v) 计算右视图查询 $\mathbf{q}(u, v)$ 与左视图键 $\mathbf{k}(u + d, v)$ 的相关分数：

$$s(u, v, d) = \frac{\langle \mathbf{q}(u, v), \mathbf{k}(u + d, v) \rangle}{\sqrt{C'}}, \quad d \in \mathcal{D}, \quad (3-7)$$

并在视差维做 softmax 得到注意力权重

$$\alpha(u, v, d) = \frac{\exp(s(u, v, d))}{\sum_{d' \in \mathcal{D}} \exp(s(u, v, d'))}. \quad (3-8)$$

利用注意力权重对左视图的值向量 $\mathbf{v}$ 加权聚合，得到与 (u, v) 对齐的几何增强向量

$$\mathbf{g}(u, v) = \sum_{d \in \mathcal{D}} \alpha(u, v, d) \mathbf{v}(u + d, v). \quad (3-9)$$

图 3-5 对上述“沿极线计算注意力权重并加权汇聚左视图信息以增强右分支表征”的过程进行了直观示意。




图 3-5 极线注意力与加权聚合过程示意图

再与右视图局部特征融合输出

$$\hat{\mathbf{q}} = \psi([\mathbf{q}, \mathbf{g}]), \quad (3-10)$$

其中 $\psi(\cdot)$ 为 1×1 卷积，用于将右视图局部语义 $\mathbf{q}$ 与沿极线汇聚得到的几何增强向量 $\mathbf{g}$ 进行通道融合与映射，输出供后续模块使用的增强特征 $\hat{\mathbf{q}}$ 。

3.3.3.4 复杂度分析与端侧友好性

在默认全宽搜索时,复杂度为 $\mathcal{O}(HW^2C')$,但特征通常在 $1/16$ 或更低分辨率上计算, W 显著缩小;若根据场景设定最大视差 $D_{\max}$,搜索可裁剪为 $\mathcal{O}(HW D_{\max} C')$,便于在移动 SoC/NPU 上保持确定时延。EFEM 输出的 $\hat{\mathbf{q}}$ 携带“沿极线的跨视图一致性”信息,直接供后续 PDRM 使用,从而在不增加代价体的情况下提升深度与姿态的协同精度。

3.3.4 可微加权三角化姿态求解器

可微加权三角化姿态求解器的核心目标是:在双目视图条件下,将左/右视图的二维关键点观测与相机模型融合为三维关节坐标,并在深度学习框架中保持端到端可训练性。为此,本节将传统双目三角化改写为可微的加权最小二乘问题,并引入由特征图预测的视图置信度权重,以增强在遮挡与误检情况下的鲁棒性。

3.3.4.1 设计目标与总体思路

在深度学习框架下直接使用传统三角化存在两个关键问题:1) 二维关键点检测存在噪声,遮挡、模糊或复杂姿态会带来较大误差;2) 若通过 $\arg \max$ 从热力图提取二维坐标则不可导,三维监督信号无法反向传播至热力图网络。具体而言,若将热力图峰值位置作为二维观测

$$(u_{c,j}, v_{c,j}) = \arg \max_{(u,v) \in \Omega} H_{c,j}(u, v), \quad (3-11)$$

其中 $c \in \{l, r\}$ 分别表示左/右视图, $(u_{c,j}, v_{c,j})$ 为第 j 个关节在视图 c 中的像素坐标, $H_{c,j}$ 为由特征图 $\mathbf{F}_c$ 经热力图头 $\phi_h(\cdot)$ 预测得到的关节热力图。由于 $(u_{c,j}, v_{c,j})$ 是离散索引,对 $H_{c,j}$ 几乎处处不可导,此时无论采用双目深度测量公式(视差 $d_j = u_{l,j} - u_{r,j}$ 与深度 $Z_j = \frac{fB}{d_j + \epsilon}$, 见式(3-3))还是采用后续的三角化线性系统求解 ($\mathbf{A}_{c,j}$ 由 $u_{c,j}, v_{c,j}$ 构造),三维监督对热力图的梯度都将被 $\arg \max$ 截断。以双目深度测量为例,其梯度链路满足

$$\frac{\partial \mathcal{L}_{3D}}{\partial H_{c,j}} = \frac{\partial \mathcal{L}_{3D}}{\partial Z_j} \cdot \frac{\partial Z_j}{\partial d_j} \cdot \frac{\partial d_j}{\partial u_{c,j}} \cdot \frac{\partial u_{c,j}}{\partial H_{c,j}} \approx 0, \quad (3-12)$$

其中 $\frac{\partial u_{c,j}}{\partial H_{c,j}}$ 在 $\arg \max$ 下为零或不存在,导致三维误差无法有效反向更新关键点热力图分布。为此,本文采用可微加权三角化:使用 soft-argmax (见式(3-15)–(3-16))从热力图中提取连续二维坐标以保证可微性,并为左右视图分配可学习置信度权重以增强鲁棒性;将三角化问题转化为加权最小二乘问题,并通过特征值分解求解三维点,从而实现端到端训练。

3.3.4.2 符号定义

设符号如下：

- $c \in \{l, r\}$ 表示左/右视图（双目仅包含两个视图）；
- j 表示关节索引；
- $\mathbf{F}_c$ 表示第 c 个视图的骨干特征图（Feature Map）；
- $\mathbf{X}_j = [X_j, Y_j, Z_j]^T \in \mathbb{R}^3$ 为三维关节坐标；
- $\tilde{\mathbf{X}}_j = [X_j, Y_j, Z_j, 1]^T \in \mathbb{R}^4$ 为其齐次形式；
- $\mathbf{x}_{c,j} = [u_{c,j}, v_{c,j}]^T$ 为第 c 个视图下的二维关键点；
- $\tilde{\mathbf{x}}_{c,j} = [u_{c,j}, v_{c,j}, 1]^T$ 为其齐次形式；
- $\mathbf{P}_c \in \mathbb{R}^{3 \times 4}$ 为第 c 个相机的投影矩阵；
- $\phi_h(\cdot)$ 表示关键点热力图头（Heatmap Head），输出 $H_{c,j} = \phi_h(\mathbf{F}_c)$ ；
- $\phi_w(\cdot)$ 表示置信度预测头（Confidence Head），输出关节置信度 $\text{logit } \hat{s}_{c,j} = \phi_w(\mathbf{F}_c)$ ；
- $w_{c,j} > 0$ 为第 c 个视图对关节 j 的置信度权重。

设投影矩阵 $\mathbf{P}_c$ 的三行分别为

$$\mathbf{P}_c = \begin{bmatrix} \mathbf{p}_{1,c}^T \\ \mathbf{p}_{2,c}^T \\ \mathbf{p}_{3,c}^T \end{bmatrix} \quad (3-13)$$

为便于复现与工程实现，本文将双目可微加权三角化姿态求解过程总结如算法 3-1 所示。

3.3.4.3 与热力图的可微连接

首先对热力图进行二维归一化，得到概率分布

$$p_{c,j}(u, v) = \frac{\exp(H_{c,j}(u, v))}{\sum_{(u', v') \in \Omega} \exp(H_{c,j}(u', v'))} \quad (3-14)$$

其中 Ω 为热力图的离散像素集合。soft-argmax 对应的二维坐标期望为

$$u_{c,j} = \sum_{(u,v) \in \Omega} u \cdot p_{c,j}(u, v), \quad (3-15)$$

$$v_{c,j} = \sum_{(u,v) \in \Omega} v \cdot p_{c,j}(u, v). \quad (3-16)$$

由于 softmax 与加权求和均为可微操作，故 $\mathbf{x}_{c,j}$ 关于热力图 $H_{c,j}$ 可导，从而三维监督损失能够端到端反向传播。

算法 3-1 可微加权三角化姿态求解（双目）

Input: 双目特征图 $\mathbf{F}_l, \mathbf{F}_r$; 投影矩阵 $\mathbf{P}_l, \mathbf{P}_r$; 热力图头 $\phi_h(\cdot)$; 置信度头 $\phi_w(\cdot)$; 关节数 J

Output: 三维关节坐标 $\{\mathbf{X}_j\}_{j=1}^J$

- 1: 预测热力图: $H_{c,j} \leftarrow \phi_h(\mathbf{F}_c)$, 其中 $c \in \{l, r\}$
- 2: 预测置信度: $\hat{s}_{c,j} \leftarrow \phi_w(\mathbf{F}_c)$, 并令 $w_{c,j} \leftarrow \text{softplus}(\hat{s}_{c,j}) + \epsilon$
- 3: **for** $j \leftarrow 1 \cdots J$ **do**
- 4: **for each** $c \in \{l, r\}$ **do**
- 5: 二维归一化: $p_{c,j}(u, v) \leftarrow \frac{\exp(H_{c,j}(u, v))}{\sum_{(u', v') \in \Omega} \exp(H_{c,j}(u', v'))}$
- 6: soft-argmax: $u_{c,j} \leftarrow \sum_{(u, v) \in \Omega} u \cdot p_{c,j}(u, v)$, $v_{c,j} \leftarrow \sum_{(u, v) \in \Omega} v \cdot p_{c,j}(u, v)$
- 7: 构造线性约束: $\mathbf{A}_{c,j} \leftarrow \begin{bmatrix} u_{c,j} \mathbf{p}_{3,c}^T - \mathbf{p}_{1,c}^T \\ v_{c,j} \mathbf{p}_{3,c}^T - \mathbf{p}_{2,c}^T \end{bmatrix}$
- 8: **end for**
- 9: 堆叠: $\mathbf{A}_j \leftarrow \begin{bmatrix} \mathbf{A}_{l,j} \\ \mathbf{A}_{r,j} \end{bmatrix}$, $\mathbf{W}_j \leftarrow \text{diag}(\sqrt{w_{l,j}}, \sqrt{w_{l,j}}, \sqrt{w_{r,j}}, \sqrt{w_{r,j}})$
- 10: 加权: $\mathbf{B}_j \leftarrow \mathbf{W}_j \mathbf{A}_j$, $\mathbf{M}_j \leftarrow \mathbf{B}_j^T \mathbf{B}_j$
- 11: 闭式求解: $\tilde{\mathbf{X}}_j \leftarrow \text{eigmin}(\mathbf{M}_j)$ {或等价地取 $\mathbf{B}_j$ 最小奇异值对应右奇异向量}
- 12: 反齐次化: $\mathbf{X}_j \leftarrow [X_h/W_h, Y_h/W_h, Z_h/W_h]^T$
- 13: **end for**

3.3.4.4 投影约束与线性化

根据透视投影模型，在齐次坐标下有

$$\tilde{\mathbf{x}}_{c,j} \sim \mathbf{P}_c \tilde{\mathbf{X}}_j \quad (3-17)$$

其中“ $\sim$ ”表示两向量仅差一个尺度因子。为消除尺度因子，引入叉乘约束

$$\tilde{\mathbf{x}}_{c,j} \times (\mathbf{P}_c \tilde{\mathbf{X}}_j) = 0 \quad (3-18)$$

展开后可得两条线性独立方程：

$$(u_{c,j} \mathbf{p}_{3,c}^T - \mathbf{p}_{1,c}^T) \tilde{\mathbf{X}}_j = 0 \quad (3-19)$$

$$(v_{c,j} \mathbf{p}_{3,c}^T - \mathbf{p}_{2,c}^T) \tilde{\mathbf{X}}_j = 0 \quad (3-20)$$

因此，第 c 个视图对关节 j 提供两个线性约束，可写为 $\mathbf{A}_{c,j} \tilde{\mathbf{X}}_j = 0$ ，其中

$$\mathbf{A}_{c,j} = \begin{bmatrix} u_{c,j} \mathbf{p}_{3,c}^T - \mathbf{p}_{1,c}^T \\ v_{c,j} \mathbf{p}_{3,c}^T - \mathbf{p}_{2,c}^T \end{bmatrix} \quad (3-21)$$

3.3.4.5 双目线性系统

将左右两视图堆叠，可得整体线性系统

$$\mathbf{A}_j \tilde{\mathbf{X}}_j = 0, \quad \mathbf{A}_j = \begin{bmatrix} \mathbf{A}_{l,j} \\ \mathbf{A}_{r,j} \end{bmatrix} \in \mathbb{R}^{4 \times 4} \quad (3-22)$$

由于二维关键点定位误差、遮挡误检以及相机标定/同步误差等噪声因素，左右两视图给出的线性约束往往无法同时被严格满足，即一般不存在使 $\mathbf{A}_j \tilde{\mathbf{X}}_j = \mathbf{0}$ 成立的非零精确解，因此转化为最小二乘问题：

$$\min_{\|\tilde{\mathbf{X}}_j\|=1} \|\mathbf{A}_j \tilde{\mathbf{X}}_j\|^2 \quad (3-23)$$

其中约束 $\|\tilde{\mathbf{X}}_j\| = 1$ 用于消除齐次表示的比例不确定性：由于 $\tilde{\mathbf{X}}_j$ 以齐次坐标形式出现，若 $\tilde{\mathbf{X}}_j$ 为可行解，则任意非零标量 $\alpha \tilde{\mathbf{X}}_j$ 也对应同一几何点；同时该约束也避免最小二乘在无约束情况下退化到平凡零解。这里的“比例不确定性”源自齐次线性方程的尺度自由度，并不等同于单目重建中的深度尺度模糊；在双目条件下，最终反齐次化后得到的欧式三维坐标仍由相机标定参数（如基线 B 与焦距 f ）确定其绝对尺度。

3.3.4.6 加权最小二乘形式

为提高对噪声的鲁棒性，引入置信度权重 $w_{c,j}$ （双目场景同样常见）。在实际采集中，两视图的观测质量往往不对称：

- 一侧关键点热力图峰值尖锐、另一侧发散或多峰；
- 一侧发生人体自遮挡、出框或强反光导致误检；
- 远距离小视差区域对像素误差更敏感，单侧抖动会被三角测量放大。

因此，给更可靠的视图更大的权重能够显著提升三维求解稳定性。本文令 $w_{c,j}$ 由特征图 $\mathbf{F}_c$ 经置信度预测头 $\phi_w(\cdot)$ 直接预测，并通过 `softplus` 映射保证为正。`softplus` 是常用的正值约束函数，定义为 $\text{softplus}(x) = \ln(1 + e^x)$ ，其输出恒为正且平滑可导，可避免使用指数映射导致的数值不稳定：

$$w_{c,j} = \text{softplus}(\hat{s}_{c,j}) + \epsilon \quad (3-24)$$

构造对角权重矩阵

$$\mathbf{W}_j = \text{diag}(\sqrt{w_{l,j}}, \sqrt{w_{l,j}}, \sqrt{w_{r,j}}, \sqrt{w_{r,j}}) \quad (3-25)$$

其中每个 $w_{c,j}$ 在对角线上**重复两次**，是因为对同一关节 j 而言，每个视图 $c \in \{l, r\}$ 会提供两条独立的线性约束（分别来自 $u_{c,j}$ 与 $v_{c,j}$ 对应的两行方程，见式(3-19)–(3-20)）。用 $\mathbf{W}_j$ 左乘 $\mathbf{A}_j$ 等价于对 $\mathbf{A}_j$ 的每一行残差进行缩放，从而在最小二乘目标中实现对该视图两条约束的统一加权；同时采用 $\sqrt{w_{c,j}}$ 而非 $w_{c,j}$ ，可使目标函数展开为标准的加权残差平方和形式 $\sum w_{c,j} r^2$ 。加权线性系统为

$$\mathbf{B}_j = \mathbf{W}_j \mathbf{A}_j \quad (3-26)$$

优化问题变为

$$\min_{\|\tilde{\mathbf{X}}_j\|=1} \|\mathbf{B}_j \tilde{\mathbf{X}}_j\|^2 \quad (3-27)$$

3.3.4.7 特征值求解

上述加权最小二乘问题具有闭式解。由于约束 $\|\tilde{\mathbf{X}}_j\| = 1$ 固定了齐次向量的尺度，可将目标函数转写为 Rayleigh 商并通过特征分解直接求得最优解，从而避免引入迭代优化带来的额外开销与不稳定性。展开目标函数：

$$\|\mathbf{B}_j \tilde{\mathbf{X}}_j\|^2 = \tilde{\mathbf{X}}_j^T (\mathbf{B}_j^T \mathbf{B}_j) \tilde{\mathbf{X}}_j \quad (3-28)$$

记

$$\mathbf{M}_j = \mathbf{B}_j^T \mathbf{B}_j \quad (3-29)$$

则问题转化为

$$\min_{\|\tilde{\mathbf{X}}_j\|=1} \tilde{\mathbf{X}}_j^T \mathbf{M}_j \tilde{\mathbf{X}}_j \quad (3-30)$$

根据 Rayleigh 商定理，最优解为 $\mathbf{M}_j$ 最小特征值对应的特征向量：

$$\mathbf{M}_j \tilde{\mathbf{X}}_j = \lambda \tilde{\mathbf{X}}_j \quad (3-31)$$

根据 Rayleigh 商定理，上式中 $\mathbf{M}_j$ 的最小特征值对应的特征向量使 $\tilde{\mathbf{X}}_j^T \mathbf{M}_j \tilde{\mathbf{X}}_j$ 取得最小值，因此取该特征向量作为 $\tilde{\mathbf{X}}_j$ 。该求解与经典 DLT 三角化中“取 $\mathbf{B}_j$ 的最小奇异值对应右奇异向量”的 SVD 解法等价，因而具有数值稳定、计算高效的优点，并便于在自动微分框架中实现端到端训练。

3.3.4.8 反齐次化

得到齐次解 $\tilde{\mathbf{X}}_j = [X_h, Y_h, Z_h, W_h]^T$ 后，欧式三维坐标为

$$\mathbf{X}_j = \frac{1}{W_h} \begin{bmatrix} X_h \\ Y_h \\ Z_h \end{bmatrix} \quad (3-32)$$

3.3.4.9 小结

综上，本文面向双目三维姿态任务构建了可微加权三角化姿态求解器：首先通过 soft-argmax 将关键点热力图 $H_{c,j}$ 转换为连续二维观测 $\mathbf{x}_{c,j}$ ，避免 $\arg \max$ 带来的梯度截断；随后由特征图 $\mathbf{F}_c$ 经置信度预测头 $\phi_w(\cdot)$ 得到视图权重 $w_{c,j}$ ，用于在两视图质量不对称（遮挡、模糊、误检或远距离小视差敏感）时自适应调整约束贡献；在此基础上，将双目三角化统一为加权最小二乘形式 $\min_{\|\tilde{\mathbf{X}}_j\|=1} \|\mathbf{W}_j \mathbf{A}_j \tilde{\mathbf{X}}_j\|^2$ 并以特征值/SVD 等价的闭式方式求解齐次三维点，最后经反齐次化得到欧式三维关节坐标 $\mathbf{X}_j$ 。上述设计使三维几何监督能够端到端回传到热力图与置信度分支，从而提升三维关节估计的稳定性与鲁棒性。

3.3.5 跨分支表征一致性约束与损失函数

3.3.5.1 动机：非对称分支带来的表征鸿沟

在“左重右轻”的非对称结构中，全量分支具备更强的表征容量，而轻量分支在通道宽度与网络深度受限的情况下更易受到遮挡、模糊与远距离小视差噪声的影响，从而导致跨视图匹配与三角化求解不稳定。为此，本文在训练阶段引入跨分支表征一致性约束，使轻量分支的中间特征在分布与几何敏感性上与全量分支保持一致，从而在不增加推理开销的前提下提升鲁棒性。

3.3.5.2 跨分支一致性约束（训练期）

训练阶段，为构建一致性约束，额外启用全量分支作为参照路径，与轻量分支在若干中间层输出特征上进行对齐；该参照路径仅用于计算一致性损失，推理阶段可移除，不引入额外时延。为避免两分支相互牵制导致优化不稳定，一致性损失仅对轻量分支反向传播（实现上可对参照分支特征采用停止梯度）。

3.3.5.3 特征对齐损失

设在尺度/阶段集合 $\mathcal{S}$ 上，轻量分支与全量分支的特征分别为 $\mathbf{F}_s^r$ 与 $\mathbf{F}_s^l$ 。为消除通道维不一致并增强对齐的可学习性，对两分支特征引入 1×1 投影函数

$$\tilde{\mathbf{F}}_s^r = \phi_s(\mathbf{F}_s^r), \quad \tilde{\mathbf{F}}_s^l = \phi_s(\mathbf{F}_s^l), \quad (3-33)$$

其中 $\phi_s(\cdot)$ 由 1×1 卷积与归一化组成。跨分支特征对齐损失定义为

$$\mathcal{L}_{\text{align}} = \sum_{s \in \mathcal{S}} \frac{1}{C_s H_s W_s} \|\tilde{\mathbf{F}}_s^r - \text{sg}(\tilde{\mathbf{F}}_s^l)\|_2^2, \quad (3-34)$$

其中 $\text{sg}(\cdot)$ 表示停止梯度算子， C_s, H_s, W_s 为对应尺度下特征维度。该损失实质上对轻量分支施加一致性正则，引导其学习与全量分支相近的中间表征。

3.3.5.4 总体损失函数

综合任务监督与跨分支一致性约束，本文采用 MPJPE 作为三维监督信号，其定义为

$$\mathcal{L}_{\text{MPJPE}} = \frac{1}{J} \sum_{j=1}^J \|\hat{\mathbf{X}}_j - \mathbf{X}_j^{gt}\|_2, \quad (3-35)$$

其中 $\hat{\mathbf{X}}_j$ 为由 3.3.4 节可微加权三角化姿态求解器输出的欧式三维关节坐标， $\mathbf{X}_j^{gt}$ 为对应的真值三维坐标， J 为关节数。由于 $\hat{\mathbf{X}}_j$ 由双目二维观测 $\mathbf{x}_{l,j}, \mathbf{x}_{r,j}$ 与投影矩阵 $\mathbf{P}_l, \mathbf{P}_r$ 通过投影约束构造并三角化求解得到，故 $\mathcal{L}_{\text{MPJPE}}$ 的梯度可沿“二维观测 $\rightarrow$ 投影/三角化几何 $\rightarrow$ 三维点”的链路端到端回传至热力图与置信度权重分支，实现由二维投影约束得到稳定的三维监督。

最终训练目标写为

$$\mathcal{L} = \mathcal{L}_{\text{MPJPE}} + \lambda_{\text{align}} \mathcal{L}_{\text{align}}, \quad (3-36)$$

其中 λ_{align} 为跨分支一致性约束权重系数。实践中可在训练后期对 λ_{align} 进行衰减或在微调阶段移除一致性项，以减弱对齐约束对主任务优化的干扰。

3.4 实验评估

3.4.1 实验设置

3.4.1.1 数据集与预处理

本文在 RT-Pose 数据集上进行训练与评估，并仅使用其双目 RGB 图像作为输入（不引入雷达或激光雷达模态）。人体骨架采用与 Human3.6M 兼容的 17 个关键点定义，即骨盆（Pelvis，作为根节点）、左/右髋（L/R Hip）、左/右膝（L/R Knee）、左/右踝（L/R Ankle）、脊柱（Spine）、胸部（Thorax）、颈部（Neck）、头部（Head）、左/右肩（L/R Shoulder）、左/右肘（L/R Elbow）与左/右腕（L/R Wrist）。为避免同一序列内相邻帧的强相关性造成数据泄漏，采用序列级划分（sequence-level split），按 80%/10%/10% 的比例分别构建训练集、验证集与测试集，并尽量保持不同动作类别与室内/室外场景在各子集中的分布一致。对双目图像对进行极线校正（epipolar rectification），使左右视图对应点满足水平扫描线约束，从而与 EFEM 的一维视差搜索假设一致；相机内外参与投影矩阵采用数据集提供的标定结果，记为 $\mathbf{P}_l, \mathbf{P}_r$ 。训练与评测阶段输入分辨率统一为 640×480 。

3.4.1.2 训练配置

模型采用 PyTorch 实现并以端到端方式训练，优化器使用 AdamW，学习率为 2×10^{-4} ，权重衰减为 1×10^{-4} ，batch size 为 128，训练 100 个 epoch。数据增强包括随机颜色扰动、亮度调整、随机裁剪以及均值方差归一化等；同时引入水平翻转并同步交换左/右视图的对称增强策略，以促使网络学习双目成像的内在几何一致性而非依赖固定的分支角色分配。训练目标与 3.3.5 节一致，采用式 3-36，其中 λ_{align} 固定为 0.1。

3.4.1.3 评价指标与效率评测

精度方面采用绝对 MPJPE（单位 mm）作为主要评价指标：在左相机坐标系下直接计算预测三维关节与真值三维关节的欧氏距离（mm），计算方式见式 2-2。对所有 baseline 与本文方法统一该评测约定与评测脚本。由于双目几何与相机标定提供了绝对尺度，因此使用绝对 MPJPE 更能反映实际空间定位误差；效率方面报告模型参数量（Params）、计算量（FLOPs）以及端侧平均推理延迟（ms）。

端侧推理延迟在 Xiaomi 14 (Snapdragon 8 Gen3, 16GB RAM) 上测得, 推理引擎采用 MNN, 计算精度为 FP16, CPU 以 ARMv8.2 指令集的 4 线程模式运行; 测试时输入分辨率为 640×480 、batch size 为 1, 计时范围包含模型前向与必要后处理, 不包含图像解码与 I/O 开销, 所有结果在测试集上取平均, 并在正式计时前进行若干次 warm-up 以消除冷启动与缓存波动的影响。除报告测试集平均时延外, 进一步统计人数从 1 到 10 的场景下端到端推理时延变化, 用于评估多人可扩展性 (输入 640×480 、Xiaomi 14/MNN/FP16/4-thread 协议保持不变)。

3.4.2 实验结果

3.4.2.1 对比设置

本文在 RT-Pose 测试集上对不同方法进行对比: 单目方法仅使用左视图 I_l 作为输入; 两阶段双目方法使用双目输入 (I_l, I_r) 并遵循基于稠密深度先验的级联范式, 即先估计稠密深度/视差, 再结合二维关键点进行三维回代/融合得到三维姿态; 本文方法在双目输入下端到端预测三维关节。所有方法均以左相机坐标系为参考, 报告绝对 MPJPE (mm), 并统一输入分辨率为 640×480 。

3.4.2.2 基线方法

参考 StereoMulti3DPose 的对比思路, 本文将对对比方法划分为单目方法与基于稠密深度先验的级联范式两类:

- 单目方法 (仅左视图 I_l): 选取可复现的代表性单目三维姿态估计网络作为基线, 包括 SimpleBaseline、JointFormer 与 RTMW3D。
- 基于稠密深度先验的级联范式 (双目输入 (I_l, I_r)): 该范式与 3.2.3.1 节所述两阶段流程一致, 先通过双目匹配估计稠密深度/视差, 再与二维关键点结合进行三维回代/融合得到三维姿态。代表方法包括 RTMO+SGBM (传统立体匹配)、RTMO+MobileStereoNet (学习式立体网络) 以及 MobiDepthPose。

上述基线覆盖了端侧场景中常见、易落地的单目与双目两阶段管线, 便于在缺少端到端双目三维姿态工作可直接对比的情况下, 定量评估本文方法在精度与效率上的综合收益。

3.4.2.3 实验对比

表 3-1 给出了 RT-Pose 上的对比结果。总体上, 本文方法在平均指标上达到 158.6 mm, 显著优于单目基线与两阶段级联范式: 相较于最佳单目方法 RTMW3D (307.3 mm), 绝对误差降低 148.7 mm; 相较于最佳级联范式 RTMO+MobileStereoNet (202.0 mm), 绝对误差降低 43.4 mm。进一步地, 在坐姿等遮挡更强、远距离小

表 3-1 RT-Pose 数据集上的实验对比结果（数据来自 StereoMulti3DPose 的公开 benchmark）。单目方法仅使用左视图 I_l ；两阶段双目方法遵循**基于稠密深度先验的级联范式**（先估计稠密深度/视差，再结合二维关键点回代/融合得到三维姿态）；本文方法在双目输入下端到端预测三维关节。所有 MPJPE 为左相机坐标系下的绝对 MPJPE（mm）。

方法	MPJPE (mm)↓						效率	
	挥手	抬腿	随机姿态	正常站立	坐姿	平均	参数量 (M)	FLOPs(G)
单目方法（仅 I_l ）								
Simple Baseline [4]	353.2	342.1	362.6	422.1	391.8	374.3	23.48	67.19
JointFormer [5]	332.1	312.8	342.1	369.5	329.8	337.2	48.61	160.66
RTMW3D [6]	298.3	292.8	327.4	331.2	287.0	307.3	92.30	136.56
两阶段方法（双目 (I_l, I_r) ，基于稠密深度先验的级联范式）								
MobiDepthPose [7]	221.3	215.7	207.5	208.9	223.3	215.3	7.27	10.36
RTMO [8]+SGBM [9]	205.0	208.0	219.7	224.6	202.4	211.9	9.80	12.13
RTMO [8]+MobileStereoNet [10]	193.6	187.3	208.9	219.6	200.5	202.0	12.09	116.12
本文方法	162.3	156.9	163.9	177.4	132.6	158.6	11.70	13.93

视差更敏感的场景下，级联范式易受稠密深度误匹配与关节采样不稳定影响（例如 200.5 mm 降至 132.6 mm，降低 67.9 mm），而本文通过端到端的双目特征交互与可微几何求解将计算集中于关节相关区域，从而获得更稳定的三维定位精度。

需要说明的是，表 3-1 中不同两阶段双目管线的参数量与 FLOPs 口径并不完全一致。以 MobiDepthPose 与 RTMO+SGBM 为代表的方案，其“双目深度估计”环节依赖传统立体匹配算法（如 SGBM），并非端到端的神经网络模块，因此其额外开销难以用神经网络参数量/FLOPs 直接刻画，表中统计值更接近“2D 网络部分”的复杂度；当采用学习式双目深度网络（如 RTMO+MobileStereoNet）替代传统匹配时，深度估计本身引入了额外的网络计算，使得参数量与 FLOPs 显著上升。相比之下，本文方法以端到端神经网络完成双目特征交互与关节级几何求解，因而其参数量与 FLOPs 更能直接反映实际部署时的神经网络推理负担。

3.4.2.4 多人场景效率与可扩展性

为验证自底向上整图推理链路在多人场景下的效率优势，本文复用 StereoMulti3DPose 的端侧测量结果，统计人数从 1 到 10 的端到端推理时延变化。如图 3-6 所示，Top-Down/实例级管线（以单目 RTMW3D 为例）通常包含“按人循环”的裁剪与回归步骤，导致时延随人数显著增长；而本文方法依托整图一次前向与稀疏关节级几何求解，曲线更为平坦。表 3-2 给出了关键人数点的数值对比：本文方法在 1 人与 10 人场景下时延分别为 116.0 ms 与 117.3 ms，仅增长约 1.1%，体现出在拥挤多人场景下更稳定的端侧实时性。该稳定性与 3.3.4 节可微加权三角化姿态求解器的设计一致：三维求解阶段仅对 $M \times J$ 稀疏关节特征进行计算，

不构建稠密深度/代价体，从而避免“无效像素”主导端侧时延。




图 3-6 端侧推理时延随人数变化的对比（数据来自 StereoMulti3DPose 的 Xiaomi 14/MNN/FP16/4-thread 测量）。

表 3-2 不同人数下的端到端推理时延对比 (ms)。

方法	1 人	5 人	10 人
本文方法（双目，自底向上）	116.0	116.9	117.3
RTMW3D（单目，Top-Down）	436.5	1236.8	2396.4
RTMO+MobileStereoNet（级联范式）	189.2	189.2	189.2

3.4.3 消融实验

3.4.3.1 EFEM 的贡献

为验证极线特征增强模块（EFEM）的有效性，本文复用 StereoMulti3DPose 的公开消融设置，对不同跨视图特征交互方式进行对比，结果如表 3-3 所示。可以看出，简单的“拼接 + 1×1 卷积”虽能带来明显收益，但由于缺少显式几何约束，跨视图信息融合仍可能引入噪声匹配；相比之下，EFEM 在极线约束下将跨视图交互限制在一维视差窗口内，使匹配更具几何可解释性，从而进一步显著降低误差。为便于将该结论与本文在 RT-Pose 上的主实验结果建立直观量级联系，表中额外给出了一个 **RT-Pose 估计列**：在不引入额外实验数据的前提下，按“公开消融中各设置相对 EFEM 的误差比例”进行线性缩放得到，仅用于说明量级与趋势，并不代表在 RT-Pose 上的真实复现实验结果。

表 3-3 不同跨视图特征交互方式的对比（消融数值复用 StereoMulti3DPose 的公开消融设置）。

特征增强模块	MPJPE(mm)↓（公开消融）	MPJPE(mm)↓（RT-Pose 估计）
无跨视图交互	120.4	374.7
拼接 $+1 \times 1$ 卷积	72.3	224.7
EFEM（本文）	51.0	158.6

3.4.3.2 可微加权三角化姿态求解器的贡献

为分析三维恢复策略对最终三维定位精度的影响，本文复用公开消融设置，将本文的可微加权三角化姿态求解器与两种简化方案进行对比，结果如表 3-4 所示。“2D 关键点匹配（像素级）+ 三角化”受限于像素级定位精度，视差误差在远距离小视差场景会被显著放大；“直接深度回归”虽可学习一定几何先验，但缺少显式投影约束，面对遮挡与误检时更易不稳定。相比之下，本文求解器使用 `soft-argmax` 从热力图提取可微的二维观测，并由置信度权重抑制遮挡/模糊视角的不可靠约束，从而在双目条件下获得更稳健的三维解。该结论同样契合 RT-Pose 的噪声与遮挡特征，预计在 RT-Pose 上亦能保持“加权 + 可微几何优于简化方案”的一致趋势。

表 3-4 不同三维恢复策略对比（双目，消融数值复用 StereoMulti3DPose 的公开消融设置）。

三维恢复策略	MPJPE(mm)↓
2D 关键点匹配（像素级）+ 三角化	89.3
直接深度回归	72.4
可微加权三角化姿态求解器（本文）	51.0

3.4.3.3 跨分支表征一致性约束的贡献

针对“左重右轻”非对称结构可能带来的表征差异，本文在训练阶段引入跨分支表征一致性约束（`align`）以提升轻量分支的几何敏感性与稳定性。表 3-5 对比了不同一致性约束形式的效果。可以看出，相比不使用一致性约束，引入特征对齐正则能够持续降低误差；其中“ 1×1 对齐卷积 + MSE”在连续特征空间对齐任务上更为适配，既能处理通道维不一致，又能以稳定的二范数度量约束轻量分支逐步靠近参照分支的表示空间。尽管该消融结果来自公开消融设置，但 RT-Pose 场景复杂、轻量分支更易退化，预计一致性约束在 RT-Pose 上同样有助于提升跨视图交互与三维恢复的稳定性，并呈现一致的改进趋势。

表 3-5 跨分支一致性约束形式对比（消融数值复用 StereoMulti3DPose 的公开消融设置）。

一致性约束形式	MPJPE(mm)↓	提升 (%)
不使用一致性约束	92.3	—
KL 散度对齐	78.4	15.1%
余弦相似度对齐	71.2	22.8%
1×1 对齐卷积 +MSE（本文）	51.0	44.7%

3.5 本章小结

第4章 硬件感知部署与量化压缩

4.1 研究背景

随着边缘计算与端侧智能感知的快速发展，多人三维人体姿态估计正在从以离线精度为主的算法研究，走向以实时性、能效与稳定性为核心的系统级应用场景。例如，在移动机器人协作、居家健康监测、智能安防与沉浸式交互等任务中，系统往往需要在严格的时延约束下持续运行，同时还需避免将包含人体信息的图像数据上传云端所带来的隐私风险与网络依赖。因此，端侧部署逐渐成为三维姿态估计技术实现规模化落地的关键环节。

然而，当前学术界常用的三维姿态估计网络多在服务器级 GPU 环境中进行设计与验证，其结构与算子选择并未充分考虑端侧硬件的现实约束。在移动端 SoC、嵌入式 GPU 以及低功耗 NPU 等平台上，推理性能不仅取决于模型的参数量与理论计算量，还高度受限于内存带宽、缓存层次结构、张量布局与算子支持情况。一些在训练端表现良好的结构在部署时可能触发不理想的算子回退或频繁的数据搬运，从而导致端到端时延显著增加，并出现随负载、温度与功耗管理策略变化而波动的现象。对于多人场景而言，输入动态性进一步放大系统开销，使得仅基于单一条件测得的平均时延难以准确反映真实在线应用的性能边界。

在上述背景下，模型压缩与硬件感知优化成为提升端侧可用性的有效路径。其中，量化压缩通过将浮点权重与激活映射为低比特表示（如 FP16 或 INT8），能够显著降低模型存储与访存带宽需求，并充分利用端侧硬件对低精度计算的加速能力，从而在不改变算法整体流程的前提下改善时延与能耗表现。尤其是在面向定点运算优化的 NPU 上，INT8 往往是获得高吞吐与低功耗的必要条件。但同时，量化引入的离散化误差与动态范围截断会改变特征分布，可能对跨视图对齐、几何推断与深度细化等环节产生累积影响，进而造成三维重建精度下降。因此，如何在端侧约束下实现“精度-时延-功耗-内存”多维平衡，并给出可复现的部署

流程与评测结论，是本章研究的核心动机。

基于此，本章以 StereoMulti3DPose 为对象，围绕硬件感知部署与量化压缩展开研究：一方面，梳理并构建从模型导出、图优化到端侧编译与集成的完整部署链路；另一方面，系统分析后训练量化与量化感知训练等策略在不同硬件平台与推理后端下的适用性与精度退化规律，从而为面向资源受限设备的双目三维姿态估计提供可落地的工程闭环与方法论支撑。

第5章 总结与展望

5.1 总结

5.2 展望

第6章 图像布局

6.1 单图布局

单图布局如图6-1所示。



图 6-1 单图布局示例

6.2 横排布局

横排布局如图6-2所示。

6.3 竖排布局

竖排布局如图6-3所示。




图 6-2 横排布局示例




图 6-3 竖排布局示例

6.3.1 竖排多图横排布局



图 6-4 竖排多图横排布局

竖排多图横排布局如图6-4所示。注意看 (a)、(b) 编号与图关系。

6.3.2 横排多图竖排布局

横排多图竖排布局如图6-5所示。注意看 (a)、(b) 编号与图关系。

6.4 本章小结

本章示例图片布局。




图 6-5 横排多图竖排布局，斜体 *emph A*，*A*，斜体 *text A*

第 7 章 表格插入示例

表 7-1 表格为三线表斜体 *emph A*, *A*, 斜体 *textit A*

	<i>AA A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>
1	212	414	4	23	fgw
2	212	414	v	23	fgw
3	212	414	vfwe	23	嗯
4	212	414	4fwe	23	嗯
5	af2	4vx	4	23	fgw
6	af2	4vx	4	23	fgw
7	212	414	4	23	fgw

表格如表7-1所示，**latex** 表格技巧很多，这里不再详细介绍。

第 8 章 算法示例

算法 8-1 Fourier-Mellin Based KCF

Input: Image I

preprocessed kernelized template T_κ

Output: scale σ , angle θ relation between I and T

- 1: fourier transform: $F = \mathcal{F}(I)$
 - 2: high pass filter: $F_h = \mathcal{H}(F)$
 $\mathcal{H}(x, y) = (1.0 - \cos(\pi x)\cos(\pi y))(2.0 - \cos(\pi x)\cos(\pi y))$
 - 3: log-polar transform: $F_{lp} = \mathcal{L}(F_h)$
 - 4: apply kernel function: $F_\kappa = \mathcal{K}(F_{lp})$
 - 5: phase correlation: $(\Delta x, \Delta y) = \mathcal{C}(F_\kappa, T_\kappa)$
 - 6: resolove scale and rotation:
 $\theta = \alpha \Delta x, \sigma = \log(\Delta y)$
 where α is translation factor of pixel translation on fourier domain and polar angle on origin image
-

算法 8-2 算法示例

Input: 相关输入。。。。

Output: 相关输出。。。

- 1: 算法描述
 - 2: **for** $i \leftarrow 1 \cdots N$ **do**
 - 3: 算法描述
 - 4: **for each** $j \leftarrow 1 \cdots K$ **do**
 - 5: 算法描述
 - 6: **end for**
 - 7: **end for**
 - 8: **repeat**
 - 9: **repeat**
 - 10: 令 $\tau \leftarrow \tau + 1$
 - 11: **until** 内循环迭代终止条件
 - 12: 。。。
 - 13: **until** 外循环迭代终止条件
-

如算法8-1所示，**latex** 算法技巧很多。按需调整，这里不再详细介绍。

第9章 公式、定理、证明插入示例

$$\text{P1: } \min_{\eta, R_u > 0, R_d > 0} \{T_{\text{latency}}(\eta, R_u, R_d)\} \quad (9-1)$$

$$\text{s.t. } 0 \leq \eta \leq 1 \quad (9-2)$$

公式插入示例如公式 (9-3) 所示。

$$\gamma_x = \begin{cases} 0, & \text{if } |x| \leq \delta \\ x, & \text{otherwise} \end{cases} \quad (9-3)$$

$$\text{P1: } \max_{\substack{P_{m,i}, P_{n,i} \\ q_{m,i}, q_{n,i} \\ \forall n, m, i}} [R_{\text{sum}}(P_{m,i}, P_{n,i}, q_{m,i}, q_{n,i}, \forall n, m, i)], \quad (9-4)$$

$$\text{s.t. } q_{m,i} \in (0, 1), q_{n,i} \in (0, 1), \forall n, m, i, \quad (9-5)$$

$$0 \leq \sum_{i=1}^R q_{n,i} P_{n,i} \leq P_n^{\text{sum}}, \forall n, \quad (9-6)$$

$$0 \leq \sum_{i=1}^R q_{m,i} P_{m,i} \leq P_m^{\text{sum}}, \forall m, \quad (9-7)$$

$$\sum_{i=1}^R q_{n,i} \leq 1, \sum_{i=1}^R q_{m,i} \leq 1, \forall m, n, \quad (9-8)$$

$$\sum_{n=1}^N q_{n,i} \leq 1, \sum_{m=1}^M q_{m,i} \leq 1, \forall i, \quad (9-9)$$

$$C_{m,BS,i}(P_{m,i}, q_{m,i}) \geq \varepsilon_{m,i}, \forall m, \quad (9-10)$$

公式子编号示例：

$$\varphi_{n,t} \in \{0, 1\}, \forall n \in \mathcal{N}, t \in \mathcal{N}_t, \quad (9-11-a)$$

$$\varphi_{n,t} \in \{0, 1\}, \forall n \in \mathcal{N}, t \in \mathcal{N}_t, \quad (9-11-b)$$

$$\varphi_{n,t} \in \{0, 1\}, \forall n \in \mathcal{N}, t \in \mathcal{N}_t, \quad (9-11-c)$$

其中，公式9-11-a表示。

$$H_j = \text{Concat}(\text{GAP}(F_j), \text{GMP}(F_j)), \quad (9-12)$$

$$\tilde{H}_{j-1,j} = \text{Concat}(H_{j-1}, H_j), j = 5, \quad (9-13)$$

$$p_c^{(i)} = \text{Softmax}(\mathbf{P}_\theta(\tilde{H}_{j-1,j})), \quad (9-14)$$

定理和证明环境说明：如”定理”使用小四黑体，编号随章节变化重新编号（如定理 4-1），定理内容使用小四宋体，且内容行距与正文一致；”证明”无需编号，且以黑色小方块结尾。

定理 9-1 开始定理。。。

证明 开始证明。。。 

第 10 章 参考文献插入示例

第 11 章 总结与展望

纯数字编号

1. XXXXXXXXXXXX
2. XXXXXXXXXXXX
3. XXXXXXXXXXXX

罗马编号

- (i) XXXXXXXXXXXX
- (ii) XXXXXXXXXXXX
- (iii) XXXXXXXXXXXX

括号编号

- (1) XXXXXXXXXXXX
- (2) XXXXXXXXXXXX
- (3) XXXXXXXXXXXX

半括号编号

- 1) XXXXXXXXXXXX
- 2) XXXXXXXXXXXX
- 3) XXXXXXXXXXXX

小字母编号

- a) XXXXXXXXXXXX
- b) XXXXXXXXXXXX
- c) XXXXXXXXXXXX

引用测试, 正如1、(i)、(1)、1)、a)所示

11.1 工作展望

手动编号

本课题针对 XX, 鉴于 XXX, 对 XX 进行了提高, 但是 XXX, 所以有如下 XX:

- (1) 目前 XX 虽然 XX, 但是 XX 仍然 XX, 所以 XX 仍然是一个值得 XX 的问题。
- (2) 随着 XX, XX 具有 XX 的问题, 仍值得进一步 XX。
- (3) 本课题在 XX 有了 XX, 但是 XX 的 XX 还存在 XX, 所以 XX。

参考文献

- [1] Ho Y H, Cheng J H, Kuan S Y, et al. Rt-pose: A 4d radar tensor-based 3d human pose estimation and localization benchmark [C]//European Conference on Computer Vision. Springer, 2024: 107-125.
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems. 2017.
- [3] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [J]. arXiv preprint arXiv:2010.11929, 2020.
- [4] Martinez J, Hossain R, Romero J, et al. A simple yet effective baseline for 3d human pose estimation [C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2640-2649.
- [5] Lutz S, Blythman R, Ghosal K, et al. Jointformer: Single-frame lifting transformer with error prediction and refinement for 3d human pose estimation [C]//2022 26th International Conference on Pattern Recognition (ICPR). IEEE, 2022: 1156-1163.
- [6] Jiang T, Xie X, Li Y. Rtmw: Real-time multi-person 2d and 3d whole-body pose estimation [J]. arXiv preprint arXiv:2407.08634, 2024.
- [7] Zhang Y, Cai J, Chen S, et al. Mobidepthpose: Efficient depth-aware 3d human pose estimation in videos [C]//European Conference on Computer Vision (ECCV). 2022: 165-182.
- [8] Lu Y, Li Y, Zhang L, et al. Rtmw: Towards high-performance one-stage real-time multi-person pose estimation [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 8583-8592.
- [9] Hirschmuller H. Accurate and efficient stereo processing by semi-global matching and mutual information [C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05): volume 2. IEEE, 2005: 807-814.
- [10] Shamsafar F, Woerz S, Rahim R, et al. Mobilestereonet: Towards lightweight deep networks for stereo matching [C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2022: 2417-2426.

附录 A （附录名称）（三号黑体，加粗）（必要时）

附录正文……（格式参考正文）。换行示例。

攻读学位期间主要的研究成果

一、学术论文

- [1] **Daxia Mou**, Director, Someone. CSU Latex Template[J]. CSU player: 1(1):1-10. **(SCI 检索, JCR 1 区)**
- [2] Director, **Daxia Mou**, Someone, Someother. XXXXXX[J]. Transactions on Image Processing. **(SCI Under Review, JCR 1 区)**
- [3] Director, **Daxia Mou**, Someone, Someother. XXXXXX[J]. Transactions on Circuits and Systems for Video Technology. **(SCI Under Review, JCR 1 区)**

二、发明专利

- [1] 某大侠, XXX, XXX. 一种用 Latex 写中南大学学位论文的方法. 申请号: CN20190415xxxx, 公开号: CNXXXXXXXXXA

三、主持和参与的科研项目

- [1] 国家自然科学基金面上项目《XXXXXXXXXXXXX》,项目编号:XXXXXXXX, 参与.

四、个人获奖情况

- [1] XX 金奖
- [2] XX 奖学金

致 谢

作者对给予指导、各类资助和协完成研究工以及提供种论文有作者对给予指导、各类资助和协完成研究工以及提供种论文有利条件的单位及个人表示感谢。

致谢应实事求是，切忌浮夸与庸俗之词。