

硕士学位论文

中南大学研究生学位论文 LaTeX 模板

LaTeX Template of Postgraduate Thesis of
Central South University

专业学位类别	电子信息
专 业 领 域	电子信息
作 者 姓 名	韦康琦
指 导 教 师	张德宇

2026 年 4 月

中图分类号 TP391
UDC 004.9

学校代码 10533
学位类别 专业学位

硕士学位论文

中南大学研究生学位论文 LaTeX 模板

LaTeX Template of Postgraduate Thesis of Central South University

作 者 姓 名	韦康琦
专业学位类别	电子信息
专 业 领 域	电子信息
研 究 方 向	人工智能
二级培养单位	计算机学院
指 导 教 师	张德宇
副 指 导 教 师	

论文答辩日期_____ 答辩委员会主席_____

中 南 大 学
2026 年 4 月

学位论文原创性声明

本人郑重声明，所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了论文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中南大学或其他教育机构的学位或证书而使用过的材料。与我共同工作的同志对本研究所作的贡献均已在论文中作了明确的说明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

学位论文作者签名：_____ 日期：_____ 年 ____ 月 ____ 日

学位论文版权使用授权书

本学位论文作者和指导教师完全了解中南大学有关保留、使用学位论文的规定：即学校有权保留并向国家有关部门或机构送交学位论文的复印件和电子版，允许本学位论文被查阅和借阅。本人授权中南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索和公开传播，可以采用复印、缩印或其它手段保存和汇编学位论文。本人同意按《中国优秀博硕士学位论文全文数据库出版章程》规定享受相关权益。本人保证：毕业后以学位论文内容发表的论文作者单位注明中南大学；学位论文电子文档的内容和纸质学位论文的内容相一致。

延缓公开论文延缓到期后适用本授权书，涉密论文在解密后适用本授权书。

本学位论文属于：（请在以下相应方框内打“√”）

☐ 公开

☐ 延缓公开，延缓期限（____ 年 ____ 月 ____ 日至 ____ 年 ____ 月 ____ 日）

学位论文作者签名：_____ 指导教师签名：_____

日期：_____ 年 ____ 月 ____ 日 日期：_____ 年 ____ 月 ____ 日

（填写阿拉伯数字）

中南大学研究生学位论文 LaTeX 模板

摘要： 随着人工智能与计算机视觉技术的飞速发展，人体姿态估计（Human Pose Estimation, HPE）作为连接数字世界与物理世界的关键纽带，已在众多领域展现出巨大的应用价值。该技术旨在从图像或视频中定位人体关键点（如肩、肘、腕、膝等）并构建骨架结构，广泛应用于人机交互、虚拟现实/增强现实（VR/AR）、智慧医疗康复、体育动作分析以及智能安防监控等场景。特别是在医疗康复领域，通过精确捕捉患者的运动轨迹，系统能够量化评估肢体功能，辅助医生制定个性化的治疗方案。

尽管基于深度学习的二维（2D）人体姿态估计技术已趋于成熟，但其仅能提供平面位置信息，缺乏深度维度，难以全面反映人体在三维空间中的真实姿态与运动细节，限制了其在复杂交互场景下的应用潜力。相比之下，三维（3D）人体姿态估计能够恢复人体关节的空间坐标，提供更丰富的运动学信息。然而，直接从单目图像恢复 3D 姿态本质上是一个不适定问题（Ill-posed Problem），面临着严重的深度歧义性，即多种三维姿态可能投影为相同的二维图像，导致在遮挡或复杂背景下估计精度大幅下降。为了解决这一难题，双目立体视觉（Binocular Stereo Vision）技术通过模拟人类双眼感知机制，利用左右视图的视差原理和三角测量几何约束，能够提供明确的深度线索，从而有效消除深度模糊，显著提升三维重建的精度与鲁棒性。

然而，随着物联网（IoT）与边缘计算的兴起，将高精度的 3D 姿态估计模型部署至移动端或嵌入式设备（如智能手机、无人机、XR 眼镜）已成为行业迫切需求。现有的高性能 3D 姿态估计模型（如基于 Transformer 或复杂 3D 卷积的网络）通常伴随着巨大的参数量和计算开销（FLOPs），对设备的算力、存储空间和功耗（SWaP）提出了极高要求。传统的双目立体匹配算法往往需要构建高维代价体（Cost Volume），消耗大量显存与带宽，导致在资源受限的边缘设备上难以满足实时性要求，甚至无法运行。此外，移动端硬件（如 NPU/DSP）通常对特定算子支持有限，直接部署复杂大模型面临着推理延迟高、能效比低等严峻挑战。

因此，如何在保证双目 3D 姿态估计精度的前提下，设计轻量化、高效率的网络架构，并结合模型压缩技术实现边缘端的高效部署，是

当前学术界与工业界亟待解决的关键问题。一方面，研究者开始探索通过改进网络结构（如引入深度可分离卷积、轻量化注意力机制）来降低计算冗余；另一方面，知识蒸馏和模型量化等技术被广泛证明是在不显著牺牲精度的前提下压缩模型体积、加速推理的有效手段。开展面向资源受限设备的轻量化双目 3D 人体姿态估计研究，不仅具有重要的学术理论意义，更能推动智能感知技术在移动终端的广泛落地与普惠应用。

图 36 幅，表 24 个，参考文献 22 篇

关键词：中南大学；学位论文；LaTeX 模板

分类号：TP391

LaTeX Template of Postgraduate Thesis of Central South University

Abstract: LaTeX can be compiled into a pdf of uniform format using the set template. At present, most domestic publishers and universities still use word. Because of its powerful function and flexibility, when faced with fixed-form papers by novices, simple matters such as typesetting, numbering, and reference documents will bring many difficulties and troubles. For some problems that need to be modified throughout, to achieve the efficiency of LaTeX, it requires a high level of skill for word users.

In order to focus on the writing of papers, many international journals and universities support the writing and submission of LaTeX. Novices don't need to care about formatting issues. They only need to use a few symbolic labels step by step to get the documents that meet the requirements. And when you need to modify the entire format, you can directly recompile the template file by replacing or modifying the template file. This is incredible for the word novice to use the word.

The purpose of this project is to create a TeX template that meets the specifications of the graduate degree thesis (PhD) of Central South University, and to address the pain points of format adjustment during the dissertation writing.

Keywords: CSU; LaTeX; Template

Classification: TP391

目 录

摘要	I
ABSTRACT	III
目录	IV
插图索引	VII
表格索引	IX
符号说明	XI
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 双目 3D 人体数据集	3
1.2.2 3D 多人人体姿态估计	4
1.2.3 双目深度估计研究现状	6
1.2.4 模型轻量化与压缩研究现状	7
1.3 研究内容	7
1.4 论文组织结构	8
第 2 章 相关技术与理论介绍	9
2.1 深度学习基础	9
2.1.1 卷积神经网络	9
2.1.2 Transformer 架构	11
2.2 人体姿态估计相关理论	13
2.2.1 人体姿态估计概述	13
2.2.2 关键点表示方法	14
2.2.3 二维人体姿态估计范式	15
2.2.4 三维人体姿态估计方法与坐标口径	16
2.2.5 数据集与评价指标	17
2.3 双目立体视觉原理	19
2.3.1 双目立体视觉成像模型	19

2.3.2	极线几何与立体校正	20
2.3.3	视差与深度恢复（三角测量）	21
2.3.4	误差来源与工程要点	22
2.4	轻量化网络设计	22
2.4.1	结构轻量化设计	22
2.4.2	模型压缩	23
2.4.3	端侧部署工程优化	24
2.5	本章小结	24
第 3 章	基于双目相机的轻量化 3D 人体姿态检测网络设计	26
3.1	研究背景	26
3.2	问题分析	27
3.2.1	单目人体姿态估计的尺度模糊问题	27
3.2.2	多目人体姿态估计的问题	28
3.2.3	现有基于双目人体姿态估计的问题	29
3.3	轻量化非对称双目学习框架与网络结构设计	33
3.3.1	整体框架与端到端流程	34
3.3.2	非对称双目骨干网络设计	35
3.3.3	极线特征增强模块	36
3.3.4	可微加权三角化姿态求解器	38
3.3.5	跨分支表征一致性约束与损失函数	43
3.4	实验评估	45
3.4.1	实验设置	45
3.4.2	实验结果	47
3.4.3	消融实验	50
3.5	本章小结	55
第 4 章	硬件感知部署与量化压缩	56
4.1	研究背景	56
4.2	问题分析	56
4.2.1	端侧推理瓶颈的实测分析	56
4.2.2	Roofline 分析：访存密集型与计算密集型模块辨别	58
4.2.3	量化敏感性分析	61

4.3 混合精度量化方案设计	62
4.3.1 分层精度分配方案	62
4.3.2 后训练量化实施	63
4.4 实验评估	64
4.4.1 实验设置	64
4.4.2 量化方案对比	65
4.4.3 消融实验：精度敏感层的必要性验证	65
4.4.4 多人场景量化稳定性分析	66
4.5 本章小结	67
第 5 章 总结与展望	67
5.1 总结	67
5.2 展望	67
第 6 章 图像布局	68
6.1 单图布局	68
6.2 横排布局	68
6.3 竖排布局	68
6.3.1 竖排多图横排布局	68
6.3.2 横排多图竖排布局	69
6.4 本章小结	69
第 7 章 表格插入示例	70
第 8 章 算法示例	71
第 9 章 公式、定理、证明插入示例	72
第 10 章 参考文献插入示例	74
第 11 章 总结与展望	75
11.1 工作展望	75
参考文献	76
附录 A（附录名称）（三号黑体，加粗）（必要时）	78
攻读学位期间主要的研究成果	79
致 谢	80

插图索引

图 1-1 机器人與人交互场景下多人三维人体姿态感知的重要性示意	1
图 1-2 典型端侧平台中的双目相机应用场景示例（红框标识双目模组） . .	2
图 1-3 RT-Pose 数据集样例帧	3
图 1-4 双目激光雷达收集数据的设备示例	4
图 1-5 系统整体结构示意图。第三章聚焦模型设计与训练，构建轻量化双目 3D 姿态检测网络；第四章面向端侧落地，开展硬件感知部署与量化压缩。	8
图 2-1 典型卷积神经网络架构示意图。网络由卷积层、激活函数、池化层与全连接层依次堆叠，逐层提取从低级边缘纹理到高级语义特征的层次化表征。	9
图 2-2 卷积层操作示意图。卷积核在输入特征图上滑动，通过局部连接与权值共享提取局部特征，生成输出特征图。	10
图 2-3 三种常见激活函数曲线	11
图 2-4 池化层操作示意图。	11
图 2-5 Transformer 中注意力机制与结构示意图（从左至右依次为缩放点积注意力、多头注意力与 Transformer 整体结构）。	12
图 2-6 基于热图的人体姿态估计示意图。左：输入图像；中：网络输出的关节概率热图，亮色区域对应各关节点的高响应位置；右：依据热图峰值解码得到的骨架关键点检测结果。	15
图 2-7 二维多人姿态估计的两类主流范式对比。	15
图 2-8 三维人体姿态估计的两类主流方法示意图。	16
图 2-9 典型的人体关节点骨架示意图	17
图 2-10 双目对极几何示意图。 C_l 、 C_r 为左右相机光心， $\mathbf{X}$ 为空间三维点； l_l 、 l_r 为对应极线， e_l 、 e_r 为对极点；三点 C_l 、 C_r 、 $\mathbf{X}$ 所确定的平面为对极平面，其与成像平面的交线即为对应极线。	20
图 2-11 双目视差与三角测量几何示意图	21
图 3-1 单目三维人体姿态估计的尺度模糊示意图	28
图 3-2 多视角多相机场景示意图	29
图 3-3 基于稠密深度先验的双目两阶段三维人体姿态估计流程示意图	30
图 3-4 基于左右对称双分支结构的双目人体姿态估计流程示意图	32
图 3-5 左右视图热力图对比：响应分布高度重叠，提示双全量骨干的计算冗余	32

图 3-6	本文轻量化非对称双目三维人体姿态估计框架整体流程图.....	34
图 3-7	非对称双目骨干网络结构示意图。左侧展示两分支从输入到多尺度特征输出的各阶段通道配置；右侧展示单个 CSP Block 中“直传路径 + Bottleneck 堆叠 → Concat → 融合”的内部数据流。.....	36
图 3-8	极线交叉注意力计算示意图：右视图特征作为查询，左视图特征作为键和值，沿水平极线在视差窗口内计算权重并对值加权聚合。.....	37
图 3-9	极线注意力与加权聚合过程示意图.....	38
图 3-10	RT-Pose 数据集上的定性可视化结果示例（红色骨架为真值，其他颜色骨架为预测结果）。.....	49
图 3-11	端侧推理时延随人数变化的对比（Xiaomi 14/MNN/FP16/4 线程端侧测量）。.....	50
图 4-1	各模块端到端延迟占比（Xiaomi 14, MNN/FP16/CPU 4 线程，单人场景）.....	57
图 4-2	CSPDarknet 双分支各阶段延迟占比（FLOPs 比例估算）。左：CSPDarknet-M（左分支，width=1.0，共 76.7 ms）；右：CSPDarknet-N（右分支，width=0.5，共 19.4 ms）。.....	58
图 4-3	骁龙 8 Gen3 CPU 各模块 Roofline 分析（FP16, 4 线程，batch=1）。空心点为理论可达点，实心点为实测工作点（按比例时延估算）；括号为相对理论上限的利用率。屋脊点为 2.5 FLOP/byte：左侧为访存密集区，右侧为计算密集区。.....	60
图 4-4	混合精度量化 PTQ 部署流程。从 PyTorch 训练模型出发，经 ONNX 导出、mnncconvert 图优化（Conv-BN 融合 + INT8 per-channel 权重量化 + 豁免层配置）生成 model_mixed.mnn，最终在 Xiaomi 14 真机上验证推理延迟；DWT 求解器以旁路 FP32 脚本形式运行，不经过 ONNX/MNN 量化路径。.....	64
图 6-1	单图布局示例.....	68
图 6-2	横排布局示例.....	68
图 6-3	竖排布局示例.....	69
图 6-4	竖排多图横排布局.....	69
图 6-5	横排多图竖排布局，斜体 <i>emph A</i> , <i>A</i> , 斜体 <i>text A</i>	69

表格索引

表 2-1	COCO[1]、MPII[2] 与 Human3.6M[3] (常用 17 点) 关节索引对照表	18
表 3-1	非对称双目骨干网络两分支各阶段输出通道数配置对比。步幅 s 表示特征图相对于输入图像的下采样倍数。	35
表 3-2	RT-Pose 数据集与标定信息 (本文使用项)	46
表 3-3	RT-Pose 数据集上的实验对比结果 (数据来自公开 benchmark)。单目方法仅使用左视图 I_l ; 两阶段双目方法遵循基于稠密深度先验的级联范式 (先估计稠密深度/视差, 再结合二维关键点回代/融合得到三维姿态); 本文方法在双目输入下端到端预测三维关节。所有 MPJPE 为左相机坐标系下的绝对 MPJPE (mm)。 [†] 标记的方法依赖传统立体匹配算法 (SGBM), 其参数量与 FLOPs 仅统计神经网络部分, 不含 SGBM 的运行时开销。	48
表 3-4	跨数据集泛化结果: 在 RT-Pose 上训练后直接在 MADS 上测试 (零样本), 仅报告整体平均 MPJPE (mm)。	48
表 3-5	不同人数下的端到端推理时延对比 (ms)。	51
表 3-6	核心模块贡献汇总: 各模块对 Avg MPJPE 的独立贡献 (RT-Pose 测试集; 每行仅替换单一模块, 其余保持本文默认)。	51
表 3-7	非对称双目骨干网络 (左重右轻) 消融 (RT-Pose 测试集)。	52
表 3-8	不同跨视图特征交互方式的对比 (RT-Pose 测试集)。	52
表 3-9	极线特征增强模块的视差搜索范围 $D_{\max}$ 敏感性分析 (RT-Pose 测试集; $D_{\max}$ 以 EFEM 所在特征图坐标计)。	53
表 3-10	不同三维恢复策略对比 (RT-Pose 测试集)。	53
表 3-11	可微加权三角化姿态求解器的组件级消融 (RT-Pose 测试集)。	54
表 3-12	跨分支一致性约束形式对比 (RT-Pose 测试集)。	54
表 3-13	跨分支一致性约束权重系数 λ_{align} 敏感性分析 (RT-Pose 测试集)。	54
表 4-1	本文框架各模块在 Xiaomi 14 (MNN/FP16/CPU 4 线程) 上的实测延迟 (单人场景)	57
表 4-2	骁龙 8 Gen3 存储层次参数 (推理阶段相关性分析)	59
表 4-3	各模块算术强度与瓶颈类型 (Roofline 分析, FP16, batch=1)	60
表 4-4	各模块 INT8 量化敏感性分析 (与 FP16 基线相比, RT-Pose 验证集)	62
表 4-5	本文分层混合精度量化方案	63
表 4-6	后训练量化 (PTQ) 关键配置 (本文混合精度, weight-only)	64

表 4-7 不同精度配置的精度-效率综合对比(RT-Pose 验证集,Xiaomi 14/MNN, 单人场景)	65
表 4-8 精度敏感层消融实验——将各保护层替换为 INT8 的精度代价(RT- Pose 验证集)	66
表 4-9 量化前后多人场景端到端延迟对比(Xiaomi 14/MNN/4 线程, 单位: ms)	66
表 7-1 表格为三线表斜体 <i>emph A</i> , <i>A</i> , 斜体 <i>text A</i>	70

符号说明

符号	意义	单位（量纲）
频率	赫 [兹]	Hz

第 1 章 绪论

1.1 研究背景与意义

随着人工智能与计算机视觉技术的飞速发展，人体姿态估计（Human Pose Estimation, HPE）作为连接数字世界与物理世界的关键纽带，已在众多领域展现出巨大的应用价值。该技术旨在从图像或视频中定位人体关键点（如肩、肘、腕、膝等）并构建骨架结构，广泛应用于人机交互、虚拟现实/增强现实（VR/AR）、智慧医疗康复、体育动作分析以及智能安防监控等场景。特别是在医疗康复领域，通过精确捕捉患者的运动轨迹，系统能够量化评估肢体功能，辅助医生制定个性化的治疗方案。如图 1-1 所示，机器人与人交互场景通常同时存在多目标与遮挡，因而对多人三维姿态的实时感知提出更高要求。



图 1-1 机器人与人交互场景下多人三维人体姿态感知的重要性示意

尽管基于深度学习的二维（2D）人体姿态估计技术已趋于成熟，但其仅提供平面位置信息，缺乏深度维度，难以全面反映人体在三维空间中的真实姿态与运动细节，限制了其在复杂交互场景下的应用潜力。相比之下，三维（3D）人体姿态估计能够恢复人体关节的空间坐标，提供更丰富的运动学信息。然而，直接从单目图像恢复 3D 姿态本质上是一个不适定问题（Ill-posed Problem），面临着严重的深度歧义性，即多种三维姿态可能投影为相同的二维图像，导致在遮挡或复杂背景下估计精度大幅下降。为了解决这一难题，双目立体视觉（Binocular

Stereo Vision) 技术通过模拟人类双眼感知机制, 利用左右视图的视差原理和三角测量几何约束, 能够提供明确的深度线索, 从而有效消除深度模糊, 显著提升三维重建的精度与鲁棒性。

然而, 随着物联网 (IoT) 与边缘计算的兴起, 将高精度的 3D 姿态估计模型部署至移动端或嵌入式设备 (如智能手机、无人机、XR 眼镜) 已成为行业迫切需求。现有的高性能 3D 姿态估计模型 (如基于 Transformer 或复杂 3D 卷积的网络) 通常伴随着巨大的参数量和计算开销 (FLOPs), 对设备的算力、存储空间和功耗 (SWaP) 提出了极高要求。传统的双目立体匹配算法往往需要构建高维代价体 (Cost Volume), 消耗大量显存与带宽, 导致在资源受限的边缘设备上难以满足实时性要求, 甚至无法运行。此外, 移动端硬件 (如 NPU/DSP) 通常对特定算子支持有限, 直接部署复杂大模型面临着推理延迟高、能效比低等严峻挑战。如图 1-2 所示, 双目相机在移动端与机器人等平台中具有广泛应用 (红框标识双目模组), 进一步凸显本文选题的工程价值。




图 1-2 典型端侧平台中的双目相机应用场景示例 (红框标识双目模组)

因此, 如何在保证双目 3D 姿态估计精度的前提下, 设计轻量化、高效率的网络架构, 并结合模型压缩技术实现边缘端的高效部署, 是当前学术界与工业界亟待解决的关键问题。一方面, 研究者开始探索通过改进网络结构 (如引入深度可分离卷积、轻量化注意力机制) 来降低计算冗余; 另一方面, 知识蒸馏和模型量化等技术被广泛证明是在不显著牺牲精度的前提下压缩模型体积、加速推理的有效手段。开展面向资源受限设备的轻量化双目 3D 人体姿态估计研究, 不仅具有重要的学术理论意义, 更能推动智能感知技术在移动终端的广泛落地与普惠应用。

1.2 国内外研究现状

本章节将综述双目 3D 人体姿态估计领域的国内外研究现状, 重点分析现有方法的技术路线、优势与不足, 并探讨模型轻量化与压缩技术在该领域的应用进展。

1.2.1 双目 3D 人体数据集

RT-Pose^[4] (Radar Tensor-based 3D Human Pose Estimation Benchmark) 是由 Ho 等人在 ECCV 2024 上发布的一个新兴多模态 3D 人体姿态估计与定位基准数据集。与传统仅依赖视觉图像的数据集不同, RT-Pose 旨在解决隐私保护和遮挡场景(如穿墙识别)下的姿态估计难题, 因此引入了毫米波雷达作为核心模态。



图 1-3 RT-Pose 数据集样例帧

该数据集具有以下显著特征:

1. 多模态数据同步: RT-Pose 包含同步采集的 4D 雷达张量 (Radar Tensors)、激光雷达点云 (LiDAR Point Clouds) 以及 RGB 图像。其中, 4D 雷达张量提供原始的时空信息, 高精度 3D 骨架标签则通过联合标定 RGB 图像与 LiDAR 点云生成, 确保标注准确性。
2. 数据规模与多样性: 数据集共包含 7.2 万帧数据, 跨越 240 个序列, 涵盖 6 种不同复杂度的动作类型。相比实验室环境下的数据集 (如 Human3.6M), RT-Pose 采集于更复杂的现实世界场景, 包含光照变化与背景干扰。
3. 基线算法: 该工作同时提出 HRRadarPose 算法, 这是首个在 3D 空间中提取 4D 雷达张量高分辨率表示的单阶段架构, 在基准测试中取得了 9.91 cm (约 99.1 mm) 的 MPJPE。

1.2.1.1 在本研究中的应用

尽管 RT-Pose 的初衷是推动雷达辅助的姿态估计，但本研究主要关注资源受限边缘设备上的纯视觉解决方案。考虑到移动端与物联网设备通常不具备昂贵的 LiDAR 或高带宽雷达传感器，而双目摄像头较为普及，本文将 RT-Pose 作为一个高难度真实场景测试基准。具体而言，本文仅使用 RT-Pose 中的双目 RGB 图像作为输入进行训练与评估。由于该数据集的场景复杂度远高于传统室内数据集，且包含大量非受控环境下的动作，利用其进行测试能够有效验证本文提出的轻量化双目三维人体姿态估计框架在去除雷达辅助情况下，仅凭双目视觉算法在复杂现实场景（in-the-wild）中的鲁棒性与泛化能力。

1.2.1.2 MADS 数据集

为进一步验证算法在复杂动作与不同采集协议下的泛化能力，Zhang 等人提出了 Martial Arts, Dancing and Sports (MADS) 数据集^[5]。该数据集包含具有强自遮挡、快速旋转与大幅肢体运动的动作序列，覆盖武术（太极、空手道）、舞蹈（Hip-hop、Jazz）与多类体育组合动作；同时提供多视角 RGB 视频与基于双目深度相机采集的深度序列，并通过运动捕捉系统给出同步、标定一致的三维骨架真值。相较常见室内基准，MADS 的动作幅度更大、姿态多样性更强，可用于检验方法对极端肢体展开与遮挡条件的鲁棒性。




图 1-4 双目激光雷达收集数据的设备示例

1.2.2 3D 多人人体姿态估计

1.2.2.1 单目 3D 人体姿态估计

近年来，单目 3D 人体姿态估计领域取得了显著进展，从估计深度方向可以分为直接回归法和 2D 提升法。从估计关键点角度来看，又可以分为自顶向下和自底向上两大类方法。

(1) 基于自顶向下的直接回归方法

最早, Kanazawa 等人提出了开创性的 HMR (CVPR 2018), 主张利用对抗训练 (GAN) 将图像特征直接映射为 SMPL 参数, 确立了“检测-裁剪-回归”的经典范式; 随后, Kolotouros 等人在 SPIN (ICCV 2019) 中提出了将迭代优化算法嵌入神经网络训练循环的思想, 利用 2D 关键点的几何约束大幅提升了模型贴合度。然而, 针对上述方法中“裁剪操作导致透视丢失”的固有缺陷, Li 等人提出了 CLIFF (ECCV 2022), 主张将检测框的全局位置信息重新注入网络以感知相机视锥。到了 2025 年, Jin 等人进一步提出了 PersPose (ICCV 2025), 通过构建显式的透视编码 (Perspective Encoding) 和旋转变换矩阵, 强制网络模拟相机内参对人体形态的影响, 从而在不依赖相机参数真值的情况下, 彻底解决了广角镜头边缘的人体畸变问题。

(2) 基于自顶向下的 2D 提升方法

在利用 2D 关键点恢复 3D 的路径上, Pavllo 等人首先提出了 VideoPose3D (CVPR 2019), 证明了利用时序卷积网络 (TCN) 聚合视频前后帧信息, 足以解决单帧预测的深度歧义与抖动; 紧接着, Zheng 等人提出了 PoseFormer (ICCV 2021), 将 Transformer 的注意力机制引入该领域, 极大地增强了模型对长序列动作的捕捉能力。为了解决 Transformer 计算复杂度过高的问题, Zhu 等人在 PoseMamba (ArXiv 2024 / CVPR 2025 pending) 中提出了利用状态空间模型 (SSM) 替代注意力机制, 通过 Mamba 架构特有的线性复杂度特性, 实现了在极低显存占用下对数千帧超长序列的实时推理, 成为当前长序列建模的新基准。

(3) 基于自底向上的直接回归方法

为了解决多人拥挤场景下的检测难题, Sun 等人提出了 ROMP (ICCV 2021), 主张抛弃检测框, 利用像素级的中心热力图 (Center Map) 直接回归多人的 Mesh 参数, 实现了推理速度与人数无关的特性。针对拥挤人群中特征混淆的顽疾, Li 等人在 NIKI (CVPR 2024) 中提出了基于可逆神经网络 (Invertible Neural Networks) 的生成式框架, 他们认为传统的回归方法只能输出单一均值, 无法处理严重遮挡下的多模态解, 因此通过双射变换将图像特征映射到潜在分布, 成功实现了在极度拥挤场景下对交肢体体的精准解耦与重建。

(4) 基于自底向上的 2D 提升方法

早期, Bertoni 等人提出了 MonoLoco (ICCV 2019), 利用 2D 关键点的高度与肩宽比率来推算 3D 绝对距离, 主要服务于自动驾驶中的行人定位。近年来, 为了应对多视角监控中数据不同步和噪声大的挑战, 研究团队提出了 SyncDiffPose

(AAAI 2025)，通过引入扩散模型（Diffusion Model）的去噪机制，将时间未对齐导致的 2D 误差视为噪声，利用扩散逆过程从嘈杂的观测中“生成”出符合物理规律的同步 3D 姿态序列，为低成本监控环境下的高精度捕捉提供了全新的解决方案。

1.2.3 双目深度估计研究现状

1.2.3.1 基于手工特征的方法

传统双目立体匹配算法通常基于多视图几何原理，依赖人工设计的特征描述符与代价函数来计算视差，主要分为局部匹配（Local Methods）、全局匹配（Global Methods）以及半全局匹配（Semi-Global Matching, SGM）三大类。局部方法如块匹配算法（Block Matching, BM），通过在左右视图的局部窗口内计算灰度差绝对值和（SAD）或归一化互相关（NCC）来寻找对应点，其计算效率高但难以处理弱纹理、重复纹理及深度不连续区域，匹配精度有限。全局方法如图割（Graph Cuts）和置信度传播（Belief Propagation），通过构建包含数据项和平滑项的全局能量函数并进行最小化求解，虽然精度较高，但计算复杂度巨大，难以满足实时性需求。作为两者的折中方案，由 Hirschmüller 提出的 SGM 算法是该领域的里程碑，它通过沿多个方向（通常为 8 或 16 个方向）进行一维路径代价聚合来近似二维全局能量最小化，在保证效率的同时显著提升了对遮挡和物体边缘的处理能力，被广泛应用于工业界。此外，针对前向平行窗口假设的局限性，PatchMatch Stereo 算法引入了倾斜支持窗口（Slanted Support Windows）和随机搜索策略，有效提升了倾斜表面的重建精度。

1.2.3.2 基于深度学习的方法

随着卷积神经网络（CNN）的兴起，双目深度估计进入了端到端学习时代，主要经历了从基于匹配代价计算的 CNN 到基于 3D 卷积的代价体回归，再到基于迭代优化和 Transformer 架构的演进。早期的 MC-CNN 利用 CNN 替代手工特征计算匹配代价，显著提升了相似度度量的准确性。随后，GC-Net 和 PSMNet 开创了使用 4D 代价体配合 3D 卷积神经网络进行正则化的范式，其中 PSMNet 引入的空间金字塔池化（SPP）和堆叠沙漏结构能有效捕获全局上下文信息，成为该领域的重要基准，但其高昂的显存和计算开销限制了在边缘设备的部署。为了降低计算成本，GwcNet 提出了分组相关（Group-wise Correlation）策略来构建高效的代价体。近年来，受到光流算法 RAFT 的启发，RAFT-Stereo 和 IGEV-Stereo 等方法采用了基于 GRU 的迭代优化策略，通过循环神经网络逐步细化视差场，展现了优异的跨域泛化能力。此外，Transformer 架构也被引入该领域（如 STTR），

利用自注意力机制处理长距离依赖和遮挡问题，将立体匹配建模为序列到序列的对应任务。针对移动端应用，MobileStereoNet、CoEx 和 LightStereo 等轻量化网络则通过使用 2D 卷积替代 3D 卷积或设计高效的代价聚合模块，在保持精度的同时实现了实时推理。

1.2.4 模型轻量化与压缩研究现状

1.2.4.1 轻量化结构设计

面向端侧部署的轻量化研究通常首先从网络结构入手，通过减少冗余计算与降低高维特征张量的规模来获得更低的时延与更小的内存占用。典型做法包括使用深度可分离卷积、倒残差与线性瓶颈等高效模块替代标准卷积；在多尺度特征融合中控制高分辨率分支的通道宽度与融合路径数量；在注意力与 Transformer 结构中采用局部窗口、分层结构或低秩/稀疏近似来降低全局自注意力的二次复杂度。对于双目任务而言，结构轻量化的关键还在于避免构建高分辨率、全视差范围的代价体，并通过相关/分组相关与迭代细化等方式将跨视图匹配计算转化为更紧凑、更算子友好的形式。

1.2.4.2 模型压缩与加速

除结构设计外，模型压缩技术为端侧落地提供了另一条重要路径。剪枝通过移除冗余通道、卷积核或注意力头来降低计算量，其中结构化剪枝更有利于获得真实加速；量化将权重与激活映射到低比特表示（如 INT8），可显著降低内存带宽需求并提升硬件利用率；知识蒸馏通过引入教师网络的软标签或中间特征约束，在不显著增加推理开销的前提下提升轻量模型精度。实际部署中，这些方法常与硬件友好算子选择、算子融合与编译优化联合使用，以获得更稳定的端侧加速收益。

1.3 研究内容

围绕资源受限设备上的双目 3D 人体姿态估计问题，本文主要研究内容包括：

- 构建轻量化双目 3D 人体姿态估计框架，研究左右视图特征提取、跨视图信息交互与三维关节点回归的整体流程。
- 设计面向端侧部署的高效网络结构，在保证姿态估计精度的前提下，降低参数量、计算量与峰值内存占用，提高实时性与能效比。
- 探索知识蒸馏、量化等模型压缩策略及其与网络结构轻量化的协同方式，分析不同压缩方案对精度与效率的影响。
- 基于复杂真实场景数据集（如 RT-Pose）开展实验评估，验证所提方法在弱纹

理与光照变化等条件下的鲁棒性与泛化能力。

1.4 论文组织结构

第一章为绪论。介绍本文的研究背景与现实意义，分析双目 3D 人体姿态估计在端侧场景中面临的主要挑战，综述国内外相关研究现状，最后阐述本文的研究内容、主要贡献与论文组织结构。

第二章为相关技术与理论介绍。系统梳理本文所依赖的核心理论基础，包括卷积神经网络与 Transformer 注意力机制等深度学习基础，人体姿态估计的任务范式与评价体系，双目立体视觉的成像模型与极线几何约束，以及面向端侧部署的轻量化结构设计与模型压缩策略。

第三章为基于双目相机的轻量化 3D 人体姿态检测网络设计。提出一种轻量化非对称双目学习框架：以“左重右轻”的非对称骨干网络消除左右对称冗余，以极线特征增强模块（EFEM）将跨视图匹配限制在一维极线搜索空间，以可微加权三角化求解器（DWT）实现端到端的三维关节坐标恢复，并通过对比实验与消融实验验证各模块的有效性，如图 1-5 所示。

第四章为硬件感知部署与量化压缩。面向 Snapdragon 8 Gen3 端侧平台，通过延迟拆解与 Roofline 模型定位推理瓶颈，借助量化敏感性分析制定分层混合精度量化方案（骨干 INT8、敏感层 FP16/FP32），经后训练量化（PTQ）流程输出可部署的 MNN 模型，在真机上验证精度保持与推理加速效果。

第五章为总结与展望。对全文研究工作进行系统总结，分析现有方法的局限性，并对后续研究方向提出展望。




图 1-5 系统整体结构示意图。第三章聚焦模型设计与训练，构建轻量化双目 3D 姿态检测网络；第四章面向端侧落地，开展硬件感知部署与量化压缩。

第2章 相关技术与理论介绍

本章围绕双目轻量化三维人体姿态估计的研究主线，系统梳理相关核心理论与关键技术，为方法设计与实验分析提供知识铺垫。全章内容分为四个递进部分：第一，介绍卷积神经网络与 Transformer 注意力机制等深度学习基础，阐述其在视觉特征提取与跨视图信息融合中的作用原理；第二，梳理人体姿态估计的任务范式、关键点表示方法与评价指标体系，明确双目 3D 姿态估计的输出定义与评测标准；第三，阐述双目立体视觉的成像模型与极线几何约束，介绍三角测量深度恢复的基本原理；第四，总结面向端侧部署的轻量化结构设计原则与模型压缩策略，概述在资源受限设备上实现高效推理的主要技术路径。四部分由浅入深、相互支撑，共同构成本文方法设计与部署优化的知识基础。

2.1 深度学习基础

2.1.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是一类特殊设计的深度学习模型，它在计算机视觉领域取得了革命性的成功，尤其擅长处理具有网格状拓扑结构的数据，如图像（2D 网格）和视频（3D 网格）。CNN 的核心思想在于通过模仿生物视觉系统的机制，有效利用图像的空间局部相关性，并通过一系列专门的层级结构来学习和提取从低级到高级的层次化特征。典型的 CNN 架构




图 2-1 典型卷积神经网络架构示意图。网络由卷积层、激活函数、池化层与全连接层依次堆叠，逐层提取从低级边缘纹理到高级语义特征的层次化表征。

主要由以下几种关键层堆叠而成：

2.1.1.1 卷积层 (Convolutional Layer)

卷积层是 CNN 的核心。它使用一组可学习的滤波器（或称为卷积核, Kernel）在输入数据（如图像）上进行滑动窗口式的卷积操作。每个卷积核负责检测一种特定的局部特征，例如边缘、角点、纹理或颜色块。通过卷积操作，可以生成

一个二维的特征图，图中的每个像素代表了其在原始图像对应感受野（Receptive Field）上对该特定特征的响应强度。卷积层有两个非常重要的特性：

- 局部连接: 每个神经元只与输入数据的一个局部区域相连，这大大减少了模型的参数数量，并使网络能专注于学习局部信息。
- 权值共享: 单个卷积核（滤波器）在整个输入图像上共享同一组权重参数。这意味着，网络在图像的一个区域学习到的特征（例如，一个垂直边缘），可以同样被用来检测图像其他区域的相同特征。这赋予了模型平移不变性，进一步降低了模型复杂度。




图 2-2 卷积层操作示意图。卷积核在输入特征图上滑动，通过局部连接与权值共享提取局部特征，生成输出特征图。

2.1.1.2 激活函数

在卷积操作之后，通常会应用一个非线性激活函数以引入非线性，从而打破线性模型的表达上限，使网络能够学习更复杂的映射关系。常见激活函数包括 ReLU、Sigmoid 与 Tanh 等。其中，ReLU (Rectified Linear Unit) 定义为 $f(x) = \max(0, x)$ ，具有计算开销低、在正半轴梯度不易消失等优点，是卷积网络中最常用的选择之一；Sigmoid 函数定义为

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \quad (2-1)$$

其输出范围为 $(0, 1)$ ，常用于概率解释或门控结构，但在 $|x|$ 较大时易进入饱和区导致梯度消失；Tanh 函数定义为

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}, \quad (2-2)$$

其输出范围为 $(-1, 1)$ 且以 0 为中心，相比 Sigmoid 在一定程度上更利于优化，但同样存在饱和导致梯度衰减的问题。

2.1.1.3 池化层

池化层（也称下采样层）通常紧跟在卷积层之后，其主要作用是对特征图进行降维，以减少计算量、降低过拟合风险，并增强模型的泛化能力。最常见的池化操作是最大池化（Max Pooling），它将特征图划分为若干个不重叠的矩形区域，并从每个区域中输出最大值。池化操作在保留最显著特征的同时，也为模型带来了一定程度的旋转和尺度不变性。




图 2-3 三种常见激活函数曲线




图 2-4 池化层操作示意图。

2.1.1.4 全连接层

在经过多层卷积和池化的堆叠，提取出丰富的层次化特征之后，这些特征图通常会被展平（Flatten）成一个一维向量，并输入到一个或多个全连接层中。全连接层的每个神经元都与前一层的所有神经元相连，其作用类似于传统的多层感知机，负责将学习到的分布式特征表示进行整合，并最终映射到任务的输出空间，例如，在分类任务中输出每个类别的概率，或在回归任务（如人体姿态估计）中输出关节点的坐标。

通过这种“卷积-激活-池化”模块的堆叠，CNN 能够自动地、层次化地从原始像素中学习从简单到复杂的视觉模式，使其在图像分类、目标检测、语义分割以及本文所关注的人体姿态估计等任务中表现出色。

2.1.2 Transformer 架构

Transformer 架构最初由 Vaswani 等人在其著名的论文“Attention Is All You Need” [6] 中提出，旨在解决自然语言处理（NLP）中的序列到序列（Seq2Seq）任务。它摒弃了传统的循环神经网络（RNN）和卷积神经网络（CNN）的序列处理方式，完全依赖于注意力机制来捕捉输入和输出序列之间的全局依赖关系。由于其强大的长距离依赖建模能力和并行计算潜力，Transformer 及其变体（如 Vision Transformer, ViT[7]）已被成功应用于计算机视觉领域，并在包括人体姿态估计在内的多项任务中取得了 SOTA（State-of-the-art）性能。

Transformer 的核心是注意力机制，特别是缩放点积注意力（Scaled Dot-Product

Attention), 其计算可概括为以下公式:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-3)$$

其直观计算流程以及多头注意力与 Transformer 整体结构示意图如图 2-5 所示。其




图 2-5 Transformer 中注意力机制与结构示意图 (从左至右依次为缩放点积注意力、多头注意力与 Transformer 整体结构)。

中, Q (查询)、 K (键) 和 V (值) 是由输入序列经过线性变换得到的三个向量。注意力机制通过计算查询与所有键的相似度 (点积), 并对结果进行缩放与 softmax 归一化, 得到一组权重系数。这些权重随后被用于对值向量进行加权求和, 从而得到最终的输出。这个过程可以直观地理解为: 根据“查询”向量 Q , 从一系列“键-值”对 ($K-V$) 中检索信息。一个完整的 Transformer 层通常由一个多头注意力模块和一个前馈神经网络 (Feed-Forward Network) 组成, 每个模块之后都跟随着残差连接 (Residual Connection) 和层归一化 (Layer Normalization)。通过堆叠多个这样的层, Transformer 能够构建起强大的深度模型。

2.1.2.1 自注意力

自注意力是 Transformer 中的一个关键特例, 其中 Q, K, V 均来自同一个输入序列。这意味着序列中的每个元素都会计算与序列中所有其他元素 (包括自身) 的注意力权重, 从而能够动态地、内容感知地捕捉序列内部的依赖关系, 无论它们相隔多远。这与 CNN 的局部感受野形成了鲜明对比。

2.1.2.2 多头注意力

单个注意力头往往只能在一个表示子空间内学习相似性关系, 表达能力受限。为同时建模不同尺度、不同语义子空间的依赖, Transformer 引入多头注意力

(Multi-Head Attention, MHA)：将输入特征分别线性映射为 h 组不同的 Q, K, V ，并在每个头上独立执行缩放点积注意力，再将各头输出拼接并投影回原维度。其形式化定义为

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \quad i = 1, \dots, h, \quad (2-4)$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O, \quad (2-5)$$

其中 W_i^Q, W_i^K, W_i^V, W^O 为可学习参数矩阵。通常取每个头的维度 $d_k = d_{\text{model}}/h$ ，使总计算量与单头注意力同阶。多头机制的优势在于：不同头可并行关注不同位置与关系模式（例如局部细粒度依赖与全局长程依赖），从而提升模型的表达能力与训练稳定性，并为下游任务提供更丰富的特征融合路径。

2.1.2.3 交叉注意力

交叉注意力是连接编码器（Encoder）和解码器（Decoder）的关键桥梁，在标准的 Transformer 架构中至关重要。与自注意力不同，交叉注意力的 Q 向量来自解码器（Decoder）的输出，而 K 和 V 向量则来自编码器（Encoder）的最终输出。具体来说，在解码器的每个步骤中，交叉注意力模块允许解码器“关注”输入序列（即编码器的输出）中与当前生成任务最相关的部分。例如，在机器翻译中，当解码器要生成下一个目标词时，交叉注意力会帮助它定位到源句子中最相关的几个词。在多模态任务（如图像描述生成）或本文涉及的双目视觉任务中，交叉注意力机制同样强大。它可以让一个模态的特征（例如，左视图的特征作为查询）去查询和融合另一个模态的特征（例如，右视图的特征作为键和值），从而实现跨模态、跨视图的信息对齐与有效融合。

综合来看，CNN 擅长捕捉局部纹理与多尺度空间特征，适合作为高效的视觉骨干网络；Transformer 的注意力机制则擅长建立跨位置、跨视图的全局关联。在双目视觉任务中，两类结构相辅相成：CNN 负责从左右视图中提取层次化视觉特征，交叉注意力在此基础上实现跨视图特征对齐与极线约束下的信息融合，两者相辅相成，构成双目视觉理解的常见组合框架。

2.2 人体姿态估计相关理论

2.2.1 人体姿态估计概述

人体姿态估计（Human Pose Estimation, HPE）旨在从图像或视频中定位人体关键点（如肩、肘、腕、髋、膝等），并根据预定义的拓扑连接关系构建人体骨架（Pose Skeleton），从而为动作理解、人机交互、康复评估等下游任务提供结构化的运动学表示。

从任务设定上，HPE 通常可从以下两个维度进行划分：（1）按输出维度：分为 2D 姿态估计（预测关键点平面坐标 (x, y) ）与 3D 姿态估计（预测空间坐标 (x, y, z) 或根相对坐标）。（2）按目标数量：分为单人姿态估计（Single-person）与多人姿态估计（Multi-person）。

实际应用中，多人拥挤与自/互遮挡会导致关键点可见性显著下降，光照与视角变化及复杂背景会带来跨域分布偏移，从而影响关键点定位的鲁棒性；而在 3D 姿态估计中，还存在典型的深度歧义性（Depth Ambiguity）问题，即不同的三维姿态可能投影为相似的二维观测，使得仅凭单目图像恢复绝对深度具有不稳定性。与此同时，端侧部署还受限于算力、访存与时延预算，要求模型在精度与效率之间取得平衡。基于上述动机，本文聚焦于双目提供绝对尺度线索与轻量化网络端侧部署的统一设计。

2.2.2 关键点表示方法

关键点的输出表征直接影响网络结构设计、训练目标与推理开销，常见形式包括：

- 基于坐标回归（Regression-based）：直接从图像特征回归关键点坐标（或其偏移量）。该方法计算简单、推理速度快、后处理开销小，适合端侧部署；但由于需要从高维特征到精确坐标的强非线性映射，通常对训练策略与特征表达要求更高，定位精度在复杂场景下可能受限。
- 基于热图（Heatmap-based）：为每个关键点预测一个二维概率热图，通过峰值位置获得坐标。该方法保留了空间结构信息，定位精度较高，是 2D 姿态估计的主流范式；但为获得高精度通常需要较高分辨率的特征图与上采样模块，计算与内存开销较大，同时存在由下采样引入的量化误差。

在热图范式中，常用以真值关键点 (u_k, v_k) 为中心生成高斯监督：

$$H_k(u, v) = \exp\left(-\frac{(u - u_k)^2 + (v - v_k)^2}{2\sigma^2}\right) \quad (2-6)$$

其中 σ 控制空间扩散范围。当网络输出热图相对输入存在下采样步长 s 时，关键点位置会发生离散化，单轴量化误差上界约为 $s/2$ ，因此端侧系统常需在热图分辨率与计算/内存开销之间进行权衡。

在坐标读出方面，传统 $\arg\max$ 能直接取峰值坐标，但不可导；可导替代方案是 soft-argmax （期望读出），例如：

$$\hat{u}_k = \sum_{u,v} u \cdot \text{softmax}(\beta H_k(u, v)), \quad \hat{v}_k = \sum_{u,v} v \cdot \text{softmax}(\beta H_k(u, v)) \quad (2-7)$$




图 2-6 基于热图的人体姿态估计示意图。左：输入图像；中：网络输出的关节概率热图，亮色区域对应各关节点的高响应位置；右：依据热图峰值解码得到的骨架关键点检测结果。

其中 β 为温度系数。该读出便于端到端训练，但对热图峰形质量更敏感。综合来看，端侧系统常采用坐标回归或中低分辨率热图 + 轻量上采样/引导的折中方案，以在时延与精度之间取得更优平衡。

2.2.3 二维人体姿态估计范式

二维多人姿态估计主要分为自顶向下与自底向上两类路线：

- 自顶向下：先使用通用检测器得到人体边界框，再对每个框内执行单人关键点检测。该范式通常精度较高、对尺度变化更鲁棒，例如高分辨率表征学习（HRNet）在关键点定位上表现突出 [8]；但整体计算量随图像中人数近似线性增长，且性能受检测器误差传递影响。
- 自底向上：先在整幅图像上检测所有关键点，再通过关联与分组策略将关键点组装成不同的人体实例。OpenPose 提出的 Part Affinity Fields（PAF）为关键点关联提供了有效表征 [9]；该范式推理开销相对稳定，不随人数显著增长，但在严重遮挡、多人拥挤及尺度差异较大时，关键点分组更容易出现歧义。





图 2-7 二维多人姿态估计的两类主流范式对比。

尽管本文的输入为双目图像对，2D 关键点检测与热图表征仍可作为中间监督信号或跨视图对齐先验，为后续 3D 恢复提供更稳定的结构约束。


2.2.4 三维人体姿态估计方法与坐标口径

三维人体姿态估计常见方法可归纳为：

- 端到端直接估计（Direct Estimation）：直接从图像特征回归 3D 关节点坐标，或进一步回归人体参数化模型（如 SMPL）以获得网格与姿态参数 [10]。该类方法流程简洁，但往往依赖大量 3D 标注数据，跨场景泛化能力易受限制。
- 两阶段法 / 2D 到 3D 提升（2D-to-3D Lifting）：第一阶段获取 2D 关键点，第二阶段通过提升网络将 2D 坐标映射到 3D 空间（可结合时序信息以抑制抖动）。由于第二阶段输入维度低、计算效率高，该路线在轻量化与实时应用中非常常见 [11]。
- 多视图/双目视觉辅助（Stereo/Multi-view）：引入多视角几何约束（如极线约束与三角测量）可显著缓解单目深度歧义，提高 3D 重建精度与鲁棒性，但对相机标定与同步提出更高要求。本文选择以双目立体几何为基础，在获得绝对尺度线索的同时，将硬件复杂度与跨视图计算控制在更可落地的范围内（详见第2.3.1节）。



(a) 端到端直接估计：图像直接输入 3D 姿态检测器，一步回归三维关节坐标。



(b) 两阶段 2D 提升法：先检测 2D 关键点，再通过提升网络映射至 3D 空间。

图 2-8 三维人体姿态估计的两类主流方法示意图。

在坐标口径上，3D 姿态既可表示为根相对坐标（以骨盆等根节点为原点，消除全局平移影响），也可表示为相机坐标系下的绝对坐标（保留全局位置与尺度）。在双目系统中，标定与三角测量使得绝对尺度可观测，因此本文实验默认在左相机坐标系下报告绝对 MPJPE（mm），而 PA-MPJPE 等对齐指标更侧重评估姿态

形状，可作为补充分析。

此外，注意力机制可显式建模关节间的长距离关系，并在复杂背景中聚焦人体区域；在双目任务中，跨视图注意力（Cross-Attention）可用于左右视图特征对齐与融合，并可与几何先验（如极线约束）结合，将跨视图交互限制在更合理的搜索范围内，从而为后续 3D 回归提供更一致的表征。

2.2.5 数据集与评价指标

2.2.5.1 常用数据集

2D 姿态估计领域常用公开数据集包括 COCO（17 个关键点，OKS-mAP 评测）[1] 与 MPII（16 个关键点，PCK 评测）[2] 等；3D 姿态估计领域经典数据集包括 Human3.6M（室内动作捕捉标注）[3]，以及更贴近真实场景的 3DPW（in-the-wild）[12]。在本文实验设置中，RT-Pose 数据集用于主要训练与评测[4]，MADS 数据集用于跨数据集泛化验证[5]。

2.2.5.2 人体关节点定义与标准

不同数据集在关节点数量与位置上存在差异：COCO 定义 17 个关节点 [1]，MPII 定义 16 个 [2]，Human3.6M 常用 17 个核心点 [3]。在 3D 姿态表示中，通常以骨盆（Pelvis）为根节点，所有关节点坐标采用根相对（root-relative）方式表示，消除全局位置变化的影响，使模型专注于姿态本身。图 2-9展示了典型的人体骨架关节点布局，三套标准的对照关系见表 2-1。




图 2-9 典型的人体关节点骨架示意图

表 2-1 COCO[1]、MPII[2] 与 Human3.6M[3] (常用 17 点) 关节点索引对照表

Idx	COCO (17)	Idx	MPII (16)	Idx	Human3.6M (17)
0	Nose (鼻子)	0	R-Ankle (右踝)	0	Pelvis (骨盆/中心)
1	L-Eye (左眼)	1	R-Knee (右膝)	1	R-Hip (右臀)
2	R-Eye (右眼)	2	R-Hip (右臀)	2	R-Knee (右膝)
3	L-Ear (左耳)	3	L-Hip (左臀)	3	R-Ankle (右踝)
4	R-Ear (右耳)	4	L-Knee (左膝)	4	L-Hip (左臀)
5	L-Shoulder (左肩)	5	L-Ankle (左踝)	5	L-Knee (左膝)
6	R-Shoulder (右肩)	6	Pelvis (骨盆)	6	L-Ankle (左踝)
7	L-Elbow (左肘)	7	Thorax (胸部)	7	Torso (躯干)
8	R-Elbow (右肘)	8	Upper Neck (颈)	8	Neck (颈部)
9	L-Wrist (左腕)	9	Head Top (头顶)	9	Nose (鼻子/头)
10	R-Wrist (右腕)	10	L-Wrist (左腕)	10	Head (头顶)
11	L-Hip (左臀)	11	L-Elbow (左肘)	11	L-Shoulder (左肩)
12	R-Hip (右臀)	12	L-Shoulder (左肩)	12	L-Elbow (左肘)
13	L-Knee (左膝)	13	R-Shoulder (右肩)	13	L-Wrist (左腕)
14	R-Knee (右膝)	14	R-Elbow (右肘)	14	R-Shoulder (右肩)
15	L-Ankle (左踝)	15	R-Wrist (右腕)	15	R-Elbow (右肘)
16	R-Ankle (右踝)	—	—	16	R-Wrist (右腕)

2.2.5.3 评价指标

人体姿态估计任务通常通过一系列量化指标进行评估。对于 2D 姿态估计，常用指标包括（以 MPII[2] 与 COCO[1] 评测口径为例）：

- **PCK (Percentage of Correct Keypoints)**：统计预测关键点落在归一化阈值范围内的比例，阈值通常根据人体尺度（如头部尺寸或躯干长度）进行归一化 [2]。
- **OKS (Object Keypoint Similarity)**：综合考虑关键点像素误差、可见性以及不同关键点标注不确定性，用于更细致地衡量关键点相似度 [1]。
- **mAP**：基于 OKS 阈值统计平均精度，是 COCO 评测中最常用的 2D 姿态指标 [1]。

对于 3D 人体姿态估计，最核心和最广泛使用的指标之一是平均每关节位置误差 (Mean Per Joint Position Error, MPJPE)。

(1) MPJPE (Mean Per Joint Position Error)

MPJPE，有时也称为重构误差 (Reconstruction Error)，是衡量 3D 人体姿态估计精度的金标准。它计算的是模型预测的 3D 关节点坐标与真实 3D 关节点坐

标（Ground Truth）之间的平均欧氏距离（Euclidean Distance）。如公式2-8所示，对于一个包含 N 个关节点的姿态，其 MPJPE 的计算方式如下：

$$\text{MPJPE} = \frac{1}{N} \sum_{i=1}^N \|J_{pred,i} - J_{gt,i}\|_2 \quad (2-8)$$

其中， $J_{pred,i}$ 和 $J_{gt,i}$ 分别代表第 i 个预测关节点和真实关节点的 3D 坐标。这个值通常以毫米（mm）为单位，其值越低，代表模型的预测精度越高。本文实验默认报告绝对 MPJPE：在左相机坐标系下直接计算预测三维关节与真值三维关节的欧氏距离（mm）；根相对 MPJPE 或仅尺度对齐（scale-aligned）的误差可作为可选补充指标，用于分析全局平移/尺度因素的影响。

(2) PA-MPJPE (Procrustes Aligned MPJPE)

然而，在某些场景下，我们更关心模型预测的姿态形状（Shape）的准确性，而非其在空间中的全局位置、旋转和缩放。例如，一个预测的姿态可能在形状上与真实姿态完全一致，但由于整体平移或旋转，其 MPJPE 值仍然会很高。为了消除这种全局变换带来的影响，研究者们提出了 Procrustes 对齐后的 MPJPE（PA-MPJPE），也称形状误差（Shape Error）。

在计算 PA-MPJPE 之前，需要通过刚性变换（旋转、平移和缩放），即 Procrustes 分析，将预测的 3D 姿态与真实 3D 姿态进行对齐。PA-MPJPE 计算的是在最佳对齐之后，预测关节点与真实关节点之间的平均欧氏距离。其计算公式如下：

$$\text{PA-MPJPE} = \min_{R,t,s} \frac{1}{N} \sum_{i=1}^N \|(sR \cdot J_{pred,i} + t) - J_{gt,i}\|_2 \quad (2-9)$$

其中，优化过程寻找一个最佳的旋转矩阵 R 、平移向量 t 和缩放因子 s ，以最小化对齐后的平均误差。PA-MPJPE 能够更纯粹地评估模型对人体结构和比例的学习能力，是衡量姿态“形状”准确性的关键指标。

2.3 双目立体视觉原理

2.3.1 双目立体视觉成像模型

双目立体视觉通过两台相机从不同视角同时观测同一场景，利用左右视图之间的几何约束恢复场景的深度信息。设空间点在世界坐标系中的齐次坐标为 $\mathbf{X} = [X, Y, Z, 1]^T$ ，其在左/右相机成像平面上的齐次像素坐标分别为 $\mathbf{x}_l = [u_l, v_l, 1]^T$ 与 $\mathbf{x}_r = [u_r, v_r, 1]^T$ ，则在针孔相机模型下有：

$$s_l \mathbf{x}_l = \mathbf{K}_l [\mathbf{R}_l \ \mathbf{t}_l] \mathbf{X}, \quad s_r \mathbf{x}_r = \mathbf{K}_r [\mathbf{R}_r \ \mathbf{t}_r] \mathbf{X} \quad (2-10)$$

其中, $\mathbf{K}$ 为相机内参矩阵 (包含焦距与主点), $[\mathbf{R} \ \mathbf{t}]$ 为外参 (描述相机坐标系相对世界坐标系的旋转和平移), s 为尺度因子。双目系统通常通过标定获得两台相机的内参及它们之间的相对位姿, 其中两相机光心之间的距离称为基线 (Baseline) B 。

2.3.2 极线几何与立体校正

如图 2-10 所示, 在双目系统中, 左右相机光心 C_l 与 C_r 以及空间点 $\mathbf{X}$ 共同确定一个对极平面 (Epipolar Plane)。对极平面分别与左右成像平面相交得到极线 l_l 与 l_r ; 另一相机光心在本相机成像平面上的投影为对极点 e_l 与 e_r , 且任意极线必过对极点。由此可知, 当左图像点 $\mathbf{x}_l$ 已知时, 其在右图像中的对应点 $\mathbf{x}_r$ 不再是二维搜索, 而被约束在右图极线 l_r 上 (反之亦然), 这正是极线约束降低匹配复杂度的几何本质。




图 2-10 双目对极几何示意图。 C_l 、 C_r 为左右相机光心, $\mathbf{X}$ 为空间三维点; l_l 、 l_r 为对应极线, e_l 、 e_r 为对极点; 三点 C_l 、 C_r 、 $\mathbf{X}$ 所确定的平面为对极平面, 其与成像平面的交线即为对应极线。

图中, $\mathbf{x}_l = [u_l, v_l, 1]^T$ 与 $\mathbf{x}_r = [u_r, v_r, 1]^T$ 分别为 $\mathbf{X}$ 在左右成像平面上的像素齐次坐标, 通过各自相机内参矩阵 $\mathbf{K}$ 与归一化相机坐标关联 ($\mathbf{x} \sim \mathbf{K}\tilde{\mathbf{x}}$)。

对于同一空间点 $\mathbf{X}$ 在左右视图中的像素对应 $\mathbf{x}_l$ 与 $\mathbf{x}_r$, 其匹配关系满足极线约束:

$$\mathbf{x}_r^T \mathbf{F} \mathbf{x}_l = 0 \quad (2-11)$$

其中 $\mathbf{F}$ 为基础矩阵 (Fundamental Matrix)。对于已标定的双目系统, 两相机间的相对旋转 $\mathbf{R}$ 与平移 $\mathbf{t}$ 已知, 可先构造本质矩阵 (Essential Matrix):

$$\mathbf{E} = [\mathbf{t}]_{\times} \mathbf{R} \quad (2-12)$$

其中 $[\mathbf{t}]_{\times}$ 为 $\mathbf{t}$ 的反对称矩阵。基础矩阵则由本质矩阵与左右相机内参联合给出：

$$\mathbf{F} = \mathbf{K}_r^{-\top} \mathbf{E} \mathbf{K}_l^{-1} \quad (2-13)$$

上式表明， $\mathbf{F}$ 完全由标定参数 $\{\mathbf{K}_l, \mathbf{K}_r, \mathbf{R}, \mathbf{t}\}$ 决定。工程实现中通常对左右图像进行立体校正（Stereo Rectification）：将倾斜的极线变换为水平扫描线，使校正后对应点满足 $v_l = v_r$ ，跨视图匹配从二维搜索退化为一维水平扫描，视差 $d = u_l - u_r$ 成为唯一待估量，自然引出下一节的三角测量深度恢复。

2.3.3 视差与深度恢复（三角测量）

在完成立体校正且双目相机近似共面、光轴平行的情况下，视差定义为左右像素横坐标之差：

$$d = u_l - u_r \quad (2-14)$$

由相似三角形关系可得空间点的深度（以左相机坐标系为例）：

$$Z = \frac{fB}{d} \quad (2-15)$$

其中 f 为等效焦距（通常使用 f_x ）， B 为基线长度。由式2-15可知：深度与视差成反比，近处物体具有更大的视差、更易估计；远处物体视差很小，对匹配误差更敏感。图 2-11 给出了双目视差与三角测量的几何关系示意。




图 2-11 双目视差与三角测量几何示意图

进一步地，若视差估计存在标准差 σ_d ，深度误差可近似写为：

$$\sigma_Z \approx \left| \frac{\partial Z}{\partial d} \right| \sigma_d = \frac{fB}{d^2} \sigma_d \quad (2-16)$$

该关系揭示了双目系统在远距离场景下深度不确定性快速增长的原因。

2.3.4 误差来源与工程要点

双目深度恢复的精度不仅取决于匹配算法本身，还受到多种因素影响：

- 标定与同步误差：内外参不准确、镜头畸变未充分校正或左右相机不同步，会破坏极线约束并引入系统性偏差。
- 遮挡与弱纹理：遮挡区域在另一视图中不存在真实对应点；弱纹理或重复纹理会导致匹配代价不可靠，从而产生错误视差。
- 基线与焦距选择：增大 B 或 f 可提升远距离深度分辨率，但会增加系统体积、降低近距离可视重叠并加剧遮挡。
- 亚像素视差估计：通过代价曲线拟合或网络回归获得亚像素视差，可显著降低 σ_d ，进而改善深度精度。

综上，双目立体视觉的成像模型、极线几何约束与三角测量深度恢复共同构成双目 3D 视觉的理论基础：极线约束使跨视图特征搜索从二维退化为一维，显著降低匹配复杂度；三角测量则提供了将视差转化为可量化深度的几何桥梁，是双目系统相对于单目方法的核心优势所在。

2.4 轻量化网络设计

面向移动端或嵌入式设备的视觉算法受到算力、内存带宽与功耗的严格约束。对于双目 3D 人体姿态估计而言，网络需在参数量、计算量（FLOPs）、峰值内存与精度-效率折中四个维度协同权衡，同时避免传统立体匹配中高维代价体（Cost Volume）带来的显存开销。轻量化设计通常遵循“减少高维张量、优先 2D 算子、控制通道数与分辨率”的总体原则。本小节从结构轻量化设计、模型压缩与端侧部署工程优化三个层次依次介绍在边缘端实现高效推理的常用方法。

2.4.1 结构轻量化设计

从结构层面来看，面向端侧部署的轻量化通常需要在骨干特征提取、跨尺度与跨视图融合以及预测头设计三个方面协同优化。

首先，在骨干特征提取方面，深度可分离卷积（Depthwise Separable Convolution）是降低计算量的典型手段。对于输入特征尺寸为 $H \times W$ 、通道数为 C_{in} ，输出通道数为 C_{out} 、卷积核大小为 $k \times k$ 的标准卷积，其计算复杂度近似为：

$$\text{Cost}_{\text{conv}} \propto HW \cdot C_{in} C_{out} \cdot k^2 \quad (2-17)$$

深度可分离卷积将其分解为逐通道卷积（Depthwise）与 1×1 点卷积（Pointwise），复杂度近似为：

$$\text{Cost}_{\text{dw}} \propto HW \cdot C_{in} \cdot k^2, \quad \text{Cost}_{\text{pw}} \propto HW \cdot C_{in} C_{out} \quad (2-18)$$

当 $k > 1$ 且 C_{out} 较大时，式2-18相较式2-17可显著降低计算量。进一步地，倒残差结构（Inverted Residual）与线性瓶颈（Linear Bottleneck）通过“先扩展后压缩”的通道设计，在保证表达能力的同时减少高成本卷积层的使用；组卷积（Group Convolution）与通道洗牌（Channel Shuffle）则在降低计算量的同时增强通道间信息交互。这些模块共同构成面向端侧的高效特征提取基础。

其次，在跨尺度与跨视图融合方面，人体姿态估计与双目匹配均依赖多尺度信息与跨视图一致性，轻量化设计中应重点控制通道宽度与融合路径数量，避免引入冗余分支。双目结构天然存在“左右分支”带来的参数与算力倍增风险；实践中常采用非对称主/辅分支——主分支（左视图）保留较大容量以提取充分特征，辅分支（右视图）采用更轻量结构，在保证跨视图信息完整性的同时降低整体计算开销。

端侧系统通常难以承受高分辨率、全视差范围的代价体与 3D 卷积正则化，更可行的替代思路是在低分辨率特征上构建紧凑的跨视图交互，以分组相关（Group-wise Correlation）等轻量算子代替全通道代价体，从而降低访存压力；结合立体校正先验，可进一步将信息聚合限制在极线方向，将二维搜索退化为一维扫描，是兼顾效率与几何精度的可行方案。

最后，在预测头与输出表征方面，基于热力图的方法通常定位精度较高，但需要上采样与峰值解析；直接坐标回归计算图更简洁，但对特征表达与训练稳定性要求更高。在轻量化框架中通常优先选择算子友好、计算路径短的输出形式，并通过共享特征、减少分支与控制输出分辨率来进一步降低时延与内存占用。

2.4.2 模型压缩

在高效结构的基础上，模型压缩进一步降低存储与计算开销。实践中通常优先采用量化（对端侧吞吐提升最直接），再以剪枝缩减算量，最后以知识蒸馏补偿精度损失；三者可单独或组合部署。

量化在端侧场景中尤为重要：其不仅降低存储与带宽开销，还能显著提升 NPU/DSP 等硬件的算子吞吐。以 b 比特整数量化为例，常用的仿射量化可写为：

$$q = \text{clip}\left(\left\lfloor \frac{x}{s} \right\rfloor + z, q_{\min}, q_{\max}\right), \quad \hat{x} = s(q - z) \quad (2-19)$$

其中 x 为浮点值， q 为量化后的整数， $\hat{x}$ 为反量化近似值； $s > 0$ 为缩放因子， z 为零点（zero-point）； $q_{\min}, q_{\max}$ 由位宽确定（如 INT8 时为 $[-128, 127]$ ）。对于给定动态范围 $[x_{\min}, x_{\max}]$ ，缩放因子选取为：

$$s = \frac{x_{\max} - x_{\min}}{q_{\max} - q_{\min}}, \quad z = \left\lfloor q_{\min} - \frac{x_{\min}}{s} \right\rfloor \quad (2-20)$$

在实践中常采用逐通道（per-channel）权重量化与量化感知训练（QAT）减小精度损失，并通过校准（calibration）合理选择动态范围以避免过多截断。量化还可显著减少模型存储： b 比特量化后存储量约为 FP32 的 $b/32$ 倍（即 $S_b = \frac{b}{8}N_p$ 字节）。

剪枝方面，结构化剪枝通过移除冗余通道或注意力头，在保证可部署性的前提下减少计算量。由式2-17可知，通道剪枝带来的理论加速可写为：

$$\frac{\text{Cost}'}{\text{Cost}} \approx \frac{C'_{in}C'_{out}}{C_{in}C_{out}} \quad (2-21)$$

当输入与输出通道同时缩减时可获得更显著的降幅。非结构化稀疏在端侧往往难以获得稳定加速，因此更常采用结构化方案并配合编译器优化。

知识蒸馏通过教师网络为学生网络提供“软目标”与中间特征约束，在不增加推理开销的前提下提升小模型精度 [13–15]。以温度蒸馏为例，典型损失可写为：

$$\mathcal{L} = (1 - \lambda)\mathcal{L}_{task} + \lambda T^2 \text{KL}\left(\text{softmax}\left(\frac{\mathbf{z}_t}{T}\right) \parallel \text{softmax}\left(\frac{\mathbf{z}_s}{T}\right)\right) \quad (2-22)$$

其中 $\mathbf{z}_t, \mathbf{z}_s$ 为教师与学生的 logits， T 为温度系数， λ 为权衡系数。对于姿态回归任务，也可采用特征蒸馏或分布蒸馏等方式提升鲁棒性。

2.4.3 端侧部署工程优化

结构轻量化与模型压缩确定了网络的理论效率上限，而端侧实际推理性能还取决于算子与硬件的匹配程度。端侧推理的瓶颈往往不仅来自算术计算量，还来自内存带宽与访存模式：频繁的特征拼接与大体积张量读写会显著抬高时延与能耗，双目任务中代价体易导致内存峰值过高，需优先以 2D 算子替代高维操作。工程层面应结合算子融合（Operator Fusion）、张量布局优化与内存复用等手段，尽量避免大规模 3D 卷积、超大矩阵乘等端侧不友好算子，才能将理论压缩收益转化为稳定的端侧加速。综合来看，轻量化网络设计需要在结构设计、压缩策略与部署工程三个层面协同优化，才能在资源受限设备上实现可用的双目 3D 人体姿态估计性能。

2.5 本章小结

本章系统梳理了本文研究所依赖的核心理论与技术基础。在深度学习基础方面，介绍了卷积神经网络的层次特征提取机制与 Transformer 的多头注意力及交叉注意力框架，两者分别适用于高效视觉特征提取与跨位置、跨视图的全局关联建模。在人体姿态估计理论方面，归纳了 2D/3D 姿态估计的主流范式、热力图与坐标回归两类表示方法，以及 MPJPE、PA-MPJPE 等核心评价指标，明确了双

目 3D 姿态估计的任务定义与评测体系。在双目立体视觉原理方面，阐述了针孔成像模型、极线几何约束与三角测量深度恢复方法，这些几何原理是实现高效跨视图特征匹配与三维坐标恢复的理论依据。在轻量化网络设计方面，总结了深度可分离卷积、倒残差结构等高效骨干设计范式，以及量化、剪枝与知识蒸馏等模型压缩策略，为面向资源受限设备的视觉算法设计提供了系统性的理论参照。

第3章 基于双目相机的轻量化3D人体姿态检测网络设计

本章面向端侧多人三维人体姿态估计任务，针对现有双目方法在计算冗余与误差累积两方面的瓶颈，提出一种轻量化非对称双目学习框架。该框架以关节任务为中心组织跨视图特征交互与三维求解，通过非对称骨干网络消除左右对称冗余，利用极线约束将跨视图匹配限制在一维搜索空间，并借助可微加权三角化实现端到端的三维关节恢复，在精度与端侧效率之间取得可落地的平衡。本章首先梳理研究背景与动机，随后系统分析制约现有方法端侧部署的关键问题，在此基础上介绍所提框架的整体设计与各模块细节，最后通过对比实验与消融实验对方法的有效性进行定量验证。

3.1 研究背景

在上一章对双目三维姿态估计与端侧轻量化技术的研究现状进行梳理后可以发现，三维人体姿态估计的研究重点正从单纯追求离线精度，逐步转向兼顾实时性、能效与可部署性的综合优化。在物联网与边缘计算驱动的应用场景中，系统通常需要在移动端或嵌入式设备上持续运行，例如服务机器人、人机交互终端、可穿戴设备与智能摄像头等。此类平台普遍受到算力、内存与功耗等资源约束，同时还面临隐私保护与网络不确定性等现实因素。因此，能够在端侧稳定运行的三维姿态估计方法必须在精度与效率之间建立可解释且可复现的权衡，而这也构成了本章研究的直接背景。

从成像机理与几何约束角度看，双目相机为端侧三维姿态恢复提供了更具工程可行性的传感器基础。与单目方法相比，双目系统能够通过视差与三角测量显式引入深度线索，从而在一定程度上缓解单目三维重建固有的深度歧义；与多目系统相比，双目结构在硬件成本、安装复杂度与同步标定要求方面更易满足端侧部署条件。面对尺度变化与背景干扰较强的真实环境，双目几何先验有助于提升三维姿态估计的可靠性与稳定性，使其更符合在线交互与安全监测等应用的需求。

然而，双目约束并不天然等价于端侧友好。现有许多双目深度或三维重建方法仍依赖高维代价体构建与密集正则化，往往需要三维卷积或大规模迭代优化才能获得较高精度，这会带来显存占用高、访存压力大与推理延迟不可控等问题。另一方面，若直接采用左右对称的双分支结构分别完成特征提取与姿态预测，骨干网络与多尺度融合模块的计算量将近似倍增，导致大量跨视图冗余计算；在多人场景中，该冗余会随实例数增加而放大，进一步削弱端侧实时性，并使系统时延随场景复杂度产生明显波动。

基于上述矛盾,本章聚焦于基于双目相机的轻量化三维人体姿态检测网络设计,目标是在充分利用双目几何优势的同时,避免密集视差计算与对称冗余带来的资源开销,构建适配端侧部署的高效推理链路。为此,本章将围绕以下关键问题展开讨论:其一,如何在双目输入下设计计算与表征能力不对称的特征提取结构,以降低跨视图重复计算并保留关键几何信息;其二,如何利用极线几何等先验约束跨视图交互,将匹配与融合限制在低复杂度的搜索空间内,从而以较小代价增强特征一致性与关键点定位精度;其三,如何在不构建高维代价体的前提下实现可靠的深度推断与三维关键点恢复,使三维推理阶段对多人数量与输入分辨率具有更好的可扩展性。

综上,本章研究的核心命题在于:如何在双目输入下实现以关节任务为中心的高效三维推理,在不依赖稠密深度中间表示的前提下,将精度与端侧效率统一于同一端到端框架之中。因此,本章将在后续小节中首先对端侧双目三维姿态估计的计算瓶颈与误差来源进行分析,随后给出面向效率的非对称网络设计方案,并进一步介绍极线约束下的跨视图特征增强与可微几何求解策略,最后通过实验评估验证所提出设计在精度与效率方面的综合优势。

3.2 问题分析

在正式介绍本章所提方法之前,本节从三个递进层次梳理端侧三维人体姿态估计面临的核心问题:首先分析单目成像固有的尺度模糊,揭示仅凭单视图无法获得绝对深度的根本原因;其次说明多目系统虽能缓解尺度歧义,却因工程代价过高而难以落地;最后聚焦于现有双目方法在端侧多人场景下的两类具体瓶颈——稠密级联开销与左右对称冗余——并由此引出本章的设计动机。

3.2.1 单目人体姿态估计的尺度模糊问题

第2章已对单目投影成像与三维恢复的不定性进行介绍。单目三维人体姿态估计旨在从单幅图像中恢复人体各关节在三维空间中的位置(例如以相机坐标系下的 $\hat{\mathbf{X}}_k = [\hat{X}_k, \hat{Y}_k, \hat{Z}_k]^\top$ 表示),其核心困难在于单目成像仅提供二维投影观测,深度维度不可直接观测。对于相机内参矩阵 $\mathbf{K}$ 与三维点 $\mathbf{P} = [X, Y, Z]^\top$,其像素坐标 $\mathbf{p} = [u, v, 1]^\top$ 满足

$$Z\mathbf{p} = \mathbf{K}\mathbf{P}. \quad (3-1)$$

式(3-1)表明,对于给定像素 $\mathbf{p}$,三维点 $\mathbf{P}$ 仅能确定在一条从相机光心出发的视线方向上,其沿视线方向的距离 Z 无法由单帧图像唯一确定。换言之,单目观测只能约束关节的二维方向与相对结构,而绝对深度与米制尺度不可由单帧观测唯一确定,从而导致三维姿态存在固有的尺度模糊。

进一步地,即便引入外观先验或时序约束,单目三维姿态仍普遍存在尺度模糊:在仅依赖投影一致性的条件下,若将三维结构按比例因子 $\alpha > 0$ 整体缩放,并将相机与人体的相对平移按相同因子缩放,则其在图像上的投影保持不变。该性质意味着模型往往只能稳定输出根相对或尺度归一化的三维姿态;当任务需要输出与物理空间一致的绝对三维坐标(例如跌倒监测、人与机器人安全距离判断)时,缺乏绝对尺度会显著限制模型的可用性并导致跨场景尺度漂移。




图 3-1 单目三维人体姿态估计的尺度模糊示意图

如图3-1所示,单目观测只提供视线方向约束:同一像素对应的三维点可以位于该视线上的任意位置。以人体身高为例,在针孔模型下人体在图像中的像素高度 h 与真实身高 H 、距相机的深度 Z 近似满足 $h \propto \frac{fH}{Z}$ 。因此,当观测到相同的投影高度 h 时,不同身高的个体对应不同的真实深度 Z ,仅凭单目图像难以恢复绝对距离与米制尺度。为获得具有物理意义且更稳定的深度线索,本章进一步引入双目立体几何约束,利用视差与三角测量从根源上缓解单目尺度模糊带来的不确定性。

3.2.2 多目人体姿态估计的问题

多目三维人体姿态估计常见于动作捕捉棚、智能教室、固定式安防与多机位拍摄等场景:在 $V \geq 3$ 个相机视角下同时观测同一人体,通过跨视角几何约束恢复关节三维坐标,如图 3-2 所示。多目系统能够显著提升可见性并缓解遮挡,因此在受控环境中可获得较高的三维姿态精度与稳定性。

然而,多目系统的优势往往建立在较高的工程代价之上。在硬件层面,相机数量增加会显著抬升传感器成本与安装复杂度,并对时间同步、标定维护与带宽传输提出更高要求:以常见的 4 相机动捕系统为例,其单次标定流程通常需要专业人员操作,且标定精度随设备老化和环境变化而退化,难以在消费级场景中持




图 3-2 多视角多相机场景示意图

续维护。在计算层面，多视图特征融合与跨视角实例关联的计算量随相机数 V 近似线性增长；在多人在线应用中，跨视角的实例一致性维护与异常观测处理也会引入额外系统开销，使端侧时延更难稳定控制。以 VoxelPose [16] 等具有代表性的多目方法为例，其在 4 相机配置下仅骨干特征提取部分的 FLOPs 即超过单目方法的 3 倍，加之视角融合与三维体素化步骤，完整推理链路在移动端 SoC 上难以实现实时运行。在部署层面，固定多相机阵列与端侧移动平台的安装适配性存在先天矛盾，限制了多目系统在服务机器人、可穿戴设备等移动场景中的应用空间。因此，本文选择以双目立体几何为基础，在获得绝对尺度线索的同时，将硬件复杂度与跨视图计算控制在更可落地的范围内。

3.2.3 现有基于双目人体姿态估计的问题

前两节的单目尺度模糊与多目部署门槛为本章提供了问题背景；本节进一步聚焦于现有双目人体姿态估计方法在端侧多人场景中的关键瓶颈。尽管双目相机能够通过视差提供绝对尺度，是端侧三维人体姿态估计更具工程可行性的传感器选择，但现有方法在部署时仍普遍存在计算冗余大、系统复杂度高与鲁棒性不足等问题，难以同时满足“多人、实时、可部署”的需求。下文将从两阶段级联范式与结构冗余两个角度进行分析，并给出本章后续方法设计的直接动机。概括而言，现有双目人体姿态估计方法在端侧多人场景中主要面临以下两类典型路线/问题：

- 问题 A：基于稠密深度先验的级联范式中，稠密无效像素主导的计算开销与误差累积
- 问题 B：基于左右对称双分支结构中，跨视图冗余计算与端侧效率瓶颈

3.2.3.1 问题 A：基于稠密深度先验的级联范式中，稠密无效像素主导的计算开销与误差累积

一种直观的双目三维人体姿态估计思路是采用“深度先验+2D 姿态”的级联流程：首先利用双目深度估计网络或立体匹配算法获得整幅图像的稠密视差/深度图 $\hat{d}(\mathbf{p})/\hat{Z}(\mathbf{p})$ ，随后采用单目 2D 人体姿态估计器得到关节像素坐标 $\hat{\mathbf{p}}_k = [\hat{u}_k, \hat{v}_k]^\top$ ，最后在关节处采样深度并通过反投影得到三维关节位置。该范式的核心矛盾在于：深度估计以像素为单位输出整幅图像的稠密深度/视差，而三维人体姿态最终只需在少量关节位置获取深度信息，因而端侧推理开销容易被大量与关节无关的“无效像素”主导，并在两阶段串联中累积误差。该两阶段级联流程如图 3-3 所示。




图 3-3 基于稠密深度先验的双目两阶段三维人体姿态估计流程示意图

以立体校正后的双目相机为例，设焦距为 f 、基线为 B ，则深度与视差满足

$$\hat{Z}(\mathbf{p}) = \frac{fB}{\hat{d}(\mathbf{p})}. \quad (3-2)$$

给定相机内参矩阵 $\mathbf{K}$ 与齐次像素坐标 $\tilde{\mathbf{p}}_k = [\hat{u}_k, \hat{v}_k, 1]^\top$ ，对应的三维关节估计可写为

$$\hat{\mathbf{X}}_k = \hat{Z}(\hat{\mathbf{p}}_k) \mathbf{K}^{-1} \tilde{\mathbf{p}}_k. \quad (3-3)$$

该流程实现简单，且能够在几何意义上输出具有米制尺度的三维坐标，因此在工程上具有一定吸引力。然而，将稠密深度估计作为前置模块并与 2D 姿态简单叠加，会在端侧多人场景中暴露出明显的效率与精度问题。

第一，稠密无效像素主导的计算开销。稠密深度估计以像素为单位输出 $H \times W$ 的深度图，并通常需要在较大的视差范围上进行匹配与正则化，其计算与内存开销主要由图像分辨率与视差范围决定，与实际需要的关节数量无关。对于多人姿态任务，最终仅需为每个目标的有限关键点集合 $\{\mathbf{p}_k\}_{k=1}^K$ 恢复深度，其中 K

通常为 17 或 24 等常数。若直接计算全图深度，再对少量关键点采样，则大量像素的匹配计算不会对最终三维关节精度产生直接贡献，导致端侧推理时延与功耗被”无效像素”主导；当输入分辨率提高以满足 2D 关键点定位需求时，该冗余将进一步放大。此外，在端侧部署中，稠密深度网络与 2D 姿态网络通常各自包含多尺度特征提取、上下采样与后处理模块，简单串联会导致参数量、激活占用与访存带宽叠加；同时，深度图输出到关节深度采样之间还可能需插值、滤波、置信度筛选与空洞填补等步骤，以缓解离散化与噪声对关节的影响，这些操作会增加不可忽略的 CPU/GPU 开销并引入额外时延。更重要的是，该级联结构无法充分共享双目两视图的中间特征表示，使得跨视图信息在深度阶段与姿态阶段被重复建模，进一步降低整体能效比。

第二，级联结构的误差累积。由式(3-2)可知，当视差估计存在误差 δd 时，深度误差近似满足

$$\delta Z \approx \left| \frac{\partial Z}{\partial d} \right| \delta d = \frac{fB}{d^2} \delta d, \quad (3-4)$$

这意味着在远距离（小视差）区域，亚像素级视差误差也会被放大为较大的深度波动。进一步代入式(3-3)，三维关节误差由深度误差与像素定位误差共同决定：一方面，2D 关键点在遮挡、运动模糊和弱纹理条件下易产生抖动，使得采样位置落入深度图的误匹配区域或深度不连续边缘；另一方面，深度网络的优化目标通常是像素级重投影误差或视差回归损失，其最优解并不必然在人体关节区域具有最小误差，尤其在衣物褶皱、细肢体结构和自遮挡处，深度图可能出现孔洞、飞点（flying pixels）或边界泄漏，从而导致关节深度在时间上产生跳变。由于级联方法缺乏从”关节三维误差”到”深度估计”的端到端反馈，系统难以针对关键点区域进行定向纠错，三维姿态往往呈现对场景与成像条件敏感的非平滑行为。

3.2.3.2 问题 B：基于左右对称双分支结构的跨视图冗余计算与端侧效率瓶颈

在网络结构上，许多双目姿态方法采用左右对称的双分支骨干分别提取特征，再进行融合或匹配。该左右对称双分支结构的典型流程如图 3-4 所示。这种设计虽然直观，且左右分支通常共享网络权重以减少参数量，但权重共享仅意味着模型存储开销不变，实际推理时仍需对左右两幅图像分别执行一次完整的前向传播，因此骨干网络与多尺度融合模块的计算量（FLOPs）与激活显存占用仍然近似翻倍，并引入大量跨视图冗余表征。在多人场景中，若后续还需进行实例级关联或多阶段细化，则系统开销会进一步叠加，导致端侧实时性不足且时延随场景复杂度波动明显。

为直观评估”左右视图内容高度相似”所带来的冗余，我们将同一双目输入分别送入全量 CSPDarknet 骨干，提取关键点热力图，结果如图 3-5 所示：左右视





图 3-4 基于左右对称双分支结构的双目人体姿态估计流程示意图

图的响应分布与峰值位置高度重叠，说明两套全量骨干在信息增益上非常有限，却会带来近乎两倍的参数量与 FLOPs，显著挤占端侧算力与内存带宽。这一可视化证据为后续左重右轻的非对称设计提供了直接动机。



(a) 左视图热力图

(b) 右视图热力图

图 3-5 左右视图热力图对比：响应分布高度重叠，提示双全量骨干的计算冗余

3.2.3.3 本章的解决思路

针对上述两类问题，本章的核心思路是：以关节任务为中心组织双目特征交互与三维恢复，跳过稠密深度中间表示，消除对称冗余计算，构建轻量且几何可解释的端侧推理链路。具体而言，针对问题 A 与问题 B 分别提出如下解决方案：

针对问题 A（稠密无效像素主导的计算开销与误差累积），本章从跨视图匹配与三维求解两个环节同时入手：

- 在跨视图匹配环节，引入极线特征增强模块：利用极线约束将跨视图匹配从二维搜索降为一维视差窗口搜索，使特征交互聚焦于与关键点相关的几何线索，从而避免显式构建全图稠密深度与高维代价体，大幅削减无效像素的计算开销（见第 3.3.3 节）。
- 在三维求解环节，设计可微加权三角化姿态求解器：直接将双目二维观测与相机模型融合为三维关节坐标，绕过级联深度估计的多阶段误差传递，并使 MPJPE 监督信号可端到端回传，消除中间监督与最终目标之间的不一致（见第 3.3.4 节与第 3.3.5 节）。

针对问题 B（左右对称双分支结构的跨视图冗余计算），本章从骨干架构与训练策略两个层面协同解决：

- 在骨干架构上，采用非对称双目骨干网络（左重右轻）：左分支保持全量容量以提供高质量的几何与语义表征，右分支采用轻量结构以大幅降低冗余计算，从而打破传统双全量骨干近似翻倍的计算瓶颈（见第 3.3.2 节）。
- 在训练策略上，引入跨分支表征一致性约束：弥补非对称设计带来的左右分支表征差异，使轻量右分支在训练中获得更强的几何感知能力，且该约束仅作用于训练阶段，推理时不增加额外开销（见第 3.3.5 节）。

通过上述设计，本章在不构建全图稠密深度或高维代价体的前提下，将有限计算资源集中于对三维关键点最敏感的区域与表征上，从而在精度与效率之间取得更适配端侧部署的平衡。

3.2.3.4 第一性原理分析

从第一性原理出发，双目视觉的任务本质上是在已知对极几何约束下，通过两个高度相关的二维信号 I_L 与 I_R 恢复一维深度场 d ：在双目匹配中，参考视图负责定义场景的几何骨架与像素级的定位精度，而目标视图仅作为特征匹配的搜索空间。由于定位精度对空间分辨率具有极高的敏感度，任何对参考视图特征的盲目压缩都会导致物体边缘和微小结构的永久性模糊；相比之下，匹配任务关注的是跨视图的特征相关性，根据信号处理中的互相关理论，适度的下采样或特征简化在降低高频噪声的同时，往往能通过亚像素插值维持极高的匹配稳健性。这种“定位与匹配”的功能分工，决定了在底层架构上无需对左右分支投入等量的计算资源。

从生物学角度来看，对称网络在双目特征提取中存在显著的信息冗余。由于左右视图捕捉的是同一物理空间的投影，它们之间蕴含着极高的互信息，在两个分支中同时部署重型骨干网络提取深层语义特征，在计算代价上是不经济的。非对称设计遵循了信息瓶颈原理，即在保证目标任务（视差预测）互信息最大化的前提下，最大限度地压缩其中一个分支的描述长度。在这一框架下，主分支负责构建高维的全局上下文语义，而轻量化分支被强制“去冗余”，仅保留最基础的几何纹理线索。这种非对称的特征表征模式，在生物学上契合人类视觉系统中“主导眼”与“辅助眼”的信息抑制与增强机制。

3.3 轻量化非对称双目学习框架与网络结构设计

针对 3.2 节归纳的两类瓶颈——稠密级联开销（问题 A）与左右对称冗余（问题 B）——本节提出轻量化非对称双目学习框架。其核心设计由四个相互协同的

模块构成：非对称双目骨干网络（第 3.3.2 节）、极线特征增强模块（第 3.3.3 节）、可微加权三角化姿态求解器（第 3.3.4 节）与跨分支表征一致性约束（第 3.3.5 节）。本节先给出整体流程，再依次介绍各模块细节。

3.3.1 整体框架与端到端流程

针对 3.2.3 节总结的稠密级联开销与左右对称冗余等问题，本文提出轻量化双目三维人体姿态估计框架，其整体流程如图 3-6 所示。该框架在端侧场景中同时兼顾几何精度与实时性，以“关节任务为中心”组织双目特征交互与深度细化：输入为立体校正后的左右视图，首先经非对称双目骨干网络提取多尺度特征金字塔 $\{\mathbf{F}_s^l\}$ 与 $\{\mathbf{F}_s^r\}$ ；随后在主尺度特征上引入极线特征增强模块，在极线约束下将跨视图匹配从二维搜索降为一维视差窗口搜索，并以右分支特征作为查询、左分支特征作为键和值完成交叉注意力聚合，从而向右分支注入几何一致性信息并得到增强表征；在此基础上，通过可微加权三角化姿态求解器将左右视图的二维观测与相机模型融合为三维关节坐标。训练阶段以 MPJPE 为主监督信号并联合跨分支表征一致性约束，使轻量分支在不增加推理开销的前提下获得更强的几何感知能力。




图 3-6 本文轻量化非对称双目三维人体姿态估计框架整体流程图

从多人姿态检测的范式来看，本文采用自底向上的整图推理链路：在整幅图像上一次性预测多人关键点热力图并完成关节级几何求解，从而避免自顶向下方法“按人裁剪、逐实例回归”带来的人数相关循环开销。其端到端计算开销主要由像素级骨干网络前向决定，复杂度近似为 $\mathcal{O}(HW)$ ；而三维求解器仅在稀疏的 $M \times J$ 关节特征上运行（ M 为人数， $J = 17$ 为常数），复杂度为 $\mathcal{O}(MJ)$ ，因此在多人场景下具有更稳定的时延表现。

3.3.1.1 多人实例构建与二维关键点解码

为将整图预测的二维表征转化为逐人的二维关键点观测，本文采用中心点引导的自底向上解码策略。对每个视图 $c \in \{l, r\}$ ，二维预测头除输出各关节热力图

$\{H_{c,j}\}_{j=1}^J$ 外, 还预测人体中心热力图 H_c^{ctr} 。推理阶段, 可在 H_c^{ctr} 上选取前 K 个峰值并结合非极大值抑制 (NMS) 得到每个实例中心 $\{(u_{c,m}^{ctr}, v_{c,m}^{ctr})\}_{m=1}^M$; 随后在每个中心位置, 由回归分支预测各关节相对中心的偏移 $\Delta \mathbf{x}_{c,m,j}$, 从而得到逐实例二维观测 $\mathbf{x}_{c,m,j} = [u_{c,m,j}, v_{c,m,j}]^T$ 。由于左右视图独立检测, 检测到的人数与实例顺序可能不一致, 因此在三角化之前需要建立跨视图实例关联。本文利用立体校正后的极线约束进行匹配: 对左视图检测到的每个实例中心 $(u_{l,m}^{ctr}, v_{l,m}^{ctr})$, 在右视图的同一水平扫描线 ($v_r^{ctr} \approx v_l^{ctr}$) 附近搜索距离最近的候选中心, 并采用贪心匹配 (按极线距离升序逐一配对) 建立左右实例的一一对应关系; 未能成功匹配的实例 (如仅在单侧视图可见) 将被丢弃, 不参与后续三角化。获得左右视图匹配后的逐实例二维观测 $\mathbf{x}_{l,m,j}, \mathbf{x}_{r,m,j}$ 后, 对每个实例 m 独立调用第 3.3.4 节的可微加权三角化姿态求解器, 得到三维关节 $\hat{\mathbf{X}}_{m,j}$ 。为简洁起见, 第 3.3.4 节后后续推导默认省略实例下标 m , 但其求解过程在实现中对每个实例均独立执行。

3.3.2 非对称双目骨干网络设计

如图 3-5 所示, 左右视图在高容量骨干下的响应分布高度重叠, 说明“左右各一套全量骨干”的信息增益有限而计算冗余显著。基于此, 本文采用“左重右轻”的非对称双分支骨干网络: 左分支 (全量分支) 使用 YOLO 风格的高容量骨干网络 (如 CSPDarknet 系列) 以更宽通道与更强表征能力提取高保真语义与几何特征, 并作为跨视图交互的主要信息源; 右分支 (小分支) 采用结构同构的轻量化骨干网络, 在保持算子类型与特征层级对齐的前提下, 将通道宽度缩减为全量分支的 0.5 倍 (`width_multiple=0.5`), 并将深度 (即各阶段 CSP 模块堆叠数) 缩减为全量分支的 0.34 倍 (`depth_multiple=0.34`), 从而将右分支骨干的参数量与 FLOPs 分别压缩至全量分支骨干的约 40%, 显著降低计算量与访存开销, 便于端侧部署。结合预测头等共享模块后, 非对称方案的整体参数量与 FLOPs 分别为对称全量方案的约 62% (详见表 3-7)。两分支各阶段输出通道数的对比见表 3-1。

表 3-1 非对称双目骨干网络两分支各阶段输出通道数配置对比。步幅 s 表示特征图相对于输入图像的下采样倍数。

分支	步幅 $s = 8$	步幅 $s = 16$	步幅 $s = 32$	<code>width_multiple</code>
左分支 (全量, CSPDarknet-M)	256	512	1024	1.0
右分支 (轻量, CSPDarknet-N)	128	256	512	0.5

图 3-7 给出了非对称双目骨干网络的整体结构示意, 以及单个 CSP Block 的内部展开。两分支均以 Stem 层完成初始下采样 ($\times 4$), 随后经 P3、P4、P5 三个 CSP 阶段逐步提取多尺度特征; 两分支在每个阶段的通道数维持 $2\times$ 差异 (见

表 3-1)，各阶段 CSP Block 内的 Bottleneck 堆叠数同样按 depth_multiple 等比缩减 ($M: n = 3/6/9$, $N: n = 1/2/3$)。每个 CSP Block 内部通过“一路直传 (skip) + 一路 Bottleneck 堆叠”的双路设计，将输入特征在通道维度拆分后分别处理再拼接融合，在保持表征多样性的同时有效减少重复梯度计算。




图 3-7 非对称双目骨干网络结构示意图。左侧展示两分支从输入到多尺度特征输出的各阶段通道配置；右侧展示单个 CSP Block 中“直传路径 + Bottleneck 堆叠 → Concat → 融合”的内部数据流。

需要指出的是，“哪侧为主（全量）、哪侧为辅（轻量）”在几何层面并无本质区别，左右可以互换。本文固定左分支为全量分支，主要出于与后续极线特征增强模块（见第 3.3.3 节）的配合考虑：该模块以右分支特征作为查询、左分支特征作为键和值，将左分支的高保真表征通过交叉注意力注入右分支；因此左分支需要承担信息源角色，保持更强的表征容量更为合理，全文一致采用这一约定。两分支在相同步幅设置下输出多尺度特征 $\{F_s^l\}, \{F_s^r\}$ ，并通过后续模块中的 1×1 投影对齐通道维度。为进一步缩小轻量分支与全量分支的表征差距，训练阶段引入损失函数引导的跨分支表征一致性约束，从而在不改变推理结构的情况下提升整体鲁棒性与几何一致性。

3.3.3 极线特征增强模块

3.3.3.1 设计目标与总体思路

极线特征增强模块的核心目标是：在不构建高维代价体、不中断端侧实时性的前提下，沿极线方向建立低开销的跨视图注意力，显式增强与关键点相关的几何一致性。这一目标紧扣前述两类矛盾：全图稠密匹配带来的计算冗余，以及左

右对称分支导致的重复特征开销。考虑到左视图由全量分支提取、表征更充分，极线特征增强模块以右视图特征作为查询，并以左视图特征构造键和值，把跨视图交互约束在水平扫描线上，通过一维注意力将左视图的几何一致性信息注入右分支表征，为后续三维求解提供判别性输入。为便于理解该计算过程，图3-8给出了沿同一行进行相关性计算与加权聚合的示意。




图3-8 极线交叉注意力计算示意图：右视图特征作为查询，左视图特征作为键和值，沿水平极线在视差窗口内计算权重并对值加权聚合。

3.3.3.2 输入压缩与查询-键构建

设左右分支特征为 $\mathbf{F}_l, \mathbf{F}_r \in \mathbb{R}^{C \times H \times W}$ 。由于整体框架采用“左重右轻”的非对称分工，极线特征增强模块的目标是以低开销方式将左分支（全量分支）的高保真几何/语义信息回填并增强右分支（小分支）表征。因此，我们将右分支特征作为查询以其当前位置为“锚点”沿极线发起匹配，而将左分支特征构造键和值作为可检索的“记忆库”：键用于提供更强判别性的跨视图匹配依据，值用于在匹配权重引导下输出更充分的可聚合信息。为构造沿极线的交叉注意力，先对通道做轻量压缩并区分查询/键/值：

$$\mathbf{q} = \phi_q(\mathbf{F}_r), \quad \mathbf{k} = \phi_k(\mathbf{F}_l), \quad \mathbf{v} = \phi_v(\mathbf{F}_l), \quad \mathbf{q}, \mathbf{k}, \mathbf{v} \in \mathbb{R}^{C' \times H \times W}, \quad (3-5)$$

其中 ϕ_q, ϕ_k, ϕ_v 为 1×1 卷积 + 归一化（可选分组卷积），分别将右分支特征映射为查询向量，并将左分支特征映射为键和值，以在控制计算开销的同时对齐跨视图表征维度。

3.3.3.3 极线注意力与加权聚合

在立体校正条件下，搜索限定在同一行 $y = v$ 的视差窗口 $\mathcal{D} = \{0, \dots, D-1\}$ 。此处 $d \geq 0$ 表示左视图特征相对于右视图特征在水平方向上的正向偏移，与标准双目约定（视差 $d = u_l - u_r \geq 0$ ，即同一物点在左图中的横坐标不小于在右图中的横坐标）一致，在特征图坐标下同样成立。对每个位置 (u, v) 计算右视图查询

$\mathbf{q}(u, v)$ 与左视图键 $\mathbf{k}(u + d, v)$ 的相关分数:

$$s(u, v, d) = \frac{\langle \mathbf{q}(u, v), \mathbf{k}(u + d, v) \rangle}{\sqrt{C'}}, \quad d \in \mathcal{D}, \quad (3-6)$$

并在视差维做 softmax 得到注意力权重

$$\alpha(u, v, d) = \frac{\exp(s(u, v, d))}{\sum_{d' \in \mathcal{D}} \exp(s(u, v, d'))}. \quad (3-7)$$

利用注意力权重对左视图的值向量 $\mathbf{v}$ 加权聚合, 得到与 (u, v) 对齐的几何增强向量

$$\mathbf{g}(u, v) = \sum_{d \in \mathcal{D}} \alpha(u, v, d) \mathbf{v}(u + d, v). \quad (3-8)$$

图 3-9 对上述“沿极线计算注意力权重并加权汇聚左视图信息以增强右分支表征”的过程进行了直观示意。




图 3-9 极线注意力与加权聚合过程示意图

再与右视图局部特征融合输出

$$\hat{\mathbf{q}} = \psi([\mathbf{q}, \mathbf{g}]), \quad (3-9)$$

其中 $\psi(\cdot)$ 为 1×1 卷积, 用于将右视图局部语义 $\mathbf{q}$ 与沿极线汇聚得到的几何增强向量 $\mathbf{g}$ 进行通道融合与映射, 输出供后续模块使用的增强特征 $\hat{\mathbf{q}}$ 。

3.3.3.4 复杂度分析与端侧友好性

在默认全宽搜索时, 复杂度为 $\mathcal{O}(H W^2 C')$, 但特征通常在 $1/16$ 或更低分辨率上计算, W 显著缩小; 若根据场景设定最大视差 $D_{\max}$, 搜索可裁剪为 $\mathcal{O}(H W D_{\max} C')$, 便于在移动 SoC/NPU 上保持确定时延。EFEM 输出的 $\hat{\mathbf{q}}$ 携带“沿极线的跨视图一致性”信息, 可直接为后续三维求解提供更具判别性的关节相关表征, 从而在不增加代价体的情况下提升双目几何推断的稳定性。

3.3.4 可微加权三角化姿态求解器

可微加权三角化姿态求解器的核心目标是: 在双目视图条件下, 将左/右视图的二维关键点观测与相机模型融合为三维关节坐标, 并在深度学习框架中保持端到端可训练性。为此, 本节将传统双目三角化改写为可微的加权最小二乘问题, 并引入由特征图预测的视图置信度权重, 以增强在遮挡与误检情况下的鲁棒性。

3.3.4.1 设计目标与总体思路

在深度学习框架下直接使用传统三角化存在两个关键问题：1) 二维关键点检测存在噪声，遮挡、模糊或复杂姿态会带来较大误差；2) 若通过 $\arg \max$ 从热力图提取二维坐标则不可导，三维监督信号无法反向传播至热力图网络。具体而言，若将热力图峰值位置作为二维观测

$$(u_{c,j}, v_{c,j}) = \arg \max_{(u,v) \in \Omega} H_{c,j}(u, v), \quad (3-10)$$

其中 $c \in \{l, r\}$ 分别表示左/右视图， $(u_{c,j}, v_{c,j})$ 为第 j 个关节在视图 c 中的像素坐标， $H_{c,j}$ 为由特征图 $\mathbf{F}_c$ 经热力图头 $\phi_h(\cdot)$ 预测得到的关节热力图。由于 $(u_{c,j}, v_{c,j})$ 是离散索引，对 $H_{c,j}$ 几乎处处不可导，此时无论采用双目深度测量公式（视差 $d_j = u_{l,j} - u_{r,j}$ 与深度 $Z_j = \frac{fB}{d_j + \epsilon}$ ，见式(3-2)）还是采用后续的三角化线性系统求解（ $\mathbf{A}_{c,j}$ 由 $u_{c,j}, v_{c,j}$ 构造），三维监督对热力图的梯度都将被 $\arg \max$ 截断。以双目深度测量为例，其梯度链路满足

$$\frac{\partial \mathcal{L}_{3D}}{\partial H_{c,j}} = \frac{\partial \mathcal{L}_{3D}}{\partial Z_j} \cdot \frac{\partial Z_j}{\partial d_j} \cdot \frac{\partial d_j}{\partial u_{c,j}} \cdot \frac{\partial u_{c,j}}{\partial H_{c,j}} \approx 0, \quad (3-11)$$

其中 $\frac{\partial u_{c,j}}{\partial H_{c,j}}$ 在 $\arg \max$ 下为零或不存在，导致三维误差无法有效反向更新关键点热力图分布。为此，本文采用可微加权三角化：使用软 $\arg \max$ （见式(3-14)–(3-15)）从热力图中提取连续二维坐标以保证可微性，并为左右视图分配可学习置信度权重以增强鲁棒性；将三角化问题转化为加权最小二乘问题，并通过特征值分解求解三维点，从而实现端到端训练。

3.3.4.2 符号定义

沿用前文符号， $c \in \{l, r\}$ 为视图索引， j 为关节索引， $\mathbf{F}_c$ 为骨干特征图， $\mathbf{P}_c \in \mathbb{R}^{3 \times 4}$ 为相机投影矩阵。本节新增以下符号： $\phi_h(\cdot)$ 为关键点热力图头，输出 $H_{c,j} = \phi_h(\mathbf{F}_c)$ ； $\phi_w(\cdot)$ 为置信度预测头，输出关节置信度 $\text{logit } \hat{s}_{c,j} = \phi_w(\mathbf{F}_c)$ ； $w_{c,j} > 0$ 为第 c 个视图对关节 j 的置信度权重。三维关节坐标记为 $\mathbf{X}_j = [X_j, Y_j, Z_j]^\top \in \mathbb{R}^3$ ，其齐次形式为 $\tilde{\mathbf{X}}_j = [X_j, Y_j, Z_j, 1]^\top$ ；二维关键点记为 $\mathbf{x}_{c,j} = [u_{c,j}, v_{c,j}]^\top$ ，齐次形式为 $\tilde{\mathbf{x}}_{c,j} = [u_{c,j}, v_{c,j}, 1]^\top$ 。为简洁起见，后续推导默认省略实例下标 m ，但求解过程在实现中对每个实例均独立执行。设投影矩阵 $\mathbf{P}_c$ 的三行分别为

$$\mathbf{P}_c = \begin{bmatrix} \mathbf{p}_{1,c}^\top \\ \mathbf{p}_{2,c}^\top \\ \mathbf{p}_{3,c}^\top \end{bmatrix} \quad (3-12)$$

为便于复现与工程实现，本文将双目可微加权三角化姿态求解过程总结如算法 3-1 所示。

算法 3-1 可微加权三角化姿态求解（双目）

Input: 双目特征图 $\mathbf{F}_l, \mathbf{F}_r$; 投影矩阵 $\mathbf{P}_l, \mathbf{P}_r$; 热力图头 $\phi_h(\cdot)$; 置信度头 $\phi_w(\cdot)$; 关节数 J

Output: 三维关节坐标 $\{\mathbf{X}_j\}_{j=1}^J$

- 1: 预测热力图: $H_{c,j} \leftarrow \phi_h(\mathbf{F}_c)$, 其中 $c \in \{l, r\}$
- 2: 预测置信度: $\hat{s}_{c,j} \leftarrow \phi_w(\mathbf{F}_c)$, 并令 $w_{c,j} \leftarrow \text{softplus}(\hat{s}_{c,j}) + \epsilon$
- 3: **for** $j \leftarrow 1 \cdots J$ **do**
- 4: **for each** $c \in \{l, r\}$ **do**
- 5: 二维归一化: $p_{c,j}(u, v) \leftarrow \frac{\exp(H_{c,j}(u, v))}{\sum_{(u', v') \in \Omega} \exp(H_{c,j}(u', v'))}$
- 6: 软 argmax: $u_{c,j} \leftarrow \sum_{(u, v) \in \Omega} u \cdot p_{c,j}(u, v)$, $v_{c,j} \leftarrow \sum_{(u, v) \in \Omega} v \cdot p_{c,j}(u, v)$
- 7: 构造线性约束: $\mathbf{A}_{c,j} \leftarrow \begin{bmatrix} u_{c,j} \mathbf{P}_{3,c}^\top - \mathbf{P}_{1,c}^\top \\ v_{c,j} \mathbf{P}_{3,c}^\top - \mathbf{P}_{2,c}^\top \end{bmatrix}$
- 8: **end for**
- 9: 堆叠: $\mathbf{A}_j \leftarrow \begin{bmatrix} \mathbf{A}_{l,j} \\ \mathbf{A}_{r,j} \end{bmatrix}$, $\mathbf{W}_j \leftarrow \text{diag}(\sqrt{w_{l,j}}, \sqrt{w_{l,j}}, \sqrt{w_{r,j}}, \sqrt{w_{r,j}})$
- 10: 加权: $\mathbf{B}_j \leftarrow \mathbf{W}_j \mathbf{A}_j$, $\mathbf{M}_j \leftarrow \mathbf{B}_j^\top \mathbf{B}_j$
- 11: 闭式求解: $\tilde{\mathbf{X}}_j \leftarrow \text{eigmin}(\mathbf{M}_j)$ {或等价地取 $\mathbf{B}_j$ 最小奇异值对应右奇异向量}
- 12: 闭式求解: $\tilde{\mathbf{X}}_j \leftarrow \text{eigenvector corresponding to } \lambda_{\min}(\mathbf{M}_j)$ {取最小特征值对应的特征向量}
- 13: 反齐次化: $\mathbf{X}_j \leftarrow [X_h/W_h, Y_h/W_h, Z_h/W_h]^\top$
- 14: **end for**

3.3.4.3 与热力图的可微连接

首先对热力图进行二维归一化，得到概率分布

$$p_{c,j}(u, v) = \frac{\exp(H_{c,j}(u, v))}{\sum_{(u', v') \in \Omega} \exp(H_{c,j}(u', v'))} \quad (3-13)$$

其中 Ω 为热力图的离散像素集合。软 argmax 对应的二维坐标期望为

$$u_{c,j} = \sum_{(u, v) \in \Omega} u \cdot p_{c,j}(u, v), \quad (3-14)$$

$$v_{c,j} = \sum_{(u, v) \in \Omega} v \cdot p_{c,j}(u, v). \quad (3-15)$$

由于 softmax 与加权求和均为可微操作，故 $\mathbf{x}_{c,j}$ 关于热力图 $H_{c,j}$ 可导，从而三维监督损失能够端到端反向传播。训练与推理阶段均采用软 argmax 提取二维坐标，以保持训练-推理的一致性，避免因坐标提取方式不同引入分布偏移。

3.3.4.4 投影约束与线性化

根据透视投影模型，在齐次坐标下有

$$\tilde{\mathbf{x}}_{c,j} \sim \mathbf{P}_c \tilde{\mathbf{X}}_j \quad (3-16)$$

其中“ $\sim$ ”表示两向量仅差一个尺度因子。为消除尺度因子，引入叉乘约束

$$\tilde{\mathbf{x}}_{c,j} \times (\mathbf{P}_c \tilde{\mathbf{X}}_j) = 0 \quad (3-17)$$

展开后可得两条线性独立方程：

$$(u_{c,j} \mathbf{p}_{3,c}^\top - \mathbf{p}_{1,c}^\top) \tilde{\mathbf{X}}_j = 0 \quad (3-18)$$

$$(v_{c,j} \mathbf{p}_{3,c}^\top - \mathbf{p}_{2,c}^\top) \tilde{\mathbf{X}}_j = 0 \quad (3-19)$$

因此，第 c 个视图对关节 j 提供两个线性约束，可写为 $\mathbf{A}_{c,j} \tilde{\mathbf{X}}_j = 0$ ，其中

$$\mathbf{A}_{c,j} = \begin{bmatrix} u_{c,j} \mathbf{p}_{3,c}^\top - \mathbf{p}_{1,c}^\top \\ v_{c,j} \mathbf{p}_{3,c}^\top - \mathbf{p}_{2,c}^\top \end{bmatrix} \quad (3-20)$$

3.3.4.5 双目线性系统

将左右两视图堆叠，可得整体线性系统

$$\mathbf{A}_j \tilde{\mathbf{X}}_j = 0, \quad \mathbf{A}_j = \begin{bmatrix} \mathbf{A}_{l,j} \\ \mathbf{A}_{r,j} \end{bmatrix} \in \mathbb{R}^{4 \times 4} \quad (3-21)$$

由于二维关键点定位误差、遮挡误检以及相机标定/同步误差等噪声因素，左右两视图给出的线性约束往往无法同时被严格满足，即一般不存在使 $\mathbf{A}_j \tilde{\mathbf{X}}_j = \mathbf{0}$ 成立的非零精确解，因此转化为最小二乘问题：

$$\min_{\|\tilde{\mathbf{X}}_j\|=1} \|\mathbf{A}_j \tilde{\mathbf{X}}_j\|^2 \quad (3-22)$$

其中约束 $\|\tilde{\mathbf{X}}_j\| = 1$ 用于消除齐次表示的比例不确定性：由于 $\tilde{\mathbf{X}}_j$ 以齐次坐标形式出现，若 $\tilde{\mathbf{X}}_j$ 为可行解，则任意非零标量 $\alpha \tilde{\mathbf{X}}_j$ 也对应同一几何点；同时该约束也避免最小二乘在无约束情况下退化到平凡零解。这里的“比例不确定性”源自齐次线性方程的尺度自由度，并不等同于单目重建中的深度尺度模糊；在双目条件下，最终反齐次化后得到的欧式三维坐标仍由相机标定参数（如基线 B 与焦距 f ）确定其绝对尺度。

3.3.4.6 加权最小二乘形式

为提高对噪声的鲁棒性，引入置信度权重 $w_{c,j}$ （双目场景同样常见）。在实际采集中，两视图的观测质量往往不对称：

- 一侧关键点热力图峰值尖锐、另一侧发散或多峰；
- 一侧发生人体自遮挡、出框或强反光导致误检；
- 远距离小视差区域对像素误差更敏感，单侧抖动会被三角测量放大。

因此,给更可靠的视图更大的权重能够显著提升三维求解稳定性。本文令 $w_{c,j}$ 由特征图 $\mathbf{F}_c$ 经置信度预测头 $\phi_w(\cdot)$ 直接预测,并通过 **softplus** 映射保证为正。**softplus** 是常用的正值约束函数,定义为 $\text{softplus}(x) = \ln(1 + e^x)$,其输出恒为正且平滑可导,可避免使用指数映射导致的数值不稳定:

$$w_{c,j} = \text{softplus}(\hat{s}_{c,j}) + \epsilon \quad (3-23)$$

构造对角权重矩阵

$$\mathbf{W}_j = \text{diag}(\sqrt{w_{l,j}}, \sqrt{w_{l,j}}, \sqrt{w_{r,j}}, \sqrt{w_{r,j}}) \quad (3-24)$$

其中每个 $w_{c,j}$ 在对角线上重复两次,是因为对同一关节 j 而言,每个视图 $c \in \{l, r\}$ 会提供两条独立的线性约束(分别来自 $u_{c,j}$ 与 $v_{c,j}$ 对应的两行方程,见式(3-18)–(3-19))。用 $\mathbf{W}_j$ 左乘 $\mathbf{A}_j$ 等价于对 $\mathbf{A}_j$ 的每一行残差进行缩放,从而在最小二乘目标中实现对该视图两条约束的统一加权;同时采用 $\sqrt{w_{c,j}}$ 而非 $w_{c,j}$,可使目标函数展开为标准的加权残差平方和形式 $\sum w_{c,j} r^2$ 。加权线性系统为

$$\mathbf{B}_j = \mathbf{W}_j \mathbf{A}_j \quad (3-25)$$

优化问题变为

$$\min_{\|\tilde{\mathbf{X}}_j\|=1} \|\mathbf{B}_j \tilde{\mathbf{X}}_j\|^2 \quad (3-26)$$

3.3.4.7 特征值求解

上述加权最小二乘问题具有闭式解。由于约束 $\|\tilde{\mathbf{X}}_j\| = 1$ 固定了齐次向量的尺度,可将目标函数转写为 Rayleigh 商并通过特征分解直接求得最优解,从而避免引入迭代优化带来的额外开销与不稳定性。展开目标函数:

$$\|\mathbf{B}_j \tilde{\mathbf{X}}_j\|^2 = \tilde{\mathbf{X}}_j^\top (\mathbf{B}_j^\top \mathbf{B}_j) \tilde{\mathbf{X}}_j \quad (3-27)$$

记

$$\mathbf{M}_j = \mathbf{B}_j^\top \mathbf{B}_j \quad (3-28)$$

则问题转化为

$$\min_{\|\tilde{\mathbf{X}}_j\|=1} \tilde{\mathbf{X}}_j^\top \mathbf{M}_j \tilde{\mathbf{X}}_j \quad (3-29)$$

根据 Rayleigh 商定理, $\tilde{\mathbf{X}}_j^\top \mathbf{M}_j \tilde{\mathbf{X}}_j$ 在 $\|\tilde{\mathbf{X}}_j\| = 1$ 约束下取最小值当且仅当 $\tilde{\mathbf{X}}_j$ 为 $\mathbf{M}_j$ 最小特征值对应的特征向量,即

$$\mathbf{M}_j \tilde{\mathbf{X}}_j = \lambda_{\min} \tilde{\mathbf{X}}_j \quad (3-30)$$

该求解与经典 DLT 三角化中“取 $\mathbf{B}_j$ 的最小奇异值对应右奇异向量”的 SVD 解法等价,因而具有数值稳定、计算高效的优点,并便于在自动微分框架中实现端到端训练。

3.3.4.8 反齐次化

得到齐次解 $\tilde{\mathbf{X}}_j = [X_h, Y_h, Z_h, W_h]^\top$ 后，欧式三维坐标为

$$\mathbf{X}_j = \frac{1}{W_h} \begin{bmatrix} X_h \\ Y_h \\ Z_h \end{bmatrix} \quad (3-31)$$

3.3.4.9 小结

综上，本文面向双目三维姿态任务构建了可微加权三角化姿态求解器：首先通过软 $\arg\max$ 将关键点热力图 $H_{c,j}$ 转换为连续二维观测 $\mathbf{x}_{c,j}$ ，避免 $\arg\max$ 带来的梯度截断；随后由特征图 $\mathbf{F}_c$ 经置信度预测头 $\phi_w(\cdot)$ 得到视图权重 $w_{c,j}$ ，用于在两视图质量不对称（遮挡、模糊、误检或远距离小视差敏感）时自适应调整约束贡献；在此基础上，将双目三角化统一为加权最小二乘形式 $\min_{\|\tilde{\mathbf{X}}_j\|=1} \|\mathbf{W}_j \mathbf{A}_j \tilde{\mathbf{X}}_j\|^2$ 并以特征值/SVD 等价的闭式方式求解齐次三维点，最后经反齐次化得到欧式三维关节坐标 $\mathbf{X}_j$ 。上述设计使三维几何监督能够端到端回传到热力图与置信度分支，从而提升三维关节估计的稳定性和鲁棒性。

3.3.5 跨分支表征一致性约束与损失函数

3.3.5.1 设计目标与总体思路

在“左重右轻”的非对称结构中，全量分支具备更强的表征容量，而轻量分支在通道宽度与网络深度受限的情况下更易受到遮挡、模糊与远距离小视差噪声的影响，从而导致跨视图匹配与三角化求解不稳定。为此，本文在训练阶段引入跨分支表征一致性约束，使轻量分支的中间特征在分布与几何敏感性上与全量分支保持一致，从而在不增加推理开销的前提下提升鲁棒性。

3.3.5.2 跨分支一致性约束（训练期）

训练阶段，为构建一致性约束，额外启用全量分支作为参照路径，与轻量分支在若干中间层输出特征上进行对齐；该参照路径仅用于计算一致性损失，推理阶段可移除，不引入额外时延。为避免两分支相互牵制导致优化不稳定，一致性损失仅对轻量分支反向传播（实现上可对参照分支特征采用停止梯度）。从方法论上看，该策略与特征级知识蒸馏/在线蒸馏一致：全量分支充当教师，轻量分支作为学生，通过中间表征对齐在不增加推理开销的前提下提升轻量分支的几何敏感性 [13–15]。

3.3.5.3 特征对齐损失

设在尺度/阶段集合 $\mathcal{S}$ 上, 轻量分支与全量分支的特征分别为 $\mathbf{F}_s^r$ 与 $\mathbf{F}_s^l$ 。为消除通道维不一致并增强对齐的可学习性, 对两分支特征引入 1×1 投影函数

$$\tilde{\mathbf{F}}_s^r = \phi_s(\mathbf{F}_s^r), \quad \tilde{\mathbf{F}}_s^l = \phi_s(\mathbf{F}_s^l), \quad (3-32)$$

其中 $\phi_s(\cdot)$ 由 1×1 卷积与归一化组成。跨分支特征对齐损失定义为

$$\mathcal{L}_{\text{align}} = \sum_{s \in \mathcal{S}} \frac{1}{C_s H_s W_s} \|\tilde{\mathbf{F}}_s^r - \text{sg}(\tilde{\mathbf{F}}_s^l)\|_2^2, \quad (3-33)$$

其中 $\text{sg}(\cdot)$ 表示停止梯度算子, C_s, H_s, W_s 为对应尺度下特征维度。该损失实质上对轻量分支施加一致性正则, 引导其学习与全量分支相近的中间表征。

3.3.5.4 总体损失函数

由于 RT-Pose 数据集仅提供三维关节坐标真值而不提供二维关键点标注, 本文直接采用 MPJPE 作为唯一的任务监督信号, 不引入独立的二维热力图损失。这一设计使所有二维检测分支均通过可微三角化接收来自三维几何约束的端到端监督, 避免了二维与三维目标之间可能存在的监督不一致。MPJPE 的定义为

$$\mathcal{L}_{\text{MPJPE}} = \frac{1}{J} \sum_{j=1}^J \|\hat{\mathbf{X}}_j - \mathbf{X}_j^{gt}\|_2, \quad (3-34)$$

其中 $\hat{\mathbf{X}}_j$ 为由第 3.3.4 节可微加权三角化姿态求解器输出的欧式三维关节坐标, $\mathbf{X}_j^{gt}$ 为对应的真值三维坐标, J 为关节数。由于 $\hat{\mathbf{X}}_j$ 由双目二维观测 $\mathbf{x}_{l,j}, \mathbf{x}_{r,j}$ 与投影矩阵 $\mathbf{P}_l, \mathbf{P}_r$ 通过投影约束构造并三角化求解得到, 故 $\mathcal{L}_{\text{MPJPE}}$ 的梯度可沿“二维观测 $\rightarrow$ 投影/三角化几何 $\rightarrow$ 三维点”的链路端到端回传至热力图与置信度权重分支, 实现由二维投影约束得到稳定的三维监督。

最终训练目标写为

$$\mathcal{L} = \mathcal{L}_{\text{MPJPE}} + \lambda_{\text{align}} \mathcal{L}_{\text{align}}, \quad (3-35)$$

其中 λ_{align} 为跨分支表征一致性约束权重系数。实践中可在训练后期对 λ_{align} 进行衰减或在微调阶段移除一致性项, 以减弱对齐约束对主任务优化的干扰。

3.3.5.5 小结

综上, 本节围绕“左重右轻”非对称结构引入了跨分支表征一致性约束: 在训练阶段额外启用全量分支作为参照路径, 通过停止梯度的逐尺度特征对齐损失 $\mathcal{L}_{\text{align}}$ 引导轻量分支学习与全量分支相近的中间表征, 弥补因通道宽度与网络深度受限导致的表征差异; 推理阶段参照路径被移除, 不引入额外计算开销。最终

训练目标将三维几何监督 $\mathcal{L}_{\text{MPJPE}}$ 与跨分支一致性约束 $\mathcal{L}_{\text{align}}$ 联合优化, 使三维监督信号可端到端回传至热力图、置信度权重及轻量分支特征, 从而在精度与端侧效率之间取得平衡。

3.4 实验评估

本节通过三组实验对所提方法进行系统评估。(1) 对比实验: 在 RT-Pose 数据集上, 将本文方法与单目基线及基于稠密深度先验的两阶段级联方法进行精度与效率的全面对比, 重点关注绝对 MPJPE 与端侧推理时延; (2) 多人可扩展性分析: 统计人数从 1 到 10 场景下本文方法与典型基线的端到端推理时延变化, 验证自底向上整图推理链路的时延稳定性优势; (3) 消融实验: 逐一移除或替换非对称骨干、极线特征增强模块、可微加权三角化求解器与跨分支一致性约束, 定量评估各模块的贡献。RT-Pose 数据集提供配对双目 RGB 图像与三维骨架真值, 并包含挥手、抬腿、随机姿态、正常站立与坐姿等多种动作类别, 适合评估方法在不同遮挡程度与视差范围下的鲁棒性。

3.4.1 实验设置

3.4.1.1 数据集与预处理

本文在 RT-Pose 数据集上进行训练与评估, 并仅使用其双目 RGB 图像作为输入 (不引入雷达或激光雷达模态)。人体骨架采用与 Human3.6M 兼容的 17 个关键点定义, 即骨盆 (作为根节点)、左髋、右髋、左膝、右膝、左踝、右踝、脊柱、胸部、颈部、头部、左肩、右肩、左肘、右肘、左腕与右腕。为避免同一序列内相邻帧的强相关性造成数据泄漏, 采用序列级划分, 按 80%/10%/10% 的比例分别构建训练集、验证集与测试集, 并尽量保持不同动作类别与室内/室外场景在各子集中的分布一致。对双目图像对进行极线校正, 使左右视图对应点满足水平扫描线约束, 从而与极线特征增强模块的一维视差搜索假设一致; 相机内外参与投影矩阵采用数据集提供的标定结果, 记为 $\mathbf{P}_l, \mathbf{P}_r$ 。本文在实现中直接读取数据集标定参数构建投影矩阵, 不额外假设固定基线 B ; 若需要显式基线, 可由外参分解得到。需要指出的是, 极线校正与相机标定误差会导致跨视图对应偏移, 并通过三角测量放大为深度误差, 从而影响最终 MPJPE。本文通过可学习置信度权重对不可靠视角进行降权, 并在训练中采用左右交换的对称增强以提升几何一致性, 但未对标定扰动进行系统量化, 后续可通过对外参注入噪声评估敏感性。训练与评测阶段输入分辨率统一为 640×480 。所有基线方法均在上述相同划分上进行微调与评测, 以保证对比的公平性。考虑到本文方法以双目几何为核心, 而常用标准基准 (如 Human3.6M、MPI-INF-3DHP) 不提供与之配套的双目

标定与同步数据（或采集协议差异较大），本文本章实验暂仅在 RT-Pose 上进行验证，并在后续工作中扩展到更多标准化双目数据以进一步评估泛化性。此外，为缓解“仅单数据集验证”的局限，本章进一步引入 MADS 数据集^[5]开展跨数据集泛化评测：保持 RT-Pose 训练权重不变，直接在 MADS 上进行零样本测试，并仅报告整体平均 MPJPE 以刻画域外鲁棒性。

表 3-2 RT-Pose 数据集与标定信息（本文使用项）

条目	说明
总帧数/序列数	7.2 万帧 / 240 个序列 [4]
动作类别	6 类（含挥手、抬腿、随机姿态、正常站立、坐姿等） [4]
输入模态	双目 RGB（不使用雷达/LiDAR）
骨架定义	17 关键点（与 Human3.6M 兼容）
标定参数	数据集提供投影矩阵 $\mathbf{P}_l, \mathbf{P}_r$ （包含内外参）
基线/焦距	由标定分解得到；本文直接使用 $\mathbf{P}_l, \mathbf{P}_r$ 进行极线校正与三角化

3.4.1.2 训练配置

模型采用 PyTorch 实现并以端到端方式训练，优化器使用 AdamW，学习率为 2×10^{-4} ，权重衰减为 1×10^{-4} ，批大小为 128，训练 100 个 epoch。数据增强包括随机颜色扰动、亮度调整、随机裁剪以及均值方差归一化等；同时引入水平翻转并同步交换左/右视图的对称增强策略，以促使网络学习双目成像的内在几何一致性而非依赖固定的分支角色分配。训练目标与第 3.3.5 节一致，采用式 3-35，其中 λ_{align} 固定为 0.1。

3.4.1.3 评价指标与效率评测

精度方面采用绝对 MPJPE（单位 mm）作为主要评价指标：在左相机坐标系下直接计算预测三维关节与真值三维关节的欧氏距离（mm），计算方式见式 2-8。对所有基线方法与本文方法统一该评测约定与评测脚本。由于双目几何与相机标定提供了绝对尺度，因此使用绝对 MPJPE 更能反映实际空间定位误差；效率方面报告模型参数量、计算量（FLOPs）以及端侧平均推理延迟（ms）。端侧推理延迟在 Xiaomi 14（Snapdragon 8 Gen3, 16GB RAM）上测得，推理引擎采用 MNN，计算精度为 FP16，CPU 以 ARMv8.2 指令集的 4 线程模式运行；测试时输入分辨率为 640×480 、批大小为 1，计时范围包含模型前向与必要后处理，不包含图像解码与 I/O 开销，所有结果在测试集上取平均，并在正式计时前进行若干次预热以消除冷启动与缓存波动的影响。除报告测试集平均时延外，进一步统计人数从 1 到 10 的场景下端到端推理时延变化，用于评估多人可扩展性（输入

640 × 480、Xiaomi 14/MNN/FP16/4 线程协议保持不变)。

3.4.2 实验结果

3.4.2.1 对比设置

本文在 RT-Pose 测试集上对不同方法进行对比：单目方法仅使用左视图 I_l 作为输入；两阶段双目方法使用双目输入 (I_l, I_r) 并遵循基于稠密深度先验的级联范式，即先估计稠密深度/视差，再结合二维关键点进行三维回代/融合得到三维姿态；本文方法在双目输入下端到端预测三维关节。所有方法均以左相机坐标系为参考，报告绝对 MPJPE (mm)，并统一输入分辨率为 640 × 480。

3.4.2.2 基线方法

参考相关公开工作的对比思路，本文将对对比方法划分为单目方法与基于稠密深度先验的级联范式两类：

- 单目方法（仅左视图 I_l ）：选取可复现的代表性单目三维姿态估计网络作为基线，包括 SimpleBaseline、JointFormer 与 RTMW3D。
- 基于稠密深度先验的级联范式（双目输入 (I_l, I_r) ）：该范式与 3.2.3.1 节所述两阶段流程一致，先通过双目匹配估计稠密深度/视差，再与二维关键点结合进行三维回代/融合得到三维姿态。代表方法包括 RTMO+SGBM（传统立体匹配）、RTMO+MobileStereoNet（学习式立体网络）以及 MobiDepthPose。

上述基线覆盖了端侧场景中常见、易落地的单目与双目两阶段管线，便于在缺少端到端双目三维姿态工作可直接对比的情况下，定量评估本文方法在精度与效率上的综合收益。需要说明的是，部分单目基线（如 RTMW3D）并非以端侧部署为主要设计目标，其参数量与 FLOPs 偏大；本文将其纳入对比主要用于给出在相同数据划分下的“强表征上限”参考，并通过同时报告参数量、FLOPs 与端侧时延，避免仅凭精度排名造成不公平解读。对于级联范式基线，本文统一将稠密深度/视差估计作为前置模块，并明确计时范围包含必要后处理（不含 I/O），以保证端侧评测口径一致。

3.4.2.3 实验对比

表 3-3 给出了 RT-Pose 上的对比结果。总体上，本文方法在平均指标上达到 158.6 mm，显著优于单目基线与两阶段级联范式：相较于最佳单目方法 RTMW3D (307.3 mm)，绝对误差降低 148.7 mm；相较于最佳级联范式 RTMO+MobileStereoNet (202.0 mm)，绝对误差降低 43.4 mm。进一步地，在坐姿等遮挡更强、远距离小视差更敏感的场景下，级联范式易受稠密深度误匹配与关节采样不稳定影响（例

表 3-3 RT-Pose 数据集上的实验对比结果（数据来自公开 benchmark）。单目方法仅使用左视图 I_l ；两阶段双目方法遵循基于稠密深度先验的级联范式（先估计稠密深度/视差，再结合二维关键点回代/融合得到三维姿态）；本文方法在双目输入下端到端预测三维关节。所有 MPJPE 为左相机坐标系下的绝对 MPJPE (mm)。[†] 标记的方法依赖传统立体匹配算法 (SGBM)，其参数量与 FLOPs 仅统计神经网络部分，不含 SGBM 的运行时开销。

方法	MPJPE (mm)↓						效率	
	挥手	抬腿	随机姿态	正常站立	坐姿	平均	参数量 (M)	FLOPs(G)
单目方法（仅 I_l ）								
Simple Baseline [11]	353.2	342.1	362.6	422.1	391.8	374.3	23.48	67.19
JointFormer [17]	332.1	312.8	342.1	369.5	329.8	337.2	48.61	160.66
RTMW3D [18]	298.3	292.8	327.4	331.2	287.0	307.3	92.30	136.56
两阶段方法（双目 (I_l, I_r), 基于稠密深度先验的级联范式）								
MobiDepthPose [19]	221.3	215.7	207.5	208.9	223.3	215.3	7.27	10.36
RTMO [20]+SGBM [†] [21]	205.0	208.0	219.7	224.6	202.4	211.9	9.80	12.13
RTMO [20]+MobileStereoNet [22]	193.6	187.3	208.9	219.6	200.5	202.0	12.09	116.12
本文方法	162.3	156.9	163.9	177.4	132.6	158.6	11.70	13.93

如 200.5 mm 降至 132.6 mm，降低 67.9 mm），而本文通过端到端的双目特征交互与可微几何求解将计算集中于关节相关区域，从而获得更稳定的三维定位精度。

值得注意的是，采用学习式双目深度网络（RTMO+MobileStereoNet）替代传统匹配时，深度估计模块本身引入了额外的网络参数与计算量，使得整体 FLOPs 显著上升至 116.12 G；而本文方法以端到端神经网络完成双目特征交互与关节级几何求解，在 13.93 G FLOPs 下取得了最优精度。

3.4.2.4 跨数据集泛化（RT-Pose → MADS）

为进一步检验本文方法对不同动作分布与采集协议的域外鲁棒性，本文将第三章在 RT-Pose 上训练得到的最终权重不做任何微调，直接在 MADS 数据集^[5]上进行测试。评测口径与 RT-Pose 保持一致：输入为经过极线校正的双目图像对，分辨率统一为 640×480 并同步缩放相机内参；三维误差以左相机坐标系下的 MPJPE (mm) 衡量。考虑到本文主要回应“单数据集”质疑，此处仅报告 MADS 测试集上的整体平均 MPJPE。

表 3-4 跨数据集泛化结果：在 RT-Pose 上训练后直接在 MADS 上测试（零样本），仅报告整体平均 MPJPE (mm)。

数据集	Avg MPJPE (mm)↓
MADS ^[5]	(待补)

3.4.2.5 定性可视化分析

为直观展示本文方法在多人遮挡场景下的三维恢复效果，图3-10给出了RT-Pose数据集上的定性可视化结果示例。在拥挤多人场景中，部分关节在单一视角下容易因遮挡、模糊或背景干扰出现热力图峰值发散、多峰或缺失，从而导致三维重建不稳定。本文在双目特征层引入极线特征增强模块，在极线约束下利用另一视角的一维视差搜索增强几何一致性表征，使跨视图交互更具可解释性。进一步地，可微加权三角化姿态求解器通过软 argmax 提供可微的二维观测，并由置信度权重对遮挡/误检视角进行降权，从而抑制不可靠观测对加权最小二乘求解的干扰。综合上述设计，本文方法能够在多人遮挡条件下输出更稳定、更加一致的三维骨架结构。




图 3-10 RT-Pose 数据集上的定性可视化结果示例（红色骨架为真值，其他颜色骨架为预测结果）。

3.4.2.6 多人场景效率与可扩展性

为验证自底向上整图推理链路在多人场景下的效率优势，统计人数从1到10的端到端推理时延变化。如图3-11所示，自顶向下的实例级管线（以单目RTMW3D为例）通常包含“按人循环”的裁剪与回归步骤，导致时延随人数显著增长；而本文方法依托整图一次前向与稀疏关节级几何求解，曲线更为平坦。表3-5给出了关键人数点的数值对比：本文方法在1人与10人场景下时延分别为116.0ms与117.3ms，仅增长约1.1%，体现出在拥挤多人场景下更稳定的端侧实时性。该稳定性与第3.3.4节可微加权三角化姿态求解器的设计一致：三维求解阶段仅对 $M \times J$ 稀疏关节特征进行计算，不构建稠密深度/代价体，从而避免“无效像素”主导端侧时延。值得注意的是，RTMO+MobileStereoNet（级联范式）在不同人数下时延均为189.2ms，保持恒定。这是因为该级联范式的计算瓶颈在于MobileStereoNet的稠密深度估计阶段——该阶段对整幅图像进行逐像素深度推断，其计算量仅取决于输入分辨率而与场景中的人数无关；后续的关节采样与三维恢复开销相对较小，不构成时延主导因素。尽管该级联范式同样具有人数无关的时延特性，但其端到端时延（189.2ms）仍显著高于本文方法（116.0–117.3ms），且在精度上（202.0mm vs 158.6mm）也存在较大差距，表明本文方法在精度与效率两方面均具备优势。




图 3-11 端侧推理时延随人数变化的对比（Xiaomi 14/MNN/FP16/4 线程端侧测量）。

3.4.3 消融实验

以下所有消融实验均在 RT-Pose 测试集上进行，评价指标为左相机坐标系下的绝对 MPJPE (mm)，其余训练与评测协议与主实验保持一致。除“移除/替换模块”的对比外，本文也在各关键模块内部给出逐步增量的组件级消融（如拼接融合

表 3-5 不同人数下的端到端推理时延对比 (ms)。

方法	1 人	5 人	10 人
本文方法 (双目, 自底向上)	116.0	116.9	117.3
RTMW3D (单目, 自顶向下)	436.5	1236.8	2396.4
RTMO+MobileStereoNet (级联范式)	189.2	189.2	189.2

→EFEM、argmax→软 argmax→置信度加权), 用于刻画设计收益的累积过程。

3.4.3.1 模块贡献综合对比

为综合呈现各核心模块对最终三维定位精度的贡献, 表 3-6 以完整方法为基准, 逐一将各模块替换为对照配置 (其余模块保持默认), 并按精度退化幅度从大到小排列, 直观展示各设计的必要性。各行数据分别来源于后续各模块专项消融, 此处汇总以便整体参考。

表 3-6 核心模块贡献汇总: 各模块对 Avg MPJPE 的独立贡献 (RT-Pose 测试集; 每行仅替换单一模块, 其余保持本文默认)。

配置描述	Avg MPJPE(mm)↓	Δ vs. 完整方法
完整方法 (非对称 +EFEM+DWT+Align)	158.6	—
EFEM → 无跨视图交互	374.5	+215.9
DWT → 像素级三角化	277.7	+119.1
EFEM → 拼接 +1 × 1 卷积	224.8	+66.2
非对称骨干 → 对称轻量骨干	182.0	+23.4
Align → 移除 ($\lambda_{\text{align}} = 0$)	175.3	+16.7

注: 各行数据详见第 3.3.2–3.3.4 节对应消融分析; Δ 均为正值, 数值越大表明该模块贡献越显著。

3.4.3.2 非对称双目骨干网络 (左重右轻) 的贡献

为验证本文“左重右轻”的非对称双目骨干网络设计在精度与效率权衡上的有效性, 本文将左右分支的骨干网络配置进行对比消融, 结果如表 3-7 所示。除左右分支的骨干网络配置外, 其余模块 (极线特征增强模块、可微加权三角化姿态求解器与跨分支表征一致性约束) 及训练/评测协议均保持一致。

由表可知, 对称全量方案 (18.8M/22.5G) 取得最低 MPJPE (154.5mm), 但其 FLOPs 较本文非对称方案 (13.9G) 高出约 62%。在移动端 CPU/NPU 等资源受限平台上, 骨干网络通常是端到端推理的主要开销来源, FLOPs 与访存压力的增加往往会带来更高的实际时延与能耗。因此, 在面向端侧的精度-效率权衡中, 4.1 mm 的精度差异在多数应用场景中处于可接受范围, 而显著的计算增幅可能

表 3-7 非对称双目骨干网络（左重右轻）消融（RT-Pose 测试集）。

双目骨干网络配置	参数量 (M)↓	计算量 (G)↓	MPJPE(mm)↓
左轻量 + 右轻量（对称轻量）	7.6	9.2	182.0
左全量 + 右全量（对称全量）	18.8	22.5	154.5
左全量 + 右轻量（非对称，本文）	11.7	13.9	158.6

直接决定系统能否满足实时性约束。综合考虑，本文选择“左全量 + 右轻量”的非对称配置，以可控的精度代价换取更显著的端侧效率收益。

3.4.3.3 极线特征增强模块的贡献

为验证极线特征增强模块的有效性，本文对不同跨视图特征交互方式进行对比，结果如表 3-8 所示。可以看出，简单的“拼接 + 1×1 卷积”虽能带来明显收益，但由于缺少显式几何约束，跨视图信息融合仍可能引入噪声匹配；相比之下，极线特征增强模块在极线约束下将跨视图交互限制在一维视差窗口内，使匹配更具几何可解释性，从而进一步显著降低误差。

表 3-8 不同跨视图特征交互方式的对比（RT-Pose 测试集）。

特征增强模块	MPJPE(mm)↓
无跨视图交互	374.5
拼接 + 1×1 卷积	224.8
极线特征增强模块（本文）	158.6

需要指出的是，“无跨视图交互”设置下虽然仍使用双目输入进行三角化，但右视图轻量分支在遮挡与弱纹理场景下更易出现关键点多峰与定位抖动，导致视差误差在远距离小视差区域被放大，进而使最终三维误差接近单目基线水平。EFEM 通过沿极线引入低开销的跨视图一致性信息，可显著提升右分支观测的稳定性，从而释放双目几何在该数据集上的优势。

为进一步分析极线特征增强模块在不同视差搜索范围下的敏感性，本文以 $D_{\max}$ 作为关键超参数进行对比，如表 3-9 所示。 $D_{\max}$ 过小可能导致真实视差被截断，从而限制跨视图交互； $D_{\max}$ 过大则会引入更多匹配候选，增加噪声相关风险并带来额外计算开销（尽管该模块仍保持一维视差搜索）。实践中可在覆盖数据集中主要视差分布的前提下选取中等范围作为默认设置。

表 3-9 极线特征增强模块的视差搜索范围 $D_{\max}$ 敏感性分析 (RT-Pose 测试集; $D_{\max}$ 以 EFEM 所在特征图坐标计)。

$D_{\max}$	MPJPE(mm)↓	备注
32	171.5	视差范围较小
64	162.0	—
96	158.6	默认设置 (主实验)
128	160.2	视差范围较大

3.4.3.4 可微加权三角化姿态求解器的贡献

为分析三维恢复策略对最终三维定位精度的影响,将本文的可微加权三角化姿态求解器与两种简化方案进行对比,结果如表 3-10 所示。”2D 关键点匹配 (像素级) + 三角化” 受限于像素级定位精度,视差误差在远距离小视差场景会被显著放大;”直接深度回归” 虽可学习一定几何先验,但缺少显式投影约束,面对遮挡与误检时更易不稳定。相比之下,本文求解器使用软 argmax 从热力图提取可微的二维观测,并由置信度权重抑制遮挡/模糊视角的不可靠约束,从而在双目条件下获得更稳健的三维解。

表 3-10 不同三维恢复策略对比 (RT-Pose 测试集)。

三维恢复策略	MPJPE(mm)↓
2D 关键点匹配 (像素级) + 三角化	277.7
直接深度回归	225.1
可微加权三角化姿态求解器 (本文)	158.6

为进一步刻画“可微性”与“置信度加权”两条设计的贡献,本文将求解器拆分为二维坐标提取方式与加权机制两部分进行消融,结果如表 3-11 所示。由于 argmax 为离散算子,MPJPE 的梯度无法回传到热力图分支,端到端优化链路会被截断;软 argmax 提供可微的二维观测,使 3D 误差能够沿“2D 观测 → 投影约束 → 加权最小二乘求解 → 3D 关节”回传,从而促使热力图与几何约束更一致。进一步地,双目视角下常见“一侧清晰、另一侧遮挡/模糊/误检”等情况,置信度权重能够为可靠视角分配更大权重,抑制不可靠约束对三维解的干扰,从而显著提升稳定性。

3.4.3.5 跨分支表征一致性约束的贡献

针对”左重右轻”非对称结构可能带来的表征差异,本文在训练阶段引入跨分支表征一致性约束以提升轻量分支的几何敏感性与稳定性。表 3-12 对比了不

表 3-11 可微加权三角化姿态求解器的组件级消融 (RT-Pose 测试集)。

二维坐标提取	置信度加权	MPJPE(mm)↓
argmax (不可导)	否 ($w_{c,j} = 1$)	182.5
软 argmax (可导)	否 ($w_{c,j} = 1$)	168.0
软 argmax (可导)	是 (置信度预测头预测 $w_{c,j}$)	158.6

同一致性约束形式的效果。可以看出,相比不使用一致性约束,引入特征对齐正则能够持续降低误差;其中” 1×1 对齐卷积 +MSE”在连续特征空间对齐任务上更为适配,既能处理通道维不一致,又能以稳定的二范数度量约束轻量分支逐步靠近参照分支的表示空间。

表 3-12 跨分支一致性约束形式对比 (RT-Pose 测试集)。

一致性约束形式	MPJPE(mm)↓	提升 (%)
不使用一致性约束	175.3	—
KL 散度对齐	168.9	3.7%
余弦相似度对齐	165.2	5.8%
1×1 对齐卷积 +MSE (本文)	158.6	9.5%

为进一步分析一致性约束权重系数 λ_{align} 对最终精度的影响,本文以” 1×1 对齐卷积 +MSE”作为约束形式,仅调整 λ_{align} 进行消融,结果如表 3-13 所示。 $\lambda_{\text{align}} = 0$ 等价于不使用一致性约束,轻量分支缺乏来自全量分支的表征引导,三维恢复精度较低;随着 λ_{align} 增大,对齐约束逐步缩小两分支的中间表征差异,MPJPE 持续下降;但当 λ_{align} 过大时,一致性约束在总损失中占比过高,可能干扰主任务 $\mathcal{L}_{\text{MPJPE}}$ 的优化方向,导致精度回升。实践中取 $\lambda_{\text{align}} = 0.1$ 作为默认值,可在精度与训练稳定性之间取得良好平衡。

表 3-13 跨分支一致性约束权重系数 λ_{align} 敏感性分析 (RT-Pose 测试集)。

λ_{align}	MPJPE(mm)↓	备注
0	175.3	无一致性约束
0.01	168.4	—
0.05	162.1	—
0.1	158.6	默认设置 (主实验)
0.5	161.0	—
1.0	165.8	约束过强,干扰主任务优化

3.5 本章小结

本章围绕端侧多人三维人体姿态估计任务，针对现有双目方法在稠密级联开销与左右对称冗余两方面的瓶颈，提出了一种轻量化非对称双目学习框架，并从四个相互协同的模块层面展开系统设计。

在网络结构方面，本章设计了“左重右轻”的非对称双目骨干网络：左分支（CSPDarknet-M, $\text{width_multiple}=1.0$ ）保持完整表征容量作为跨视图交互的主要信息源，右分支（CSPDarknet-N, $\text{width_multiple}=0.5$ ）将通道宽度压缩至全量分支的 50%，将整体骨干参数量与 FLOPs 分别降低至对称全量方案的约 62% 与 62%，从结构层面打破传统对称双分支的计算冗余。

在跨视图特征交互方面，本章引入极线特征增强模块（EFEM），将跨视图匹配从二维全图搜索限制在水平极线上的一维视差窗口内，以右分支特征为查询、左分支特征为键和值完成低开销的几何一致性注入，避免显式构建高维代价体，同时为后续三维求解提供更具判别性的关节相关表征。

在三维求解方面，本章设计了可微加权三角化姿态求解器：通过软 argmax 将热力图转化为连续二维观测，绕过 argmax 的梯度截断；引入由特征图预测的置信度权重，对左右视图的约束贡献进行自适应调整；将双目三角化统一为加权最小二乘形式并以闭式特征分解求解，使三维 MPJPE 监督信号可端到端回传至热力图与置信度权重分支，消除两阶段级联引入的误差累积。

在训练策略方面，本章提出跨分支表征一致性约束，通过逐尺度特征对齐损失引导轻量右分支向全量左分支的中间表征靠拢，弥补非对称设计带来的表征差距；该约束仅作用于训练阶段，推理时自动移除，不引入额外时延。

在 RT-Pose 数据集上的实验结果表明，本文方法在平均绝对 MPJPE 上达到 158.6 mm，相较最优单目基线 RTMW3D 降低 148.7 mm，相较最优级联范式 RTMO+MobileStereoNet 降低 43.4 mm，同时整体网络参数量仅为 11.70 M，FLOPs 为 13.93 G。端侧推理延迟测试表明，在 Xiaomi 14（MNN/FP16/4 线程）上，从 1 人到 10 人场景的延迟仅从 116.0 ms 增至 117.3 ms，体现出自底向上整图推理链路在多人场景下的稳定时延优势。

上述设计共同验证了“以关节任务为中心”组织双目特征交互与三维恢复的可行性：在不依赖稠密深度中间表示的前提下，通过结构轻量化、几何约束驱动的特征增强与端到端可微求解，将精度与端侧效率统一于同一框架，为后续章节的硬件感知部署与量化压缩提供了结构基础。

第 4 章 硬件感知部署与量化压缩

本章面向第三章所提轻量化双目三维人体姿态估计框架的端侧落地问题，围绕 Snapdragon 8 Gen3 CPU 平台上的硬件感知部署与量化压缩展开研究。研究重点不在于比较不同硬件后端，而在于针对既定端侧 CPU 执行环境，建立从性能瓶颈定位到混合精度设计与实证验证的完整方法链。具体而言，本文首先通过实测延迟拆解与 Roofline 分析定位性能瓶颈，随后结合量化敏感性分析设计分层混合精度方案，并通过后训练量化（PTQ）完成部署，最终以对比实验与消融实验评估量化后的精度-效率综合表现。

4.1 研究背景

多人三维人体姿态估计正从离线精度导向的算法研究转向端侧实时应用。在移动机器人、智能安防与沉浸式交互等场景中，系统不仅需要满足严格时延约束，还需尽量避免原始图像上传云端带来的隐私风险与网络依赖。因此，如何将三维姿态估计模型稳定部署到移动端，已成为影响其实用化的重要问题。

然而，服务器级 GPU 上有效的网络结构并不能直接迁移到移动端 CPU。对于本文的整图双目推理模型而言，推理性能同时受卷积算力、内存带宽、缓存层次与算子实现方式影响，而跨视图匹配、softmax 归一化与几何求解又对数值误差较为敏感。这意味着本章的核心任务并不是简单地“做量化”，而是针对 Snapdragon 8 Gen3 CPU 与 MNN 后端，先识别端侧瓶颈与高风险环节，再据此设计兼顾精度、时延与模型体积的混合精度部署方案。

4.2 问题分析

在正式介绍量化方案之前，本节从三个递进层次分析端侧推理的性能瓶颈：首先通过实测延迟拆解定位计算热点，随后借助 Roofline 模型判断各模块的访存与计算约束类型，最后通过量化敏感性分析识别精度高风险层，为后续的分层混合精度设计提供数据支持。

4.2.1 端侧推理瓶颈的实测分析

为定位第三章所提框架在端侧的计算热点，本节以 Xiaomi 14（Snapdragon 8 Gen3, 16 GB RAM）为目标平台，采用 MNN 推理引擎在 FP16 精度、ARMv8.2 指令集、4 线程 CPU 模式下对各模块逐一计时。计时方法与第三章实验协议保持一致：输入分辨率为 640×480 ，批大小为 1，测试前进行若干次预热以消除冷启动影响，正式计时取 100 次前向的均值，计时范围包含各模块的前向计算，不

含图像解码与 I/O 开销，并以单人场景 ($M = 1$) 为基准。

各模块实测延迟如表 4-1 所示。

表 4-1 本文框架各模块在 Xiaomi 14 (MNN/FP16/CPU 4 线程) 上的实测延迟 (单人场景)

模块	延迟 (ms)	占比 (%)	主要算子类型
左分支骨干	76.7	66.1	Conv, BN, SiLU, CSP
右分支骨干	19.4	16.7	Conv, BN, SiLU, CSP
极线特征增强模块	10.0	8.6	1×1 Conv, 矩阵乘, Softmax
热力图头与置信度头	7.0	6.0	1×1 Conv
可微加权三角化求解器	1.1	0.9	Softmax, 矩阵乘, 特征值分解
端到端合计	116.0	100.0	—

各模块端到端延迟占比 (Xiaomi 14 / MNN / FP16 / 4线程, 单人场景, 共 116.0 ms)




图 4-1 各模块端到端延迟占比 (Xiaomi 14, MNN/FP16/CPU 4 线程, 单人场景)

由表 4-1 与图 4-1 可得到以下结论。

(1) 骨干网络是延迟主体：左右两分支合计占端到端总延迟的绝大部分，其中左分支（全量 CSPDarknet-M）因通道宽度更大（步幅 $s = 8/16/32$ 处分别为 256/512/1024 通道）而耗时显著高于右分支（128/256/512 通道）；这一分布说明骨干推理阶段是优化的首要目标。

(2) EFEM 贡献可观的额外开销：极线注意力模块在 1/16 分辨率特征图上沿视差窗口执行相关运算，由于需要对左分支键值特征进行逐视差位移采样，访存模式不规则，导致其实测延迟与其理论 FLOPs 占比不成正比，是量化收益的次要来源。

(3) 可微加权三角化求解器延迟可忽略：可微加权三角化仅在 $J = 17$ 个关节上执行 4×4 矩阵运算，批大小为 1 时计算量极小，在端到端延迟中占比低于 1%，无量化必要。

4.2.1.1 CSPDarknet 结构特性与量化适应性分析。

CSPDarknet 对 INT8 量化具有天然适应性（网络结构详见第三章图 3-7），体现在三个方面。第一，Conv-BN 可融合：骨干中所有卷积均为标准 Conv+BN+SiLU 结构，MNN 图优化可自动将 BN 参数吸收至前置 Conv 权重，量化对象简化为单一权重矩阵，per-channel 对称量化可精确建模各输出通道的幅值分布。第二，激活分布稳定：SiLU 输出动态范围有界，权重幅值在 BN 归一化后集中，per-channel 缩放因子覆盖率高、量化误差小。第三，延迟由算术负载主导：非对称双分支（左 width=1.0，右 width=0.5）实测延迟比约 $3.95\times$ （76.7ms vs. 19.4ms），与理论计算量比吻合，说明骨干延迟由卷积算术负载决定，INT8 dotprod 加速可直接转化为延迟收益，左分支为首要优化目标。

图 4-2 给出双分支各阶段延迟占比。P3/P4 阶段合计约占各分支延迟 70%（分辨率适中、通道数大，FLOPs 密度最高），是 INT8 量化加速的主要来源；Stem 通道少延迟低；P5 虽通道最多，但分辨率最小（ 15×20 ），FLOPs 绝对值反而低于 P4。




图 4-2 CSPDarknet 双分支各阶段延迟占比（FLOPs 比例估算）。左：CSPDarknet-M（左分支，width=1.0，共 76.7ms）；右：CSPDarknet-N（右分支，width=0.5，共 19.4ms）。

4.2.2 Roofline 分析：访存密集型与计算密集型模块辨别

Roofline 模型以算术强度（Arithmetic Intensity, AI）刻画算子“算得多还是搬得多”，其中 $AI = FLOPs/bytes$ （FLOP/byte）。在给定硬件上，理论可达性能满足

$$P \leq \min(P_{\text{peak}}, B_{\text{eff}} \cdot AI),$$

其中 P_{peak} 为计算峰值、 B_{eff} 为有效带宽。该模型用于判断第三章各模块属于“计算密集”（受算力限制）还是“访存密集”（受带宽限制），从而为后续量化策略确定优先级与预期收益来源。

实验平台为 Xiaomi 14（Snapdragon 8 Gen3，大核集群 $1 \times \text{Cortex-X4}@3.3 \text{ GHz}$ + $3 \times \text{Cortex-A720}@3.15 \text{ GHz}$ ）。在 NEON FP16 下取 4 线程理论峰值算力 $P_{\text{peak}} \approx 100 \text{ GFLOPS}$ ；LPDDR5X 双通道理论带宽 $B_{\text{peak}} \approx 68 \text{ GB/s}$ 。推理阶段由于缓存缺失与控制器利用率等因素，采用更符合实际的有效带宽 $B_{\text{eff}} \approx 40 \text{ GB/s}$ 。由此屋脊点为

$$\text{AI}_{\text{ridge}} = \frac{P_{\text{peak}}}{B_{\text{eff}}} \approx 2.5 \text{ FLOP/byte},$$

因此 $\text{AI} < 2.5$ 的算子主要受带宽约束， $\text{AI} > 2.5$ 的算子主要受算力约束。

4.2.2.1 缓存约束与 B_{eff} 取值依据。

推理阶段的关键在于 LLC 容量瓶颈：FP16 基线权重约 23.4 MB，显著超过 LLC（8 MB），骨干权重难以整体驻留片上，前向过程中需要按层从 LPDDR5X 流水加载，导致 LLC 缺失频繁。因此在 Roofline 中采用 B_{eff} 而非 B_{peak} ，以反映实际访存上限。表 4-2 给出存储层次的容量与带宽量级（L1/L2 为每核独享，LLC 为四核共享）。

表 4-2 骁龙 8 Gen3 存储层次参数（推理阶段相关性分析）

层次	容量	典型带宽（估算）	推理阶段角色
L2 Cache	512 KB–2 MB	$\sim 200 \text{ GB/s}$	热点小算子局部复用
LLC（共享 L3）	8 MB	$\sim 80 \text{ GB/s}$	权重驻留能力瓶颈
LPDDR5X	12 GB	68 GB/s（理论）	权重按层流水加载来源
UFS 4.0	片上存储	$\sim 4 \text{ GB/s}$	模型加载阶段（一次性）

4.2.2.2 模型各模块算术强度计算与分类

以 FP16、batch=1 估算各模块的 AI。对于 3×3 卷积（输入通道 C_{in} 、输出通道 C_{out} 、分辨率 $H \times W$ ），有

$$\text{AI}_{3 \times 3} = \frac{2 C_{\text{in}} \cdot 9 \cdot C_{\text{out}} \cdot HW}{2(9 C_{\text{in}} C_{\text{out}} + C_{\text{in}} HW + C_{\text{out}} HW)}$$

骨干三尺度 3×3 卷积的 $\text{AI} \approx 280\text{--}923 \text{ FLOP/byte}$ ，远高于 AI_{ridge} ，属于计算密集型；EFEM 中 1×1 投影卷积 $\text{AI} \approx 11.3 \text{ FLOP/byte}$ 与热力图头 1×1 卷积 $\text{AI} \approx 15.7 \text{ FLOP/byte}$ 虽位于屋脊点右侧，但相较骨干卷积算术强度低 1–2 个数量级，更靠近屋脊点，因而更容易受到带宽与算子启动/调度开销的共同影响；EFEM

的 gather/correlation (视差维度 $D=24$ 的逐位移采样与点积) $AI \approx 0.04$ FLOP/byte, 为极端访存密集型。表 4-3 汇总各模块的 AI 与瓶颈类型。

表 4-3 各模块算术强度与瓶颈类型 (Roofline 分析, FP16, batch=1)

模块	主要算子	AI (FLOP/byte)	瓶颈类型
左/右骨干 (stride=8, $C=256$)	3×3 Conv	923	计算密集
左/右骨干 (stride=16, $C=512$)	3×3 Conv	784	计算密集
左骨干 (stride=32, $C=1024$)	3×3 Conv	280	计算密集
EFEM 投影 (1×1 Conv)	1×1 Conv	11.3	屋脊点附近
EFEM gather/correlation	逐视差切片点积	0.04	极端访存密集
热力图/置信度头	1×1 Conv	15.7	屋脊点附近
DWT 三角化	矩阵乘/特征值	—	计算量可忽略

图 4-3 给出理论可达点 (空心) 与实测工作点 (实心) 的对比。骨干卷积位于计算密集区, 实测硬件利用率为 72–83%, 与计算屋顶的差距主要来自指令调度开销与数据依赖气泡; EFEM gather 位于极端访存密集区, 实测仅达到有效带宽上限的约 33%, 反映出不规则访存带来的 TLB 缺失与访存合并效率下降; EFEM 投影与预测头处在屋脊点附近, 实测约为理论上限的 44–50%, 受小尺寸算子启动与调度开销影响更明显。




图 4-3 骁龙 8 Gen3 CPU 各模块 Roofline 分析 (FP16, 4 线程, batch=1)。空心点为理论可达点, 实心点为实测工作点 (按比例时延估算); 括号为相对理论上限的利用率。屋脊点为 2.5 FLOP/byte: 左侧为访存密集区, 右侧为计算密集区。

4.2.2.3 Roofline 分析结论

上述结果表明: 骨干卷积的瓶颈主要在算力侧, INT8 可通过 ARMv8.2 dotprod 将 4 线程吞吐提升至约 FP16 的 $2\times$ (约 200 GOPS), 从而直接缩短卷积耗时; EFEM

投影/头部卷积及 `gather` 更易受带宽效率影响，INT8 权重可将 DRAM 读入字节数减半（2 B/param $\rightarrow$ 1 B/param），并通过更高缓存命中率进一步改善有效带宽利用。两类收益叠加，端到端延迟理论上可达约 1.5–1.7 $\times$ 加速，模型体积约 2 $\times$ 压缩（具体取决于分层混合精度的权重占比）。

4.2.3 量化敏感性分析

上一小节的 Roofline 结果表明，INT8 量化在算力侧（骨干卷积）与带宽侧（EFEM 投影、`gather` 等）均存在潜在收益。但端到端三维姿态估计同时包含相关性匹配、`softmax` 归一化与几何求解等数值敏感环节，若盲目对全部层施加 INT8 可能引入不可接受的几何误差。因此，本节在量化前对各模块进行敏感性筛查，识别“可安全量化”的主体层与“必须保护”的高风险层，为后续分层混合精度方案提供依据。

4.2.3.1 实验设置与度量指标

以第三章 FP16 模型为基线，在 RT-Pose 验证集上以 MPJPE 均值作为精度指标。采用逐组替换的方式：每次仅将某一模块的权重或激活替换为 INT8 表示（per-channel 对称量化），其余模块保持 FP16，记录相对基线的变化量 ΔMPJPE 。其中权重量化对应卷积权重的静态离散化；激活量化对应中间特征图的动态离散化，两者对数值稳定性的影响路径不同。

4.2.3.2 结果与关键结论

表 4-4 给出各模块的 ΔMPJPE 与推荐处置，可归纳为三点：

- 1) 骨干与 EFEM 投影的权重量化整体低敏感（ $\Delta\text{MPJPE} < 2.5\text{ mm}$ ），适合作为 INT8 量化的主要覆盖对象；
- 2) EFEM 注意力分数与 DWT 求解相关激活对量化高度敏感（ $\Delta\text{MPJPE} \approx 6.8\text{--}7.3\text{ mm}$ ），应作为精度保护层；
- 3) 热力图与置信度头输出激活呈中等敏感（ $+3\text{--}4\text{ mm}$ ），为避免峰值判别退化，同样建议保护。

4.2.3.3 误差来源解释与保护策略。

从运算特性看，高敏感模块均包含“差异放大”的数值环节：EFEM 注意力分数进入 `softmax` 后，细微分数差异将影响匹配权重分布；DWT 依赖小规模矩阵分解/求解，离散化误差容易直接传递到三维坐标；热力图与置信度输出则决定峰值定位与可信度筛选，对输出分辨率与峰形更敏感。综合结果与 MNN CPU 推理对混合精度的实现方式（量化豁免层以 FP32 执行），本文将精度保护层定义

表 4-4 各模块 INT8 量化敏感性分析（与 FP16 基线相比，RT-Pose 验证集）

量化目标	量化类型	$\Delta\text{MPJPE (mm)}\uparrow$	敏感等级	推荐处置
骨干 Conv+BN 权重（左分支）	权重	+1.8	低	INT8 per-channel
骨干 Conv+BN 权重（右分支）	权重	+1.4	低	INT8 per-channel
EFEM 投影权重 ($\varphi_q/\varphi_k/\varphi_v$)	权重	+2.1	低	INT8 per-channel
EFEM 注意力分数（激活）	激活	+6.8	高	保留 FP32
热力图头输出（激活）	激活	+3.2	中	保留 FP32
置信度头输出（激活）	激活	+4.1	中	保留 FP32
DWT 输入/输出（激活）	激活	+7.3	极高	保留 FP32

为：EFEM 注意力分数（激活，FP32）、热力图与置信度头输出（激活，FP32）、DWT 三角化求解器（全模块，FP32）；其余主体卷积与投影层按 INT8 per-channel 量化。

4.3 混合精度量化方案设计

综合 4.2.1 的延迟拆解、4.2.2 的 Roofline 瓶颈判别与 4.2.3 的敏感性筛查结果，本节将“瓶颈位置”和“误差风险”统一到同一设计框架下。设计目标可概括为：在保持几何推理稳定性的前提下，最大化主体卷积层的 INT8 覆盖率，使量化收益尽可能来自真正主导时延的模块，而不是来自边缘算子的局部压缩。

4.3.1 分层精度分配方案

4.3.1.1 设计原则。

本方案首先回答“什么应优先量化、什么必须保护”。依据 4.2 的证据链结果，骨干与 EFEM 的主体卷积层既主导端侧时延，又表现出较低量化敏感性，因此应作为 INT8 的主要覆盖对象；相反，EFEM 注意力分数、热力图/置信度输出以及 DWT 求解器虽然参数占比很小，却直接影响匹配分布、峰值判别和三维求解稳定性，更适合作为 FP32 保护路径。换言之，本文的混合精度分配并非按模块大小划分，而是按“性能贡献 $\times$ 数值风险”的联合标准划分。

4.3.1.2 量化范围。

基于上述原则，本文混合精度采用**权重静态量化（weight-only PTQ）**：仅对主体卷积权重执行 INT8，以避免在高敏感激活上引入新的误差传播链；对被豁免的高风险算子，MNN 在 CPU 侧保持 FP32 执行，DWT 三角化求解器则以旁路 FP32 形式运行，不进入量化图。这样，量化范围与 4.2 中识别出的低风险高收益区域保持一致。为给出该设计的收益上限与精度代价参照，4.4 同时测试启用激

活量化的“激进 INT8”配置。

4.3.1.3 量化格式。

在 INT8 权重量化实现上, 本文选用 per-channel 对称方案。各输出通道经 BN 归一化后仍存在幅值差异 (stride=32 处通道间差异可达 $6\times$), per-channel 缩放因子可精确适配各通道动态范围, 优于 per-tensor 的单一缩放; 对称量化 (零点固定为 0) 使骁龙 8 Gen3 的 ARMv8.2 dotprod 指令无需零点偏置修正, 对骨干大卷积有实际吞吐收益。

表 4-5 给出具体分层方案。

表 4-5 本文分层混合精度量化方案

模块	操作对象	分配精度	设计依据
左骨干 (全部 Conv+BN)	权重	INT8 per-channel	低敏感; 计算/访存密集
右骨干 (全部 Conv+BN)	权重	INT8 per-channel	低敏感; 计算/访存密集
EFEM 投影 ($\varphi_q/\varphi_k/\varphi_v$)	权重	INT8 per-channel	低敏感; 访存密集
EFEM 注意力分数 (scores)	激活	FP32 (不量化)	高敏感; 视差匹配精度
EFEM 聚合与融合 (ψ)	权重	INT8 per-channel	低敏感
热力图头 (左/右)	权重 + 激活	FP32 (不量化)	中敏感; 坐标回归精度
置信度头 (左/右)	权重 + 激活	FP32 (不量化)	中敏感; 权重自适应精度
DWT 三角化求解器	全部	FP32 (不量化)	极高敏感; 数值稳定性

INT8 量化覆盖左/右骨干全部卷积权重及 EFEM 投影/聚合卷积权重, 合计约 11.6 M 参数, 占模型总参数的 99.1%; FP32 保留层 (EFEM 注意力分数激活、热力图与置信度头权重、DWT) 仅约 0.1 M 参数。混合精度模型理论大小约 12.0 MB, 实际 MNN 文件约 15.2 MB (差异来源于 per-channel 缩放因子存储与 protobuf 结构开销), 相比 FP16 基线 (23.4 MB) 减小约 35%。

4.3.2 后训练量化实施

本文采用后训练量化 (PTQ) 生成可部署的混合精度模型, 而不引入量化感知训练 (QAT)。其原因不在于 PTQ 工程实现更简单, 而在于本章的量化对象主要是经 BN 归一化的标准卷积权重: 这部分权重分布稳定、量化敏感性低, 适合直接采用 per-channel 对称量化; 相反, 真正高风险的激活与几何求解链路已被保留为 FP32, 因此无需通过 QAT 进一步学习误差补偿。换言之, PTQ 在本文中是由问题条件决定的部署选择, 而不是经验性的工程折中。整体流程如图 4-4 所示。

表 4-6 汇总本文 PTQ 的关键配置。本文采用 weight-only PTQ: 借助 mnnconvert 对卷积权重执行 INT8 per-channel 对称量化, 并通过豁免列表保留高敏感张量的




图 4-4 混合精度量化 PTQ 部署流程。从 PyTorch 训练模型出发，经 ONNX 导出、mnnconvert 图优化（Conv-BN 融合 + INT8 per-channel 权重量化 + 豁免层配置）生成 model_mixed.mnn，最终在 Xiaomi 14 真机上验证推理延迟；DWT 求解器以旁路 FP32 脚本形式运行，不经过 ONNX/MNN 量化路径。

FP32 路径；DWT 求解器以旁路 FP32 形式运行，不进入 ONNX/MNN 量化图。模型转换完成后，仅进行输入输出一致性检查与真机推理验证，不再引入额外训练或校准步骤。

表 4-6 后训练量化（PTQ）关键配置（本文混合精度，weight-only）

项目	设置	说明
导出格式	ONNX (opset 17)	输入固定 [1, 3, 480, 640] (batch=1)
图优化	Conv-BN 融合、常量折叠	由 mnnconvert 自动完成
量化对象	仅卷积权重 (weight-only)	避免引入激活量化误差链路
位宽与粒度	INT8, per-channel 对称	适配 dotprod, 通道尺度更稳健
豁免策略	高敏感激活/求解保留 FP32	EFEM scores、热力图/置信度输出、DWT
校准数据	不需要	权重静态量化由权重统计量确定

4.4 实验评估

本节通过三组实验验证所提方案的有效性：首先比较不同精度配置下的精度-效率权衡，其次通过消融实验验证各保护层的必要性，最后考察量化后模型在多人场景中的时延稳定性。

4.4.1 实验设置

硬件平台与推理环境。实验在 Xiaomi 14 真机（Snapdragon 8 Gen3, 16 GB LPDDR5X）上进行，推理框架采用 MNN 2.9.0，编译时启用 ARMv8.2 dotprod 与 FP16 NEON 支持。为保证不同精度配置间的可比性，所有实验均固定 4 线程 CPU 执行环境（1×Cortex-X4 + 3×Cortex-A720），并将推理进程绑定至大核集群以减

小线程调度带来的波动。每种配置预热 10 次后正式计时 100 次，取均值作为延迟报告值；批大小固定为 1，输入分辨率统一为 640×480 。

对比配置。本节测试四种精度配置：（1）FP32 全精度，作为精度上界与速度下界；（2）FP16 全精度（第三章基线）；（3）激进 INT8，在权重量化基础上进一步启用激活量化以追求最大加速，DWT 保留 FP32；（4）本文混合精度（weight-only PTQ），依据表 4-5 仅对主体卷积执行 INT8 权重量化，对高敏感激活与求解器保持 FP32。四种配置共享相同的网络结构、输入尺寸与推理协议，仅精度设置不同；因此其性能差异可主要归因于量化策略本身。

评估指标。精度以 RT-Pose 验证集上的 MPJPE 均值（mm）衡量，同时记录与 FP16 基线的偏差 ΔMPJPE ；效率以端到端推理延迟（ms，单人场景）和模型文件大小（MB）表征，加速比以 FP16 基线（ $1.00\times$ ）为参考归一化。

4.4.2 量化方案对比

四种精度配置的综合评测结果如表 4-7 所示。

表 4-7 不同精度配置的精度-效率综合对比（RT-Pose 验证集，Xiaomi 14/MNN，单人场景）

配置	MPJPE (mm)↓	ΔMPJPE (mm)	延迟 (ms)↓	加速比	模型大小 (MB)
FP32 全精度	158.6	0.0	208.7	$0.56\times$	46.8
FP16 全精度（基线）	158.6	0.0	116.0	$1.00\times$	23.4
激进 INT8	172.0	+13.4	67.8	$1.71\times$	11.7
本文混合精度	160.8	+2.2	72.3	$1.60\times$	15.2

表 4-7 反映出三点。其一，FP32 与 FP16 的 MPJPE 完全一致，而 FP16 延迟仅为 FP32 的约 56%，说明本任务在端侧采用 FP16 不会带来可观测精度损失。其二，激进 INT8 虽取得最高加速比（ $1.71\times$ ），但 MPJPE 增量达到 +13.4 mm，说明对高敏感激活继续量化会显著破坏跨视图匹配与坐标回归精度。其三，本文混合精度以 72.3 ms 的延迟实现 $1.60\times$ 加速，同时仅带来 +2.2 mm 的 MPJPE 增量，表明主要收益已由主体权重量化获得，而关键保护层有效抑制了额外精度损失。综合而言，本文方案保留了激进 INT8 的主要加速收益，同时显著抑制了精度退化，因此在目标平台上表现出更优的精度-效率折中。

4.4.3 消融实验：精度敏感层的必要性验证

为验证混合精度方案中各精度保护层的必要性，本节以本文方案（表 4-5）为基准，逐一将被保护的 FP32 层替换为 INT8，记录 MPJPE 变化。实验结果如表 4-8 所示。

表 4-8 精度敏感层消融实验——将各保护层替换为 INT8 的精度代价 (RT-Pose 验证集)

变体	MPJPE (mm)↓	Δ MPJPE (mm)	延迟 (ms)
本文混合精度 (基准)	160.8	0.0	72.3
+ EFEM 注意力分数改 INT8	167.3	+6.5	71.8
+ 热力图/置信度头改 INT8	163.5	+2.7	72.0
+ DWT 改 INT8 (FP32→INT8)	168.2	+7.4	72.3
+ 以上三者全部改 INT8 ($\approx$ 激进 INT8)	172.4	+11.6	67.8

消融结果进一步验证了保护策略的必要性。EFEM 注意力分数改为 INT8 后, MPJPE 增加 6.5 mm, 是影响最大的单因素, 说明 softmax 前分数精度对视差匹配排序至关重要。DWT 改为 INT8 后, MPJPE 增加 7.4 mm, 表明小规模矩阵分解对数值精度极为敏感。热力图/置信度头改为 INT8 的精度代价相对较小 (+2.7 mm), 但考虑到其参数量极少、压缩收益有限, 保留 FP32 更为合理。三者同时改为 INT8 后, MPJPE 增量达到 +11.6 mm, 已接近激进 INT8 的结果, 说明本文所设保护层基本覆盖了主要精度损失来源。消融末行与表 4-7 中激进 INT8 存在 0.4 mm 差异, 主要来自两组实验的量化路径不同, 不影响总体结论。

4.4.4 多人场景量化稳定性分析

第三章已证明, 本文框架的自底向上整图推理链路在人数增加时延迟增长极为平缓 (1 人 116.0 ms $\rightarrow$ 10 人 117.3 ms)。本节在量化后配置 (本文混合精度) 下复现该实验, 验证 INT8 量化是否影响延迟随人数变化的稳定性。实验结果如表 4-9 所示。

表 4-9 量化前后多人场景端到端延迟对比 (Xiaomi 14/MNN/4 线程, 单位: ms)

人数 M	FP16 基线 (ms)	混合 INT8 (ms)	加速比
1	116.0	72.3	1.60 $\times$
2	116.0	72.3	1.60 $\times$
3	116.1	72.4	1.60 $\times$
5	116.3	72.5	1.60 $\times$
7	116.5	72.8	1.60 $\times$
10	117.3	73.4	1.60 $\times$

量化前后, 随人数增加的延迟增长模式基本一致 (Δ 延迟 ≤ 1.3 ms), 且各人数配置下的加速比稳定保持在 1.60 $\times$ 。这说明本文量化方案并未改变自底向上整图推理的时延特性, 多人场景下的额外开销仍主要来自后处理阶段, 而非量化

本身。该结果表明，本文方案不仅在单人场景下有效，也具备面向多人动态场景的部署稳定性。

4.5 本章小结

本章围绕 Snapdragon 8 Gen3 CPU 端侧部署场景，完成了从性能瓶颈识别到混合精度落地验证的闭环分析，可归纳为以下三点。

第一，端到端时延的主要瓶颈集中在双分支骨干卷积，而 EFEM gather 虽计算量有限，却因不规则访存成为额外热点。Roofline 分析进一步表明，骨干主要受算力约束，EFEM 投影、头部卷积与 gather 更接近带宽约束，因此 INT8 在本文模型上的收益来源同时包含算力侧加速与访存侧压缩。

第二，量化风险在网络中呈明显非均匀分布。骨干权重与 EFEM 投影权重属于低风险高收益量化对象，而 EFEM 注意力分数、热力图/置信度输出以及 DWT 求解器直接影响匹配分布与几何求解稳定性，应作为保护层保留 FP32。基于这一结论，本文形成了“主体权重量化、关键激活与求解路径保护”的分层混合精度方案。

第三，实验结果验证了该方案在目标平台上的有效性。本文混合精度方案以 +2.2mm 的 MPJPE 代价实现 $1.60\times$ 推理加速，并将模型体积由 23.4MB 压缩至 15.2MB；相较于激进 INT8，保留了主要加速收益，同时显著降低了精度退化。多人场景实验进一步表明，量化后模型仍保持与第三章基线一致的时延增长规律。

因此，本章的贡献不在于给出某一组固定平台参数下的经验配置，而在于提出了一套面向目标平台重新标定量化范围的方法流程。上述结论针对 Snapdragon 8 Gen3 CPU 与 MNN 推理后端这一特定执行环境成立；迁移到其他 SoC、GPU/NPU 后端或不同推理框架时，仍需结合目标平台重新进行性能建模与敏感性分析，但“瓶颈定位 + 敏感性筛查 + 分层混合精度设计”的分析路径具有可复用性。

第5章 总结与展望

5.1 总结

5.2 展望

第6章 图像布局

6.1 单图布局

单图布局如图??



图 6-1 单图布局示例

6.2 横排布局

横排布局如图??




图 6-2 横排布局示例

6.3 竖排布局

竖排布局如图??

6.3.1 竖排多图横排布局

竖排多图横排布局如图??



(a)



(b)

图 6-3 竖排布局示例



(a)



(b)

图 6-4 竖排多图横排布局

6.3.2 横排多图竖排布局



(a)



(b)

图 6-5 横排多图竖排布局, 斜体 *emph A*, *A*, 斜体 *textit A*

横排多图竖排布局如图??

6.4 本章小结

本章示例图片布局。

第 7 章 表格插入示例

表 7-1 表格为三线表斜体 *emph A*, *A*, 斜体 *text A*

	<i>AA A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>
1	212	414	4	23	fgw
2	212	414	v	23	fgw
3	212	414	vfwe	23	嗯
4	212	414	4fwe	23	嗯
5	af2	4vx	4	23	fgw
6	af2	4vx	4	23	fgw
7	212	414	4	23	fgw

表格如表??

第 8 章 算法示例

算法 8-1 Fourier-Mellin Based KCF

Input: Image I

preprocessed kernelized template T_κ

Output: scale σ , angle θ relation between I and T

- 1: fourier transform: $F = \mathcal{F}(I)$
 - 2: high pass filter: $F_h = \mathcal{H}(F)$
 $\mathcal{H}(x, y) = (1.0 - \cos(\pi x)\cos(\pi y))(2.0 - \cos(\pi x)\cos(\pi y))$
 - 3: log-polar transform: $F_{lp} = \mathcal{L}(F_h)$
 - 4: apply kernel function: $F_\kappa = \mathcal{K}(F_{lp})$
 - 5: phase correlation: $(\Delta x, \Delta y) = \mathcal{C}(F_\kappa, T_\kappa)$
 - 6: resolove scale and rotation:
 $\theta = \alpha \Delta x, \sigma = \log(\Delta y)$
 where α is translation factor of pixel translation on fourier domain and polar angle on origin image
-

算法 8-2 算法示例

Input: 相关输入。。。。

Output: 相关输出。。。

- 1: 算法描述
 - 2: **for** $i \leftarrow 1 \cdots N$ **do**
 - 3: 算法描述
 - 4: **for each** $j \leftarrow 1 \cdots K$ **do**
 - 5: 算法描述
 - 6: **end for**
 - 7: **end for**
 - 8: **repeat**
 - 9: **repeat**
 - 10: 令 $\tau \leftarrow \tau + 1$
 - 11: **until** 内循环迭代终止条件
 - 12: 。。。
 - 13: **until** 外循环迭代终止条件
-

如算法??

第9章 公式、定理、证明插入示例

$$\text{P1: } \min_{\eta, R_u > 0, R_d > 0} \{T_{\text{latency}}(\eta, R_u, R_d)\} \quad (9-1)$$

$$\text{s.t. } 0 \leq \eta \leq 1 \quad (9-2)$$

公式插入示例如公式 (??)

$$\gamma_x = \begin{cases} 0, & \text{if } |x| \leq \delta \\ x, & \text{otherwise} \end{cases} \quad (9-3)$$

$$\text{P1: } \max_{\substack{P_{m,i}, P_{n,i} \\ q_{m,i}, q_{n,i} \\ \forall n, m, i}} [R_{\text{sum}}(P_{m,i}, P_{n,i}, q_{m,i}, q_{n,i}, \forall n, m, i)], \quad (9-4)$$

$$\text{s.t. } q_{m,i} \in (0, 1), q_{n,i} \in (0, 1), \forall n, m, i, \quad (9-5)$$

$$0 \leq \sum_{i=1}^R q_{n,i} P_{n,i} \leq P_n^{\text{sum}}, \forall n, \quad (9-6)$$

$$0 \leq \sum_{i=1}^R q_{m,i} P_{m,i} \leq P_m^{\text{sum}}, \forall m, \quad (9-7)$$

$$\sum_{i=1}^R q_{n,i} \leq 1, \sum_{i=1}^R q_{m,i} \leq 1, \forall m, n, \quad (9-8)$$

$$\sum_{n=1}^N q_{n,i} \leq 1, \sum_{m=1}^M q_{m,i} \leq 1, \forall i, \quad (9-9)$$

$$C_{m,BS,i}(P_{m,i}, q_{m,i}) \geq \varepsilon_{m,i}, \forall m, \quad (9-10)$$

公式子编号示例：

$$\varphi_{n,t} \in \{0, 1\}, \forall n \in \mathcal{N}, t \in \mathcal{N}_t, \quad (9-11-a)$$

$$\varphi_{n,t} \in \{0, 1\}, \forall n \in \mathcal{N}, t \in \mathcal{N}_t, \quad (9-11-b)$$

$$\varphi_{n,t} \in \{0, 1\}, \forall n \in \mathcal{N}, t \in \mathcal{N}_t, \quad (9-11-c)$$

其中，公式9-11-a表示。

$$H_j = \text{Concat}(\text{GAP}(F_j), \text{GMP}(F_j)), \quad (9-12)$$

$$\tilde{H}_{j-1,j} = \text{Concat}(H_{j-1}, H_j), j = 5, \quad (9-13)$$

$$p_c^{(i)} = \text{Softmax}(\mathbf{P}_\theta(\tilde{H}_{j-1,j})), \quad (9-14)$$

定理和证明环境说明：如”定理”使用小四黑体，编号随章节变化重新编号（如定理 4-1），定理内容使用小四宋体，且内容行距与正文一致；”证明”无需编号，且以黑色小方块结尾。

定理 9-1 开始定理。。。

证明 开始证明。。。 

第 10 章 参考文献插入示例

第 11 章 总结与展望

纯数字编号

1. XXXXXXXXXXXX
2. XXXXXXXXXXXX
3. XXXXXXXXXXXX

罗马编号

- (i) XXXXXXXXXXXX
- (ii) XXXXXXXXXXXX
- (iii) XXXXXXXXXXXX

括号编号

- (1) XXXXXXXXXXXX
- (2) XXXXXXXXXXXX
- (3) XXXXXXXXXXXX

半括号编号

- 1) XXXXXXXXXXXX
- 2) XXXXXXXXXXXX
- 3) XXXXXXXXXXXX

小字母编号

- a) XXXXXXXXXXXX
- b) XXXXXXXXXXXX
- c) XXXXXXXXXXXX

引用测试, 正如1、(i)、(1)、1)、a)所示

11.1 工作展望

手动编号

本课题针对 XX, 鉴于 XXX, 对 XX 进行了提高, 但是 XXX, 所以有如下 XX:

- (1) 目前 XX 虽然 XX, 但是 XX 仍然 XX, 所以 XX 仍然是一个值得 XX 的问题。
- (2) 随着 XX, XX 具有 XX 的问题, 仍值得进一步 XX。
- (3) 本课题在 XX 有了 XX, 但是 XX 的 XX 还存在 XX, 所以 XX。

参考文献

- [1] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context [C]//Computer Vision – ECCV 2014. Springer, 2014: 740-755.
- [2] Andriluka M, Pishchulin L, Gehler P, et al. 2d human pose estimation: New benchmark and state of the art analysis [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2014: 3686-3693.
- [3] Ionescu C, Papava D, Olaru V, et al. Human3.6m: Large scale datasets and predictive methods for 3d human sensing in natural environments [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 36(7): 1325-1339.
- [4] Ho Y H, Cheng J H, Kuan S Y, et al. Rt-pose: A 4d radar tensor-based 3d human pose estimation and localization benchmark [C]//European Conference on Computer Vision. Springer, 2024: 107-125.
- [5] Zhang W, Liu Z, Zhou L, et al. Martial arts, dancing and sports dataset: A challenging stereo and multi-view dataset for 3D human pose estimation [J/OL]. Image and Vision Computing, 2017, 61: 22-39. DOI: [10.1016/j.imavis.2017.02.002](https://doi.org/10.1016/j.imavis.2017.02.002).
- [6] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems. 2017.
- [7] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [J]. arXiv preprint arXiv:2010.11929, 2020.
- [8] Sun K, Xiao B, Liu D, et al. Deep high-resolution representation learning for human pose estimation [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 5693-5703.
- [9] Cao Z, Simon T, Wei S E, et al. Realtime multi-person 2d pose estimation using part affinity fields [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 7291-7299.
- [10] Loper M, Mahmood N, Romero J, et al. SMPL: A skinned multi-person linear model [J]. ACM Transactions on Graphics, 2015, 34(6): 248:1-248:16.
- [11] Martinez J, Hossain R, Romero J, et al. A simple yet effective baseline for 3d human pose estimation [C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2640-2649.

- [12] von Marcard T, Henschel R, Black M J, et al. Recovering accurate 3d human pose in the wild using IMUs and a moving camera [C]//Computer Vision – ECCV 2018. 2018: 601-617.
- [13] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network [J]. arXiv preprint arXiv:1503.02531, 2015.
- [14] Romero A, Ballas N, Kahou S E, et al. Fitnets: Hints for thin deep nets [C]//International Conference on Learning Representations. 2015.
- [15] Zagoruyko S, Komodakis N. Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer [C]//International Conference on Learning Representations. 2017.
- [16] Tu H, Wang C, Zeng W. Voxelpose: Towards multi-camera 3d human pose estimation in wild environment [C]//Computer Vision–ECCV 2020. 2020.
- [17] Lutz S, Blythman R, Ghosal K, et al. Jointformer: Single-frame lifting transformer with error prediction and refinement for 3d human pose estimation [C]//2022 26th International Conference on Pattern Recognition (ICPR). IEEE, 2022: 1156-1163.
- [18] Jiang T, Xie X, Li Y. Rtmw: Real-time multi-person 2d and 3d whole-body pose estimation [J]. arXiv preprint arXiv:2407.08634, 2024.
- [19] Zhang Y, Cai J, Chen S, et al. Mobidepthpose: Efficient depth-aware 3d human pose estimation in videos [C]//European Conference on Computer Vision (ECCV). 2022: 165-182.
- [20] Lu Y, Li Y, Zhang L, et al. Rtmo: Towards high-performance one-stage real-time multi-person pose estimation [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 8583-8592.
- [21] Hirschmuller H. Accurate and efficient stereo processing by semi-global matching and mutual information [C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05): volume 2. IEEE, 2005: 807-814.
- [22] Shamsafar F, Woerz S, Rahim R, et al. Mobilestereonet: Towards lightweight deep networks for stereo matching [C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2022: 2417-2426.

附录 A （附录名称）（三号黑体，加粗）（必要时）

附录正文……（格式参考正文）。换行示例。

攻读学位期间主要的研究成果

一、学术论文

- [1] **Daxia Mou**, Director, Someone. CSU Latex Template[J]. CSU player: 1(1):1-10. **(SCI 检索, JCR 1 区)**
- [2] Director, **Daxia Mou**, Someone, Someother. XXXXXX[J]. Transactions on Image Processing. **(SCI Under Review, JCR 1 区)**
- [3] Director, **Daxia Mou**, Someone, Someother. XXXXXX[J]. Transactions on Circuits and Systems for Video Technology. **(SCI Under Review, JCR 1 区)**

二、发明专利

- [1] 某大侠, XXX, XXX. 一种用 Latex 写中南大学学位论文的方法. 申请号: CN20190415xxxx, 公开号: CNXXXXXXXXXA

三、主持和参与的科研项目

- [1] 国家自然科学基金面上项目《XXXXXXXXXXXXX》,项目编号:XXXXXXXX, 参与.

四、个人获奖情况

- [1] XX 金奖
- [2] XX 奖学金

致 谢

作者对给予指导、各类资助和协完成研究工以及提供种论文有作者对给予指导、各类资助和协完成研究工以及提供种论文有利条件的单位及个人表示感谢。

致谢应实事求是，切忌浮夸与庸俗之词。