

骁龙 8 Gen3 CPU Roofline 模型 (FP16, 4 线程, batch = 1)

性能 (GFLOPS)

10^3

10^2

10^1

1

访存密集区

计算密集区

EFEM 投影 (1×1 Conv) 44%

预测头 (1×1 Conv) 50%

40 GB/s 带宽

EFEM gather (视差相关) 33%带宽

屋脊点 (2.5, 100)
= $P_{\text{peak}}/B_{\text{eff}}$

100 GFLOPS 算力峰值

骨干 P3 (stride=8) 83%

骨干 P5 (stride=32) 72%

骨干 P4 (stride=16) 80%

- Roofline 理论上限
- 理论可达点 (ON Roofline)
- 实测工作点
- 骨干卷积 (P3/P4/P5)
- EFEM 投影 / 预测头
- EFEM gather

10^{-2}

10^{-1}

1

10^1

10^2

10^3

算术强度 (FLOP/byte)